

Universidad de Valladolid

Universidad de Valladolid

Facultad de Ciencias

Extensión y optimización del procedimiento CIRCUST de reconstrucción temporal

Trabajo de Fin de Grado en Estadística

Autor:
Samuel Ortega Bustos

Tutores:
Yolanda Larriba González
Juan Camilo Yepes Borrero

Curso Académico 2025-2026

27 de octubre de 2026

Resumen

La estimación de la fase circadiana a partir de datos transcriptómicos representa un reto central en cronobiología, especialmente en estudios humanos donde las etiquetas temporales suelen ser inaccesibles por restricciones éticas o clínicas. El algoritmo CIRCUST, basado en el Análisis de Componentes Principales Circulares (CPCA), ha demostrado ser una herramienta prometedora para la reconstrucción del orden temporal. Sin embargo, su implementación actual carece de la modularidad necesaria y de mecanismos para ajustar covariables o manejar muestreos dispersos.

Este trabajo presenta una re-implementación modular y eficiente de CIRCUST en Python, junto con un refinamiento metodológico profundo. Las mejoras incluyen la integración de ajustes por covariables y una optimización de la ordenación circular para mejorar la inferencia de fase. Además, se ha desarrollado un marco de simulación para evaluar sistemáticamente la robustez del modelo frente a perturbaciones como el ruido y los efectos por lotes. Finalmente, el pipeline mejorado se valida utilizando conjuntos de datos transcriptómicos reales del cerebro humano post-mortem, demostrando una mayor precisión y relevancia biológica.

Palabras clave: Cronobiología, Transcriptómica, Ordenación Circular, CPCA, Python.

Abstract

Estimating circadian phase from transcriptomic data is a central challenge in chronobiology, particularly in human studies where time-of-day labels are often unavailable. The CIRCUST algorithm, based on Circular Principal Component Analysis (CPCA), offers a promising approach for temporal order reconstruction. However, its current implementation lacks modularity, extensibility, and built-in mechanisms to adjust for covariates or to handle sparse sampling patterns.

This project presents a modular and efficient re-implementation of CIRCUST in Python, alongside a deep methodological refinement. Improvements include the integration of covariate adjustments and enhanced circular ordering for better phase inference. Furthermore, a simulation framework is developed to systematically evaluate robustness against perturbations such as noise and batch effects. Finally, the improved pipeline is validated using real post-mortem human brain transcriptomic datasets, demonstrating improved accuracy and biological relevance.

Keywords: Chronobiology, Transcriptomics, Circular Ordering, CPCA, Python.

Índice general

Índice de figuras IV

Índice de tablas V

1. Introducción **1**

1.1. El sistema circadiano: ritmos, reloj molecular y genes circadianos 1

1.2. Análisis de genes circadianos humanos: modelos para el análisis de señales oscilatorias 3

1.3. Atlas de expresiones circadianas humanas. El problema de estimación del orden temporal 4

1.3.1. Limitaciones de los datos de expresión génica humana 4

1.3.2. Atlas de expresión circadiana humana 5

1.4. Estimación del orden temporal en estudios transcriptómicos *post mortem* . 6

1.5. Objetivos del trabajo 8

1.6. Asignaturas relacionadas con el Trabajo de Fin de Grado 9

2. Metodología **10**

2.1. Antecedentes Metodológicos 10

2.1.1. Notación 10

2.1.2. Formulación del problema de estimación del orden temporal. Orden circular 10

2.1.2.1. Orden circular 11

2.1.3. El algoritmo CIRCUST 11

2.1.4. El modelo FMM monocomponente 14

2.1.4.1. Estimación de los parámetros del modelo FMM 15

2.2. Propuesta metodológica 16

2.2.1. Regularización del procedimiento de estimación del modelo FMM . 16

2.2.1.1. Ponderación temporal del diseño de muestreo 16

2.2.1.2. Regularización en la estimación FMM 17

2.2.2. Elección de un orden circular óptimo 18

2.2.2.1. Selección de la mejor ordenación circular 19

2.2.2.2. Construcción de una ordenación circular de consenso . . . 20
2.2.2.2.1. Agregación mediante el Problema del Viajante (TSP3) . . . 20
2.2.2.2.2. Agregación mediante la teoría de Hodge (HOD) . 23
2.2.2.2.3. Agregación mediante la media circular 26
2.2.2.3. Estimación de las fases asociadas al orden de consenso . . 26
2.2.3. Mejora de CIRCUST: implementación modular y eficiencia 27
2.2.3.1. Implementación modular y extensiones de CIRCUST . . . 28
2.2.3.1.1. Preprocesado 28
2.2.3.1.2. Selección de genes *core* 29
2.2.3.1.3. CPCA y detección de *outliers* 29
2.2.3.1.4. Sincronización del orden circular 30
2.2.3.1.5. Identificación de genes TOP 31
2.2.3.1.6. Estimación iterativa de órdenes circulares 31
2.2.3.1.7. Orden final y caracterización de los genes TOP . 32
2.2.3.1.8. Modelos de ajuste 33
2.2.3.2. Eficiencia computacional 33
2.2.3.2.1. Herramientas de Python 34
2.2.3.2.2. Compilación de los núcleos de cálculo 34
2.2.3.2.3. Precálculo y reutilización 34
2.2.3.2.4. Paralelización 35
2.2.3.2.5. Supresión de cálculos innecesarios 35

3. Simulaciones **37**
3.0.1. Escenarios de simulaciones 37
3.0.2. Validación 37

4. Experimentos con datos reales **38**
4.0.1. Descripción del conjunto de datos 38
4.0.2. Resultados 38

5. Conclusiones y Trabajo Futuro **39**

Bibliografía **40**

A. Material complementario **45**
Listado de acrónimos 45
A.1. Otros métodos de estimación del orden temporal 47
A.1.1. CYCLOPS 47
A.1.2. CYCLOPS 2.0 49
A.1.3. CHIRAL 49

A.2. Metodología CPCA 51
A.2.1. Fundamentos: componentes circulares en PCA no lineal 51
A.2.2. CPCA en CIRCUST: construcción de los *eigengenes* y de la escala circular 51
A.3. Genes Core 53
A.4. Detección de muestras atípicas 54
A.4.1. Criterio radial sobre los *eigengenes* 54
A.4.2. Criterio basado en los residuos del modelo FMM 54
A.4.3. Criterio para la detección de *outliers* 55
A.5. Sincronización del orden circular 56
A.6. Parámetros del modelo FMM e interpretación circadiana 58
A.6.1. Parámetros del modelo 58
A.6.2. Parámetros FMM 59
A.6.3. Medida de bondad de ajuste 60
A.6.4. Criterios para la identificación de genes TOP 60
A.7. Regularización de la estimación del modelo FMM 62
A.7.1. Riesgo de sobreajuste para valores pequeños de ω 62
A.7.2. Funcional de rugosidad $R(\alpha, \omega)$ 62
A.7.3. Modulación de la penalización 64
A.7.4. Calibración del parámetro de regularización λ 64
A.7.5. Refinamiento local 65
A.8. Pasos de los módulos de la implementación 65
A.8.1. Módulo 1. Preprocesado 65
A.8.2. Módulo 2. Selección de genes *core* 66
A.8.3. Módulo 3. CPCA y detección de *outliers* 66
A.8.4. Módulo 4. Sincronización del orden circular 66
A.8.5. Módulo 5. Identificación de genes TOP 67
A.8.6. Módulo 6. Estimación iterativa de órdenes circulares 68
A.8.7. Módulo 7. Orden final y caracterización de los genes TOP 69
A.9. Detección de muestras atípicas con *splines* cúbicos periódicos 70
A.9.1. Spline cúbico periódico 70
A.9.2. Ajuste y residuos estandarizados 70
A.9.3. Regla de decisión 71
A.9.4. Alcance 71
A.10. Verificación de la orientación mediante pares de genes 72
A.10.1. Por qué es necesaria una verificación 72
A.10.2. Relación de orden entre dos genes sobre la circunferencia 72
A.10.3. Puntuación y decisión 73
A.10.4. Alcance 74

Índice de figuras

1.1. Organización jerárquica del sistema circadiano. 2
1.2. Esquematización del ritmo circadiano subyacente en datos de expresión de un gen circadiano en 24 horas. 2

2.1. Esquema del procedimiento de agregación TSP3. 24
2.2. Esquema del procedimiento de agregación HOD en su variante HODs. . . . 26

A.1. Detección de muestras atípicas con *splines* cúbicos periódicos. (a) Base de $m = 5$ nodos, con cuatro funciones B-*spline* periódicas que suman uno. (b) Ajuste a un gen *core* simulado, con una muestra atípica en naranja. (c) Residuos estandarizados y umbrales $\pm 3{,}5$. Los datos son sintéticos. 71
A.2. Verificación de la orientación con el seno de la diferencia. (a) Un par con g_1 a las 23 h y g_2 a la 1 h. La comparación lineal falla por el corte de la escala, mientras que el seno de la diferencia es positivo. (b) Aportación $\sin \delta$ de un par según la separación entre sus máximos, y su opuesto tras invertir la orientación. 73

Índice de tablas

2.1. Definición de $\lambda^{(k)}_{i_1 i_2 i_3}$ en las variantes del método de Hodge seleccionadas por Barragán et al. [1], con $V = \{1, \ldots, n\}$, $V^{(l)} = V \setminus \{l\}$ e i_1, i_2, i_3 las posiciones de las tres muestras en $\mathbf{o}^{(k)}$, y $R^{(k)}_{i_1 i_2 i_3}$ la longitud resultante media de $\varphi_{o^{(k)}_{i_1}}$, $\varphi_{o^{(k)}_{i_2}}$ y $\varphi_{o^{(k)}_{i_3}}$. 25
2.2. Estrategias de eficiencia computacional aplicadas en cada módulo. 36

A.1. Parámetros del modelo FMM monocomponente y características circadianas derivadas del ajuste. 60

Capítulo 1

Introducción

1.1. El sistema circadiano: ritmos, reloj molecular y genes circadianos

Los ritmos circadianos subyacen a una gran variedad de procesos biológicos en prácticamente todos los organismos vivos, desde cianobacterias hasta seres humanos [2]. Estos ritmos se manifiestan en distintos niveles de organización biológica, incluyendo procesos fisiológicos, hormonales y moleculares, como la regulación de la temperatura corporal, el ritmo cardíaco, la secreción de cortisol y melatonina o la expresión génica. Sincronizados principalmente por el ciclo diario de luz y oscuridad, los ritmos circadianos desempeñan un papel fundamental en la regulación y coordinación temporal de procesos fisiológicos, metabólicos y conductuales a lo largo de las 24 horas del día [3, 4, 5, 6].

En mamíferos, la organización del sistema circadiano es jerárquica [7]: un oscilador central, conocido como reloj circadiano central y localizado en el núcleo supraquiasmático del hipotálamo [8], recibe información lumínica desde la retina y la utiliza para sincronizarse con el ciclo externo de luz y oscuridad. Este reloj actúa como marcapasos y coordina osciladores periféricos presentes en órganos y tejidos. La correcta sincronización entre estos relojes resulta esencial para mantener la coordinación temporal de los procesos fisiológicos y metabólicos del organismo, así como su adecuada adaptación a las condiciones ambientales. A nivel molecular, tanto el reloj central como los relojes periféricos se sustentan en redes de genes reloj organizadas en bucles de retroalimentación entre la transcripción y la traducción, que generan oscilaciones de expresión génica con un periodo cercano a las 24 horas y permiten mantener la ritmicidad circadiana en cada tejido [3, 9]. La Figura 1.1 muestra una esquematización de dicha estructura jerárquica.

Esta arquitectura jerárquica da lugar a patrones de expresión génica rítmica específicos de cada tejido. Denominaremos genes circadianos a aquellos cuya expresión presenta oscilaciones con un periodo aproximado de 24 horas, véase Figura 1.2. Estos genes desempeñan un papel fundamental en la regulación temporal de procesos celulares y fisiológicos,

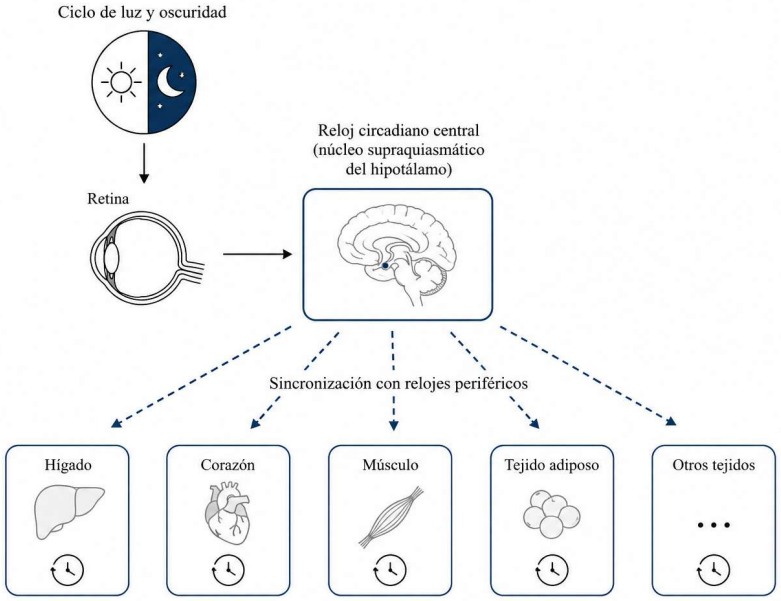


Figura 1.1: Esquematización de la organización jerárquica del sistema circadiano: el reloj central se sincroniza con la luz a través de la retina, así como con los relojes periféricos de los distintos órganos o tejidos.

favoreciendo que las distintas funciones biológicas se ejecuten de forma coordinada a lo largo del día. En particular, el instante de máxima expresión génica (pico de expresión) se encuentra estrechamente relacionado con el momento del día en que el gen ejerce su función biológica [10, 11].

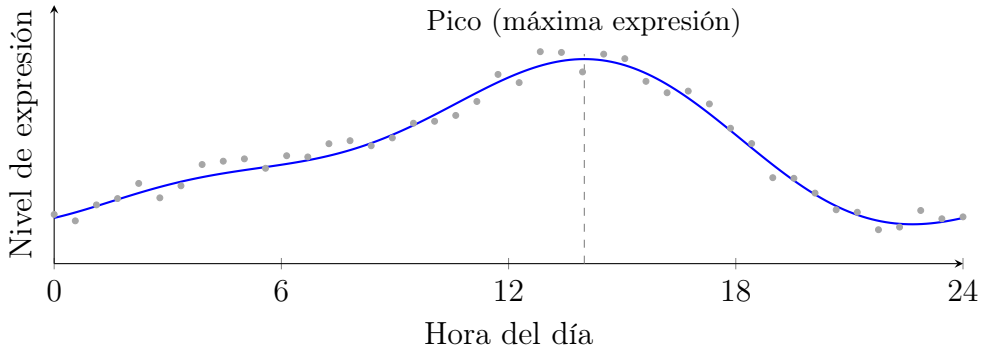


Figura 1.2: Esquematización del ritmo circadiano subyacente en datos de expresión de un gen circadiano en 24 horas. Los puntos representan las observaciones de expresión y la línea azul el patrón oscilatorio subyacente. El pico marca el instante de máxima expresión y se relaciona con el momento del día en que el gen realiza su función biológica.

En el contexto de la biología circadiana humana, ámbito en el que se centra este trabajo, la relevancia de los ritmos y genes circadianos ha sido ampliamente documentada, existiendo evidencia de variaciones temporales en resultados clínicos y en la respuesta a distintas intervenciones terapéuticas, como la cirugía cardíaca, la quimioterapia o la

respuesta inmune [12, 13, 14]. En contraposición, se ha evidenciado que la desalineación crónica del reloj circadiano, asociada al trabajo por turnos (*shift work*), al *jet lag* social o a la exposición nocturna a luz artificial, constituye un factor de riesgo para trastornos metabólicos, enfermedades cardiovasculares, trastornos neurodegenerativos y diversos tipos de cáncer [15, 16].

1.2. Análisis de genes circadianos humanos: modelos para el análisis de señales oscilatorias

La identificación y caracterización de los genes circadianos constituye un reto fundamental en biología circadiana, ya que permite comprender cómo se organizan y sincronizan los procesos moleculares y fisiológicos con los ciclos ambientales, sentando las bases para el desarrollo de estrategias de cronomedicina y medicina de precisión.

Los modelos para el análisis de señales oscilatorias más empleados en cronobiología para describir e identificar ritmos circadianos son los modelos armónicos sinusoidales, normalmente con un único componente de periodo fijado, por ejemplo 24 horas, entre los que destaca el modelo Cosinor [17]. Este enfoque representa la señal mediante una función cosenoidal, habitualmente con un periodo prefijado, y permite estimar parámetros interpretables como la amplitud, la fase y el nivel medio de expresión. Este tipo de aproximación resulta útil por su sencillez e interpretabilidad, pero puede ser limitada cuando las señales presentan formas asimétricas o patrones de oscilación más complejos.

Como alternativa, existen métodos no paramétricos como RAIN [18] o JTK_CYCLE [19] o más recientemente ORI [20], que permiten identificar patrones rítmicos sin imponer una forma funcional tan rígida. Sin embargo, no siempre proporcionan parámetros directamente interpretables desde el punto de vista biológico, lo que puede dificultar la caracterización posterior de las diferencias entre grupos o regiones.

En este contexto, destacan los modelos FMM (Frequency Modulated Möbius) [21], una familia de modelos paramétricos flexibles diseñada para modelizar señales oscilatorias complejas mediante un conjunto reducido de parámetros con interpretación fisiológica. Estos modelos constituyen una alternativa especialmente adecuada para describir patrones de expresión génica no sinusoidales o asimétricos. Además, su sólido fundamento matemático ha favorecido el desarrollo de numerosas extensiones metodológicas y su aplicación al análisis de señales oscilatorias en distintos ámbitos de la cronobiología.

La aplicación de estos modelos resulta especialmente relevante en el estudio de la expresión génica circadiana. En este ámbito, la identificación y caracterización precisa de los genes circadianos, así como de sus relaciones intra- e intertisulares, constituye uno de los principales retos de la cronobiología, ya que es fundamental para comprender la regulación y coordinación de los relojes circadianos entre tejidos humanos y su interacción

con el entorno.

Este objetivo se materializa en los denominados atlas de expresión circadiana, que describen la regulación temporal de la expresión génica a escala del organismo y constituyen un recurso clave para el descubrimiento de biomarcadores temporales y el desarrollo de estrategias terapéuticas *time-aware* [22, 23, 6, 24, 25, 26]. Hasta la fecha se dispone de atlas de expresiones circadianas humanas para un número muy reducido de tejidos, generalmente periféricos. Esta limitación ha llevado tradicionalmente a recurrir tradicionalmente a estudios en especies homólogas, como ratones o babuinos, donde es posible obtener muestras in vivo. Aunque estos modelos han servido como referencia para guiar la toma de decisiones en humanos, es evidente que pueden introducir sesgos relevantes.

1.3. Atlas de expresiones circadianas humanas. El problema de estimación del orden temporal

Para abordar el problema de la identificación y caracterización de genes circadianos humanos orientado al avance en la construcción de atlas de expresión génica circadiana en humanos, así como al estudio de la interrelación entre tejidos de estos genes, resulta imprescindible disponer de matrices de datos de expresión génica humana a lo largo de las 24 horas en una amplia colección de tejidos y órganos. Sin embargo, la obtención de dichos datos transcriptómicos longitudinales no es viable por razones clínicas y éticas, lo que motiva el uso de datos de expresión *post mortem* en estudios transcriptómicos humanos.

1.3.1. Limitaciones de los datos de expresión génica humana

A diferencia de lo que ocurre en estudios experimentales con modelos animales, donde la variable temporal puede observarse de forma controlada mediante muestreos realizados a distintas horas del día, en humanos este tipo de diseño no es viable debido al riesgo que implica la obtención de biopsias seriadas de tejidos internos a lo largo del día. Como consecuencia, el análisis transcriptómico en humanos habitualmente se realiza a partir de estudios transversales con muestras *post mortem*, en las que el tiempo biológico interno de cada individuo no se observa directamente y debe ser inferido a partir de la información disponible.

Como aproximación a esta limitación, algunos estudios utilizan la hora de muerte (*TOD*, del inglés *Time of Death*) como referencia temporal. Sin embargo, emplear directamente esta variable puede inducir una ordenación inadecuada de las muestras, ya que la hora de fallecimiento no tiene por qué coincidir con la fase circadiana real del individuo. Factores como el cronotipo, los hábitos de sueño, determinadas patologías, la medicación

o las condiciones previas al fallecimiento pueden provocar discrepancias entre el tiempo externo registrado y el estado circadiano interno.

A esta incertidumbre temporal se añade la elevada variabilidad característica de los estudios transcriptómicos humanos. Por un lado, existe variabilidad técnica derivada de la degradación del ARN (Ácido ribonucleico), de errores sistemáticos o aleatorios en los dispositivos de medición y de la heterogeneidad de los protocolos experimentales entre laboratorios. Por otro, al tratarse de datos transversales procedentes de individuos distintos, también existe una importante variabilidad biológica y clínica. Variables como la edad, el sexo, la causa de la muerte, el estado clínico o la historia individual de sueño pueden influir en la expresión génica y dificultar la separación entre la variabilidad interindividual y la asociada al momento circadiano.

Además, los estudios transcriptómicos humanos *post mortem* suelen presentar una cobertura temporal irregular a lo largo del ciclo circadiano, ya que determinadas franjas horarias se encuentran sobrerrepresentadas mientras que otras apenas disponen de muestras [27, 28]. Esta distribución no uniforme compromete la identificación de genes circadianos y dificulta la caracterización precisa de sus patrones de expresión.

En conjunto, estas limitaciones han condicionado significativamente el avance de la biología circadiana humana, al dificultar la construcción de atlas transcriptómicos circadianos multitisulares de referencia. Como consecuencia, gran parte del conocimiento inicial sobre ritmicidad circadiana procede de modelos animales mantenidos bajo condiciones experimentales altamente controladas, que no reproducen la complejidad ni la variabilidad inherentes a la fisiología humana y que pueden introducir sesgos en las conclusiones[22]. También se han desarrollado atlas transcriptómicos en especies filogenéticamente próximas, como el babuino [6], aunque su reducido tamaño muestral limita la reproducibilidad y la generalización de los resultados. Esta situación dificulta tanto la validación objetiva de nuevas metodologías como la comparación sistemática de los patrones de expresión circadiana entre tejidos humanos, constituyendo un reto adicional para comprender la organización temporal del transcriptoma humano a escala multitisular.

1.3.2. Atlas de expresión circadiana humana

Las limitaciones asociadas al acceso a datos de expresión génica humana han ralentizado el desarrollo de estos atlas, ya que requieren una estimación previa del tiempo biológico de las muestras, problema conocido en estadística como estimación del orden temporal.

Los trabajos centrados en humanos son escasos y principalmente se basan en muestras *post mortem*, en su mayoría procedentes del proyecto GTEx (*Genotype-Tissue Expression*) [29], principal referencia para el estudio de la expresión génica en tejidos humanos *post mortem*. Aunque GTEx registra para cada donante una estimación del instante de fallecimiento (*Time of Death*, TOD), esta medida suele ser imprecisa y no refleja necesariamente

la fase circadiana interna del individuo.

Los atlas de expresión circadiana humana desarrollados durante la última década se han construido a partir de distintos algoritmos de estimación del orden temporal e hipótesis biológicas tal y como se detalla en la siguiente sección. Entre ellos destacan:

- Atlas de 13 tejidos de Ruben et al. [24]: primer atlas circadiano multitisular humano, basado en el algoritmo CYCLOPS y en información circadiana conservada entre ratón y humano, lo que introduce una dependencia de referencias e información externas.

- Atlas de 34 tejidos de Larriba et al. [26]: primer atlas circadiano de tejidos humanos no cerebrales construido exclusivamente con transcriptómica humana mediante CIRCUST. Requiere un conjunto de genes rítmicos, estimar sus momentos de máxima expresión y estudiar su organización temporal entre tejidos.

- Atlas de 46 tejidos de Talamanca et al. [30]: atlas circadiano humano basado en el algoritmo CHIRAL, que integra información transcriptómica multitisular y requiere también información de un conjunto de genes de referencia. Su principal limitación es la dependencia de patrones circadianos compartidos entre tejidos, que puede dificultar la caracterización de ritmos específicos de cada tejido.

La estimación del orden temporal de las muestras constituye un problema central para la construcción de atlas circadianos humanos, ya que la metodología empleada para resolverlo y la precisión del orden estimado condicionan directamente los resultados del atlas, en particular la identificación de genes rítmicos, la estimación de sus fases de expresión y la caracterización de su organización temporal entre tejidos. Este problema resulta particularmente complejo debido a la elevada incertidumbre y heterogeneidad inherentes a los datos transcriptómicos *post mortem*.

1.4. Estimación del orden temporal en estudios transcriptómicos *post mortem*

Los algoritmos de estimación del orden temporal comparten generalmente varios elementos metodológicos comunes: la selección o definición de un conjunto de genes circadianos de referencia (*core genes* o *seed genes*), la reducción de dimensionalidad de la matriz de expresión génica a partir de dichos genes, y la construcción de un espacio latente de naturaleza circular que permita representar la trayectoria circadiana subyacente de la ordenación de las muestras. Entre los métodos más utilizados destacan CYCLOPS [31] y CYCLOPS 2.0 [32], CIRCUST [26] y CHIRAL [30].

CYCLOPS es hasta la fecha la metodología de estimación del orden temporal más extendida de referencia en la literatura. Su estrategia combina una reducción de dimensionalidad basada en componentes principales con un *autoencoder* de geometría circular que proyecta las muestras sobre una representación latente en la que la posición angular se interpreta como tiempo circadiano. Aunque ha demostrado un excelente rendimiento en aplicaciones reales, su dependencia de conjuntos de genes homólogos en otras especies y la pérdida de rendimiento en muestras reducidas constituyen algunas de sus principales limitaciones. CYCLOPS 2.0 es una extensión reciente que permite incorporar covariables durante la estimación del orden temporal, lo que permite tener en cuenta fuentes de variabilidad ajenas al ritmo circadiano y mejorar la estimación de las fases temporales. No obstante mantiene dependencia de genes circadianos de referencia. La Sección A.1 del Anexo incluye una descripción detallada de los fundamentos metodológicos, hipótesis y principales características de estos algoritmos. Otros algoritmos que comparten la misma filosofía de *autoencoders* circulares son PENN [33], PROTECT [34] o COFE [35].

CHIRAL adopta un enfoque probabilístico en el que la fase circadiana de cada muestra se considera una variable latente circular y la expresión de los genes reloj de referencia se modeliza mediante funciones armónicas. Los parámetros de expresión se integran analíticamente dentro de un modelo bayesiano y las fases circadianas se estiman mediante maximización de la distribución *a posteriori*. El procedimiento consta de dos etapas, primero se estiman las fases de las muestras de cada tejido y, posteriormente, se combinan para obtener una fase circadiana por donante. Esta estrategia permite aprovechar la información de tejidos con señales circadianas más robustas para mejorar la ordenación de aquellos con señales más débiles. Sin embargo, depende de la existencia de relaciones de fase suficientemente estables entre tejidos, lo que puede limitar su capacidad para caracterizar diferencias temporales específicas de cada tejido. La descripción detallada de CHIRAL se recoge en la Sección A.1.3 del Anexo.

A diferencia de los algoritmos anteriores, CIRCUST (CIRCular-robUST) aborda el problema desde una perspectiva diferente, fundamentada en estadística direccional y en el modelo para el análisis de señales oscilatorias FMM. Su principal aportación radica en proporcionar un marco matemático explícito para formular la estimación del orden temporal como un problema de optimización sobre un espacio circular, aprovechando la naturaleza intrínsecamente periódica de los patrones de expresión de los genes circadianos. Este marco permite resolver de forma directa problemas inerentes como la sincronización del orden estimado para ello, el método combina la selección de un conjunto inicial de genes *core*, una reducción de dimensionalidad no lineal basada en *CPCA* (*Circular Principal Component Analysis*) [36, 37] y el uso del modelo paramétrico FMM, cuya formulación incorpora de manera natural la geometría circular de las señales oscilatorias.

A diferencia de los métodos anteriores, cuyo objetivo principal es la reconstrucción del orden temporal de las muestras, CIRCUST se desarrolló con el propósito de proporcionar

una caracterización robusta de los marcadores circadianos en estudios transcriptómicos *post mortem*, permitiendo la construcción del primer atlas transcriptómico circadiano multitisular basado exclusivamente en información transcriptómica humana. Para ello, la estimación del orden temporal constituye un problema intermedio que se resuelve mediante un procedimiento iterativo de refinamiento, en el que las estimaciones temporales y la identificación de genes circadianos se actualizan de forma conjunta hasta alcanzar una solución estable. Este enfoque permitió caracterizar genes circadianos mediante parámetros interpretables del modelo FMM, como la amplitud o los instantes de máxima expresión génica, en 34 tejidos humanos, no cerebrales, del proyecto GTEx. No obstante, su rendimiento depende de la calidad y representatividad del conjunto inicial de genes *core* utilizado para iniciar el procedimiento iterativo. Además, el algoritmo no proporciona una solución única para la estimación del orden temporal, sino que esta depende del punto de partida definido por dicho conjunto de genes de referencia.

1.5. Objetivos del trabajo

El objetivo principal de este trabajo es el desarrollo de nuevas metodologías y herramientas de *software* estadístico orientadas a la extensión y optimización del algoritmo CIRCUST para la estimación del orden temporal. En particular, se persigue incrementar su flexibilidad metodológica, mejorar su eficiencia computacional y ampliar su aplicabilidad en estudios transcriptómicos humanos a gran escala, favoreciendo así su potencial uso en investigación biomédica. Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. **Re-implementación modular en Python del algoritmo CIRCUST.** Diseñar e implementar una arquitectura modular en la que cada etapa original de CIRCUST quede aislada en componentes independientes, reproducibles, fáciles de extender y acoplar en etapas futuras, y computacionalmente eficiente. La implementación se acompañará de una guía y ejemplos de uso.

2. **Incorporación de una metodología de estimación FMM ponderada y regularizada.**Integrar en CIRCUST una extensión metodológica del modelo FMM que incorpora ponderaciones basadas en la distribución temporal de las muestras para corregir desequilibrios en el muestreo y una penalización de la rugosidad para estabilizar la estimación de perfiles oscilatorios asimétricos o muy localizados.

3. **Desarrollo de un módulo de selección óptima del orden temporal.** Desarrollar un módulo de consenso para la estimación del orden temporal que permita obtener una solución óptima a partir de las estimaciones del orden temporal obtenidas en el proceso iterativo. Se evaluarán estrategias basadas en la minimización

de discrepancias circulares y en la agregación de órdenes circulares, con el objetivo de mejorar la robustez, estabilidad y reproducibilidad de la estimación final.

4. **Diseño de un experimento de simulación y validación.** Diseñar un marco de validación basado en datos sintéticos que reproduzca las características de los estudios transcriptómicos circadianos, permitiendo evaluar de forma sistemática la precisión, robustez y estabilidad de la metodología propuesta para la estimación del orden temporal bajo distintos escenarios experimentales.

5. **Aplicación a un conjunto de datos reales.** Evaluar la eficiencia de la metodología propuesta en conjuntos de datos de expresión humana *post mortem*, así como en modelos animales. (A concretar cuando se haya realizado.)

1.6. Asignaturas relacionadas con el Trabajo de Fin de Grado

El desarrollo de este trabajo se apoya en competencias adquiridas en varias asignaturas del Grado en Estadística:

- Estadística Descriptiva. Proporciona las herramientas básicas para la exploración, síntesis numérica y representación gráfica de los datos, esenciales en cualquier análisis estadístico posterior.

- Inferencia Estadística I y II. Proporcionan el marco para la validación de los resultados y la evaluación de modelos, aspectos centrales en la metodología de validación propuesta en este trabajo.

- Técnicas de Aprendizaje Automático. Aporta los fundamentos de las técnicas de aprendizaje automático y de la metodología experimental para la evaluación y comparación de modelos.

- Análisis de Datos y Análisis Multivariante. Aportan las técnicas de análisis multivariante y, en particular, el Análisis de Componentes Principales, que constituye la base del CPCA sobre el que se sustenta CIRCUST.

- Regresión y Anova y Modelos Lineales. Estas materias conforman el pilar de la modelización estadística del grado. Aportan el marco teórico y práctico necesario para abordar el análisis de expresión génica realizado en este trabajo.

- Computación Estadística y Fundamentos de Programación. Fundamenta la programación y la implementación computacional del algoritmo, así como su optimización.

Capítulo 2

Metodología

2.1. Antecedentes Metodológicos

2.1.1. Notación

Sea $\mathbf{X} \in \mathbb{R}^{G \times n}$ la matriz de expresión génica, donde las G filas corresponden a genes (del orden de decenas de miles) y las n columnas a las muestras (habitualmente de decenas a cientos de individuos). El elemento X_{gi} representa la expresión del gen g, con $g = 1, \ldots, G$, en la muestra i, con $i = 1, \ldots, n$. En este trabajo, en general, se asume que el orden temporal de las muestras es desconocido.

2.1.2. Formulación del problema de estimación del orden temporal. Orden circular

En estudios transcriptómicos circadianos se asume que la variación observada en la expresión génica está gobernada por un proceso oscilatorio subyacente de periodo aproximado de 24 horas. Bajo esta hipótesis, el problema de estimación del orden temporal puede formularse como un problema de optimización cuyo objetivo es encontrar el orden de las muestras que mejor reproduzca dicha estructura oscilatoria latente.

Sea $\mathcal{O} = \{\mathbf{o} : \mathbf{o} \text{ es una permutación de } (1, \ldots, n)\}$ el conjunto de todos los órdenes posibles de las n muestras. El problema consiste en determinar el orden óptimo

$$\mathbf{o}^* = \arg\min_{\mathbf{o} \in \mathcal{O}} D(\mathbf{o}; \mathbf{X}),$$

donde $D(\mathbf{o}; \mathbf{X})$ es una función objetivo que evalúa la calidad del orden propuesto. En la práctica, dicha función suele construirse a partir de una medida de discrepancia entre los datos de expresión génica reordenados según $\mathbf{o}$ y el ajuste proporcionado por un modelo para señales oscilatorias. Por ejemplo, es habitual definir $D(\mathbf{o}; \mathbf{X})$ en términos del error cuadrático medio, del coeficiente de determinación o de funciones de verosimili-

tud asociadas al modelo ajustado. La elección concreta de $D(\mathbf{o}; \mathbf{X})$ depende del método de ordenación considerado. En este algoritmo, la estimación del orden circular se realiza mediante un procedimiento inspirado en los principios de *Circular Principal Component Analysis* (CPCA) [36, 37]. Mientras que la metodología original de CPCA propone una representación no lineal basada en redes neuronales, CIRCUST utiliza un enfoque más sencillo basado en el Análisis de Componentes Principales (PCA). Concretamente, a partir de los patrones de expresión conjunta de un conjunto de genes circadianos de referencia (core genes) o genes rítmicos, se obtienen dos componentes principales (eigengenes) que proporcionan una representación bidimensional de las muestras. A partir de sus coordenadas se calcula una posición angular sobre la circunferencia unidad, que se interpreta como una estimación de la fase circadiana relativa de cada muestra y cuya ordenación permite reconstruir el orden temporal circular. Los fundamentos matemáticos de este procedimiento y la construcción de los eigengenes se describen en la Sección A.2 del Anexo.

En lo sucesivo, $\mathbf{o}$ denota un orden circular genérico y $\mathbf{o}^*$ el orden óptimo o finalmente seleccionado.

2.1.2.1. Orden circular

Dado el carácter periódico del fenómeno biológico, la solución óptima no corresponde a un orden lineal, sino a un orden circular $\mathbf{o} = (o_1, o_2, \ldots, o_n)$, que representa la disposición relativa de las muestras a lo largo de un ciclo circadiano de aproximadamente 24 horas.

El orden circular $\mathbf{o}$ induce una permutación de las columnas de la matriz de expresión, $\big(X_{g,(1)}, X_{g,(2)}, \ldots, X_{g,(n)}\big)$, donde $X_{g,(i)}$ denota la expresión del gen g en la muestra situada en la i-ésima posición del orden estimado. De este modo, la reordenación de las columnas de $\mathbf{X}$ aproxima la progresión temporal del ritmo circadiano subyacente. La mayoría de los algoritmos de estimación del orden temporal asignan a cada muestra una fase circadiana, expresada como un ángulo en el intervalo $[0, 2\pi)$, cuya ordenación creciente determina el orden circular de las muestras.

A diferencia de un orden lineal, en un orden circular las muestras situadas al inicio y al final de la secuencia son consecutivas, reflejando la naturaleza periódica del fenómeno biológico. En consecuencia, la estimación del orden circular determina únicamente la posición relativa de las muestras dentro del ciclo, sin fijar un origen temporal.

Nótese que un mismo orden circular admite $2n$ representaciones equivalentes, ya que el recorrido puede iniciarse en cualquiera de las n muestras y realizarse en sentido horario o antihorario.

2.1.3. El algoritmo CIRCUST

CIRCUST [26] aborda el problema de la estimación del orden temporal de las muestras de la matriz de expresión $\mathbf{X}$ mediante un procedimiento iterativo de estimación y

refinamiento del orden circular asociado al proceso oscilatorio subyacente a partir de submatrices de genes circadianos seleccionados. En consecuencia, el problema se formula como la estimación de la posición angular de cada muestra sobre una circunferencia, donde dicha posición representa su fase circadiana relativa.

Para cada tejido, el algoritmo CIRCUST consta de las siguientes etapas. Una descripción detallada de cada una de ellas puede consultarse en Larriba et al. [26].

1. **Preprocesado.** Se eliminan de la matriz de expresión los genes sin identificador y aquellos con recuento nulo en más del 30 % de las muestras. Posteriormente, los niveles de expresión se normalizan gen a gen al intervalo $[-1, 1]$ mediante una normalización *min-max*.

2. **Selección de genes *core*.** Se define un conjunto inicial de genes circadianos de referencia (*core genes*), denotado por $\mathcal{C} \subseteq \{1, \ldots, G\}$, con conocido caracter rítmico en la mayoría de tejidos, utilizado para obtener una primera aproximación del orden temporal. Por defecto, CIRCUST considera los genes *PER1, PER2, PER3, CRY1, CRY2, ARNTL, CLOCK, NR1D1, RORA, DBP, TEF* y *STAT3*. En la Sección A.3 del Anexo se incluye una justificación para la elección de este conjunto de genes.

3. **Estimación del orden circular preliminar.** A partir de la submatriz formada por los genes *core*, la metodología descrita anteriormente basada en CPCA se aplica a esta submatriz obteniéndose el orden circular preliminar,

$$\mathbf{o}^{(0)} = \left(o_1^{(0)}, \ldots, o_n^{(0)}\right).$$

   Este orden proporciona una estimación inicial del orden temporal obtenida al ordenar las muestras según los ángulos de las proyecciones de sus coordenadas en los dos primeros eigengenes sobre la circunferencia unidad. La metodología CPCA junto con los residuos del ajuste FMM se emplea como método de detección de muestras atípicas, descrito en la Sección A.4 del Anexo. En caso de existir muestras outliers, estas se eliminan y se repiten las dos etapas anteriores.

4. **Identificación de genes TOP.** Utilizando el orden preliminar $\mathbf{o}^{(0)}$, se identifican los genes con mayor evidencia rítmica. Para ello, se emplea el modelo no paramétrico para señales oscilatorias ORI como filtro inicial, debido a su elevada eficiencia computacional frente a FMM, seleccionando aquellos genes con $R^2_{\text{ORI}} \geq 0{,}5$. Sobre este subconjunto se ajusta posteriormente el modelo paramétrico FMM, que permite caracterizar los patrones de expresión circadiana mediante parámetros fisiológicamente interpretables.

   A partir de dichos parámetros se retiene una fracción prefijada del total de genes de la matriz, denominada conjunto TOP y denotado por $\mathcal{T} \subseteq \{1, \ldots, G\}$, correspondiente

a aquellos con mayor R^2_{FMM}, perfiles no *spiked* ($\omega > 0{,}1$) y cuyos instantes de máxima expresión (t_U) cubren de forma aproximadamente uniforme la circunferencia unidad. Con independencia de estos criterios, los genes *core* se incorporan siempre al conjunto TOP.

5. **Estimación iterativa de órdenes circulares.** A partir del conjunto de genes TOP se generan K subconjuntos aleatorios, sin reemplazo, de tamaño aproximado 2/3 del total de genes TOP. Para cada subconjunto se construye la correspondiente submatriz de expresión y se aplica nuevamente la metodología basada en CPCA, obteniéndose los órdenes circulares

$$\mathbf{o}^{(1)}, \mathbf{o}^{(2)}, \ldots, \mathbf{o}^{(K)}.$$

   Únicamente serán considerados como factibles aquellas soluciones para las que el orden estimado para las que la distancia angular máxima entre muestras consecutiva no exceda de la calculada en el orden preliminar y sea siempre inferior a π. En otro caso, dicha selección es remplazada por otra mientras no se haya excedido el número de intentos permitidos. Cada uno de estos órdenes se sincroniza posteriormente, determinando su punto de inicio y orientación a partir de la información aportada por los genes *core*, según lo descrito en la Sección A.5 del Anexo.

6. **Estimación robusta de las características circadianas de los genes TOP.** Cada uno de los órdenes circulares $\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}$ induce un ajuste diferente del modelo FMM sobre los perfiles de expresión de los genes TOP. Para cada gen se estiman los parámetros circadianos asociados a cada uno de estos ajustes y, finalmente, se calcula la mediana de las K estimaciones obtenidas para cada parámetro, proporcionando estimadores robustos de las características circadianas de interés.

Nótese que CIRCUST no proporciona una única estimación del orden temporal, sino una colección de órdenes circulares sincronizados obtenidos a partir de diferentes subconjuntos de genes TOP.

$$\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}.$$

Esta estrategia incrementó la robustez del procedimiento frente a la selección inicial de genes *core* y permitió la obtención del primer atlas transcriptómico circadiano humano, proporcionando caracterizaciones estables de los patrones de expresión circadiana.

No obstante, tanto la identificación del conjunto de genes TOP como la posterior caracterización circadiana dependen de la calidad del ajuste del modelo FMM, evaluada mediante medidas descriptivas de bondad de ajuste, como el coeficiente de determinación R^2. Dichas medidas pueden verse afectadas por la presencia de observaciones atípicas, ruido experimental o desviaciones respecto al modelo oscilatorio asumido, distribución

irregular en la estimación temporal obtenida. Este hecho pone de manifiesto el interés de desarrollar procedimientos de estimación más robustos para el modelo FMM, capaces de reducir la influencia de estos factores sobre la caracterización circadiana.

En consecuencia, estas consideraciones motivan el desarrollo de la metodología propuesta en este trabajo, que aborda dos problemas complementarios. El primero es el de la agregación de órdenes circulares, esto es, la obtención de un orden representativo del tejido a partir de la colección $\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}$. El segundo es el de la estimación robusta del modelo FMM, que se afronta mediante la regularización del procedimiento de estimación del modelo FMM. Estos desarrollos metodológicos se presentan en las Secciones 2.2.2 y 2.2.1, respectivamente.

2.1.4. El modelo FMM monocomponente

Los modelos para el análisis de señales oscilatorias, como el modelo FMM en el que se centra este trabajo, requieren que los instantes de observación sean conocidos.

Sea $X_g(t_i)$ la variable aleatoria que representa la expresión del gen g medida en el instante t_i, $i = 1, \ldots, n$, dentro de un ciclo de período conocido, que en este trabajo se asume de 24 horas. Sin pérdida de generalidad, se supondrá que los instantes de observación pertenecen al intervalo $[0, 2\pi)$. En caso contrario, si los tiempos originales pertenecen a un intervalo $[a, b)$, se transforman linealmente mediante $t \to 2\pi \frac{t-a}{b-a}$,. En adelante, y por simplicidad en la notación, se omitirá el subíndice g, escribiendo simplemente $X(t_i)$.

El modelo FMM monocomponente (FMM_1), en el que el subíndice indica el número de componentes oscilatorias y que está diseñado para representar una oscilación simple, se define como

$$X(t) = M + A\cos(\beta + \phi(t; \alpha, \omega)) + \varepsilon(t), \qquad \varepsilon(t) \sim N(0, \sigma^2), \tag{2.1}$$

donde $M \in \mathbb{R}$ es el nivel basal de expresión, $A \geq 0$ es la amplitud de la componente oscilatoria, $\beta \in [0, 2\pi)$ es un parámetro relacionado con la dirección del pico y la asimetría de la curva, $\phi(t; \alpha, \omega)$ es la función de fase de Möbius y σ^2 representa la varianza del término de error. En lo sucesivo, salvo que se indique lo contrario, se escribirá simplemente FMM para referirse a este modelo monocomponente.

La función de fase de Möbius viene dada por

$$\phi(t; \alpha, \omega) = 2\arctan\left(\omega \tan\left(\frac{t-\alpha}{2}\right)\right),$$

donde $\alpha \in [0, 2\pi)$ es el parámetro de localización de fase y $\omega \in (0, 1]$ es un parámetro de apuntamiento o deformación no lineal de la fase. Este último controla la desviación respecto a un perfil cosenoidal. En particular, cuando $\omega = 1$, el modelo se identifica con el modelo Cosinor. A medida que ω disminuye, los perfiles presentan transiciones más loca-

lizadas y formas progresivamente más apuntadas y asimétricas, permitiendo representar una mayor variedad de patrones oscilatorios que una representación armónica clásica. La Sección A.6 del Anexo describe con detalle los parámetros del modelo y su interpretación.

2.1.4.1. Estimación de los parámetros del modelo FMM

La estimación de los parámetros del modelo FMM se realiza mediante máxima verosimilitud. Para ello, el modelo FMM_1 de la ecuación (2.1) se expresa como un modelo de señal más ruido:

$$X(t_i) = M + W(t_i; A, \alpha, \beta, \omega) + \varepsilon(t_i), \qquad \varepsilon(t_i) \overset{\text{iid}}{\sim} N(0, \sigma^2),$$

donde $W(t; A, \alpha, \beta, \omega) = A\cos(\beta + \phi(t; \alpha, \omega))$ representa la componente oscilatoria. Aunque el modelo es no lineal en sus parámetros, admite una reparametrización que permite separar los parámetros lineales de los no lineales. En particular, para cada par de valores (α, ω), se definen las funciones

$$C_{\alpha,\omega}(t_i) = \cos\big(\phi(t_i; \alpha, \omega)\big), \qquad S_{\alpha,\omega}(t_i) = \sin\big(\phi(t_i; \alpha, \omega)\big).$$

Utilizando la identidad trigonométrica del coseno de una suma y definiendo

$$\delta = A\cos(\beta), \qquad \gamma = -A\sin(\beta),$$

el modelo puede reescribirse como

$$X(t_i) = M + \delta C_{\alpha,\omega}(t_i) + \gamma S_{\alpha,\omega}(t_i) + \varepsilon(t_i).$$

Esta representación permite distinguir entre los parámetros lineales (M, δ, γ) y los parámetros no lineales (α, ω). Para valores fijados de estos últimos, la estimación de los parámetros lineales se reduce a un problema de regresión lineal ordinaria. Bajo la hipótesis de normalidad de los errores, la maximización de la verosimilitud respecto a los parámetros de la señal equivale a minimizar la suma de cuadrados residual. La estimación se aborda mediante una estrategia de optimización separable: inicialmente se realiza una búsqueda en rejilla (grid search) sobre los parámetros no lineales (α, ω) y, para cada combinación, se estiman los parámetros lineales por mínimos cuadrados y se evalúa la verosimilitud perfilada. Posteriormente, las estimaciones iniciales de los parámetros no lineales se refinan mediante un algoritmo de optimización local, como Nelder-Mead. Una vez estimados los parámetros, se recuperan la amplitud y el parámetro de fase de la formulación original mediante

$$\widehat{A} = \sqrt{\widehat{\delta}^2 + \widehat{\gamma}^2}, \qquad \widehat{\beta} = \operatorname{atan2}(-\widehat{\gamma}, \widehat{\delta}) \pmod{2\pi}.$$

Esta estrategia de estimación separable constituye la base del algoritmo de backfitting

utilizado en las extensiones multicomponente y multidimensionales del modelo FMM [21, 38], en las que las componentes oscilatorias se estiman iterativamente, actualizando los parámetros de cada una condicionados a las estimaciones de las restantes hasta alcanzar la convergencia.

2.2. Propuesta metodológica

En esta sección se presentan las dos contribuciones metodológicas desarrolladas en este TFG, concebidas como extensiones modulares del algoritmo CIRCUST descrito en la Sección 2.1.3. Ambas propuestas pueden incorporarse de forma independiente al procedimiento original, permitiendo su utilización conjunta o por separado en función del objetivo del análisis.

La primera contribución consiste en incorporar una estrategia de estimación ponderada y regularizada del modelo FMM, desarrollada en el marco de CircaFMM [39], con el objetivo de mejorar la estabilidad del ajuste de los perfiles de expresión génica. Esta estrategia tiene en cuenta la distribución temporal de las muestras y penaliza soluciones excesivamente apuntadas que podrían reflejar fluctuaciones locales de los datos.

La segunda aborda el problema de la obtención de un orden circular representativo a partir de la colección de órdenes circulares generados por CIRCUST durante su proceso iterativo.

En conjunto, estas extensiones pretenden aumentar la robustez y la interpretabilidad del procedimiento, manteniendo la filosofía y la estructura general del algoritmo original.

2.2.1. Regularización del procedimiento de estimación del modelo FMM

Aunque el procedimiento anterior proporciona estimaciones precisas en la mayoría de situaciones, puede resultar inestable cuando el diseño temporal presenta una distribución irregular de los instantes de muestreo o cuando los patrones de expresión están muy localizados. Con el objetivo de mejorar la estabilidad de la estimación de los perfiles oscilatorios, en este trabajo se incorpora a CIRCUST el procedimiento de estimación ponderada y regularizada desarrollado en CircaFMM [39]. Esta metodología no constituye una aportación original del presente trabajo; la contribución consiste en su integración en distintas etapas del algoritmo CIRCUST y en la evaluación de su efecto sobre los resultados.

2.2.1.1. Ponderación temporal del diseño de muestreo

La primera modificación consiste en incorporar ponderaciones dependientes exclusivamente del diseño temporal del experimento. En estudios transcriptómicos circadianos

es habitual que los instantes de observación no cubran uniformemente el ciclo circadiano, concentrándose numerosas muestras en determinados intervalos y existiendo una menor representación en otros. Para compensar esta irregularidad, a cada observación se le asigna un peso inversamente proporcional a la densidad local de muestreo, estimada mediante un estimador kernel de von Mises [40]. Si $\widehat{f}(t_i)$ representa la densidad estimada en el instante t_i, los pesos se definen como

$$\widetilde{w}_i = \frac{1}{\max\{\widehat{f}(t_i), \epsilon_w\}}, \qquad i = 1, \ldots, n,$$

donde $\epsilon_w > 0$ evita la aparición de pesos excesivamente grandes en regiones muy poco muestreadas. Posteriormente, los pesos se normalizan como

$$w_i = n \, \frac{\widetilde{w}_i}{\sum_{j=1}^{n} \widetilde{w}_j}, \qquad i = 1, \ldots, n,$$

de forma que

$$\sum_{i=1}^{n} w_i = n.$$

Con esta construcción, las observaciones situadas en regiones densamente muestreadas reciben menor peso, mientras que aquellas correspondientes a intervalos poco representados adquieren una mayor influencia en el proceso de estimación.

2.2.1.2. Regularización en la estimación FMM

La segunda modificación introducida en CircaFMM tiene como objetivo mejorar la estabilidad de la estimación de los parametros no lineales (α, ω) y reducir el riesgo de sobreajuste. En particular valores pequeños de ω permiten representar oscilaciones con transiciones muy abruptas y perfiles marcadamente asimétricos. Aunque esta flexibilidad constituye una de las ventajas del modelo FMM, también puede favorecer ajustes excesivamente localizados, especialmente cuando la señal es débil o el muestreo temporal es irregular. Para controlar este comportamiento, CircaFMM incorpora un criterio de selección que combina una medida de alineamiento ponderado entre la expresión observada y las funciones base del modelo con una penalización de rugosidad . Para cada par candidato (α, ω), se define:

$$P(\alpha, \omega) = \frac{\langle \widetilde{\mathbf{x}}, \mathbf{C}_{\alpha,\omega} \rangle_w^2 + \langle \widetilde{\mathbf{x}}, \mathbf{S}_{\alpha,\omega} \rangle_w^2}{\langle \mathbf{C}_{\alpha,\omega}, \mathbf{C}_{\alpha,\omega} \rangle_w + \langle \mathbf{S}_{\alpha,\omega}, \mathbf{S}_{\alpha,\omega} \rangle_w},$$

donde $\widetilde{x}_i = x_i - \bar{x}_w$, con $x_i = X(t_i)$ y $\bar{x}_w$ la media ponderada de las observaciones. Asimismo, $\langle \mathbf{a}, \mathbf{b} \rangle_w = \sum_{i=1}^{n} w_i a_i b_i$ denota el producto escalar ponderado, mientras que $\mathbf{C}_{\alpha,\omega}$ y $\mathbf{S}_{\alpha,\omega}$ representan las evaluaciones de las funciones base definidas anteriormente en los instantes de observación. La selección de los parámetros no lineales se realiza maximizando

el criterio regularizado

$$J(\alpha, \omega) = P(\alpha, \omega) - \lambda g(\omega) R(\alpha, \omega),$$

donde $R(\alpha, \omega)$ es un funcional de rugosidad que penaliza las variaciones bruscas de las funciones oscilatorias, $g(\omega)$ modula dicha penalización en función del parámetro de apuntamiento y λ controla su intensidad. La función $g(\omega)$ concentra el efecto de la regularización en valores pequeños de ω, para los que el modelo puede generar perfiles excesivamente apuntados. En cambio, a medida que ω se aproxima a 1 y las oscilaciones se acercan a una forma sinusoidal, la penalización disminuye. El parámetro λ se calibra previamente mediante simulaciones Monte Carlo y se mantiene fijo para todos los genes analizados.

De este modo, la selección de (α, ω) no depende únicamente del alineamiento con los datos observados, sino también de la regularidad de la forma oscilatoria estimada. Esta estrategia permite conservar la flexibilidad del modelo FMM para representar perfiles no sinusoidales, limitando al mismo tiempo la selección de soluciones excesivamente apuntadas que podrían reflejar fluctuaciones locales de la expresión en lugar de una estructura oscilatoria subyacente.

Finalmente, el par $(\widehat{\alpha}, \widehat{\omega})$ que maximiza $J(\alpha, \omega)$ se utiliza para estimar los parámetros lineales mediante mínimos cuadrados ponderados y recuperar los parámetros originales del modelo FMM. Los detalles de la definición del funcional $R(\alpha, \omega)$, la función de modulación $g(\omega)$ y la calibración de λ se presentan en la Sección A.7 del Anexo. Esta metodología, desarrollada en CircaFMM [39], se incorpora a CIRCUST exclusivamente para la estimación de los perfiles oscilatorios de expresión génica, sin utilizar el procedimiento de contraste de ritmicidad propuesto en dicho trabajo.

2.2.2. Elección de un orden circular óptimo

Como se ha descrito en la Sección 2.1.3, el procedimiento iterativo de CIRCUST genera una colección de órdenes circulares $\mathbf{o}^{(1)}, \mathbf{o}^{(2)}, \ldots, \mathbf{o}^{(K)}$, obtenidos a partir de diferentes subconjuntos de genes TOP. Esta estrategia incrementa la robustez del algoritmo frente a la selección de genes, pero plantea un problema adicional: determinar un único orden circular representativo del tejido.

La obtención de un orden circular representativo requiere tener en cuenta las particularidades de este tipo de datos. A diferencia de los órdenes lineales, un mismo orden circular puede representarse mediante distintas secuencias dependiendo de la muestra elegida como punto de partida.

Por tanto, promediar directamente las posiciones de las muestras en los distintos órdenes puede producir resultados inconsistentes, incluso cuando estos representan una misma disposición circular. Esto hace necesario emplear procedimientos de agregación que respeten la estructura circular de las ordenaciones.

Para obtener una ordenación circular representativa del tejido se consideran dos alternativas. La primera selecciona, entre las ordenaciones obtenidas durante las iteraciones de CIRCUST, aquella que mejor satisface un criterio de calidad. La segunda combina la información de las distintas ordenaciones para construir un orden circular de consenso.

2.2.2.1. Selección de la mejor ordenación circular

Como primera alternativa para obtener una ordenación circular representativa del tejido, se propone seleccionar una de las K ordenaciones generadas durante el procedimiento iterativo de CIRCUST. Para ello, se consideran tres criterios: dos basados en la calidad del ajuste del modelo FMM a los genes del conjunto TOP ($\mathcal{T}$), y un tercero basado en el grado de concordancia entre las distintas ordenaciones.

En los dos primeros casos, se utiliza el coeficiente de determinación $R^2_{\text{FMM}}\left(\mathbf{X}_{g\cdot}^{\mathbf{o}^{(k)}}\right)$ del modelo FMM ajustado al perfil del gen g reordenado según $\mathbf{o}^{(k)}$, definido en la Sección A.6.3 del Anexo. El tercer criterio selecciona la ordenación más representativa del conjunto, entendida como aquella que presenta la menor distancia media respecto a las restantes.

- **Selección por la mediana del R^2_{FMM} de los genes TOP**. Se selecciona el orden que maximiza la mediana de los coeficientes de determinación obtenidos sobre los genes del conjunto TOP,

$$\mathbf{o}^* = \arg\max_{\mathbf{o}^{(k)}} \ \text{Me}_{g\in\mathcal{T}}\, R^2_{\text{FMM}}\left(\mathbf{X}_{g\cdot}^{\mathbf{o}^{(k)}}\right).$$

  Este criterio permite comparar las ordenaciones obtenidas a partir de distintas selecciones de genes TOP según su capacidad para representar la estructura oscilatoria del conjunto TOP. Aunque estos genes presentan incialmente un buen ajuste FMM, la calidad de dicho ajuste puede variar entre las ordenaciones. La mediana de los coeficientes de determinación permite así seleccionar aquella que proporciona una representación más consistente de los patrones de expresión del conjunto de genes considerado.

- **Seleccion por la frecuencia de genes TOP con $R^2_{\text{FMM}} \geq \tau$**. Se selecciona el orden que maximiza el número de genes TOP cuyo ajuste mediante el modelo FMM supera un umbral predefinido $\tau > 0$,

$$\mathbf{o}^* = \arg\max_{\mathbf{o}^{(k)}} \sum_{g\in\mathcal{T}} \mathbb{I}\left(R^2_{\text{FMM}}\left(\mathbf{X}_{g\cdot}^{\mathbf{o}^{(k)}}\right) \geq \tau\right),$$

  donde τ representa el umbral de calidad del ajuste y $\mathbb{I}(\cdot)$ es la función indicadora. Este criterio favorece las ordenaciones que permiten representar saatisfactoriamente

un mayor número de perfiles de expresión, sin que los valores especialmente elevados de R^2_{FMM} de algunos genes compensen los ajustes deficientes de otros. El umbral τ es configurable y, por defecto, se establece en 0,5, siguiendo la implementación original de CIRCUST.

Los genes con coeficientes inferiores a este valor no contribuyen al recuento, aunque permanecen en el conjunto TOP. En caso de empate entre varias ordenaciones, se selecciona aquella con mayor mediana de los coeficientes de determinación.

- **Selección por la mínima distancia media entre ordenaciones circulares**. Se selecciona el orden cuya distancia media al resto de las soluciones sea mínima,

$$\mathbf{o}^* = \arg\min_{\mathbf{o}^{(k)}} \frac{1}{K-1} \sum_{\substack{\ell=1 \\ \ell \neq k}}^{K} \frac{1}{n} \sum_{i=1}^{n} d_{\cos}\left(\varphi_{o_i^{(k)}}, \varphi_{o_{j_i}^{(\ell)}}\right),$$

donde $\varphi_{o_i^{(k)}}$ denota la fase circadiana estimada para la muestra que ocupa la posición i de acuerdo a la ordenación $\mathbf{o}^{(k)}$, j_i es la posición que ocupa esa misma muestra en $\mathbf{o}^{(\ell)}$, es decir, $o_{j_i}^{(\ell)} = o_i^{(k)}$, y

$$d_{\cos}(\theta_1, \theta_2) = 1 - \cos(\theta_1 - \theta_2)$$

denota la distancia coseno entre dos valores angulares θ_1 y θ_2.

A diferencia de los criterios anteriores, este procedimiento no considera la calidad del ajuste FMM, sino la concordancia entre las ordenaciones obtenidas. Así, selecciona el medoide del conjunto, es decir, la ordenación más próxima, en promedio, a las restantes, reduciendo la posibilidad de elegir una solución alejada de la mayoría.

2.2.2.2. Construcción de una ordenación circular de consenso

Los tres métodos de consenso que se describen a continuación combinan la información de las K ordenaciones mediante unos pesos $\omega_k \geq 0$, con $\sum_{k=1}^{K} \omega_k = 1$, que recogen las diferencias de variabilidad entre repeticiones. Siguiendo a Barragán et al. [1], se toman $\omega_k = \kappa_k / \sum_{\ell=1}^{K} \kappa_\ell$, donde κ_k es el parámetro de concentración de una distribución de von Mises asociada a la repetición k.

2.2.2.2.1 Agregación mediante el Problema del Viajante (TSP3)

La principal limitación de los criterios anteriores es que restringen la solución final a una de las ordenaciones obtenidas durante las iteraciones de CIRCUST. Una alternativa consiste en construir una nueva ordenación que combine la información contenida en las K soluciones estimadas. Para ello, se emplea el método de agregación propuesto por

Barragán et al. [1], basado en el Problema del Viajante de Comercio (*Traveling Salesman Problem*, TSP).

Cada ordenación $\mathbf{o}^{(k)}$, con $k = 1, \ldots, K$, se representa mediante un grafo dirigido completo cuyos nodos corresponden a las n muestras. A cada arista dirigida (i_1, i_2), con $i_1, i_2 \in \{1, \ldots, n\}$, se le asigna un coste que cuantifica la preferencia por situar la muestra i_2 después de la muestra i_1 en el sentido de rotación del círculo, según la ordenación obtenida en la repetición k. Los costes correspondientes a las K ordenaciones se combinan mediante una media ponderada, obteniéndose un único grafo dirigido que integra la información del conjunto de soluciones.

A partir de este grafo agregado, la obtención del orden de consenso se plantea como un problema TSP. Cada recorrido que visita exactamente una vez las n muestras y regresa al punto de partida, denominado ciclo hamiltoniano, determina una ordenación circular. El objetivo consiste en encontrar el ciclo hamiltoniano que minimiza la suma de los costes de sus aristas. La secuencia de muestras definida por dicho recorrido constituye la ordenación circular de consenso. Nótese que el resultado es un orden de las muestras, es decir, un vector de posiciones, y no un vector de fases.

Existen distintas variantes de este procedimiento, que se diferencian en la definición de los costes de las aristas. En este trabajo se adopta TSP3, que distingue entre los desplazamientos en el sentido de rotación del círculo y los realizados en sentido contrario, penalizando estos últimos con un factor de tres. Esta penalización admite una interpretación geométrica sencilla: si un viajante llega a la muestra i_2 sin haberse detenido previamente en i_1, debe retroceder hasta i_1 y recorrer nuevamente el tramo hasta i_2, acumulando una distancia equivalente a tres veces la separación entre ambas muestras. Los resultados de simulación de Barragán et al. [1] muestran un comportamiento favorable de TSP3, especialmente en términos del criterio MSCE. La Figura 2.1 esquematiza el procedimiento de agregación.

Formulación y solución aproximada del problema TSP3. Siguiendo a Barragán et al. [1], cada una de las K ordenaciones obtenidas mediante CIRCUST se utiliza para calcular los costes de desplazamiento entre las muestras, considerando sus fases circadianas estimadas y el sentido del recorrido sobre el círculo.

Consideremos dos muestras que ocupan las posiciones i_1 e i_2 en la ordenación $\mathbf{o}^{(k)}$, con fases $\varphi_{o_{i_1}^{(k)}}$ y $\varphi_{o_{i_2}^{(k)}}$, respectivamente. La diferencia angular dirigida entre ambas se define como

$$\Delta = \left(\varphi_{o_{i_2}^{(k)}} - \varphi_{o_{i_1}^{(k)}} \right) \text{ mód } 2\pi,$$

donde $\Delta \in [0, 2\pi)$ representa el desplazamiento angular desde la primera muestra hasta la segunda en el sentido de rotación del círculo. En la variante TSP3, el coste de un

desplazamiento angular Δ en dicho sentido se define mediante

$$d_R(\Delta) = \begin{cases} 1 - \cos(\Delta), & 0 \leq \Delta \leq \pi, \\ 3 - \cos(\Delta - \pi), & \pi < \Delta < 2\pi. \end{cases}$$

El coste de desplazarse desde la primera muestra hasta la segunda se obtiene considerando ambos sentidos de recorrido,

$$d_3(\Delta) = \text{mín}\left\{d_R(\Delta),\ 3\, d_R\big((-\Delta) \text{ mód } 2\pi\big)\right\}.$$

El primer término corresponde al recorrido en el sentido de rotación, mientras que el segundo considera el recorrido contrario, penalizado por un factor de tres. De este modo, el coste incorpora tanto la separación angular entre las muestras como la orientación del desplazamiento. En la implementación desarrollada, el factor 3 es el valor por defecto de una penalización configurable $\xi \geq 1$, de modo que el coste general es $d_\xi(\Delta) = \text{mín}\{d_R(\Delta),\ \xi\, d_R((-\Delta) \text{ mód } 2\pi)\}$ y TSP3 corresponde a $\xi = 3$.

Este cálculo se realiza para cada par de muestras en cada una de las K ordenaciones. Los costes correspondientes a un mismo par de muestras se combinan mediante una media ponderada, utilizando los pesos ω_k definidos en la Sección 2.2.2.2. Se obtiene así una matriz agregada $\mathbf{E}$, de dimensión $n \times n$, cuyo elemento

$$E_{i_1 i_2} = \sum_{k=1}^{K} \omega_k\, d_3\big(\Delta_{i_1 i_2}^{(k)}\big)$$

con $\Delta_{i_1 i_2}^{(k)}$ la diferencia angular anterior calculada con las fases que la repetición k asigna a las muestras i_1 e i_2, representa el coste conjunto de desplazarse desde la muestra i_1 hasta la muestra i_2, independientemente de las posiciones que ocupen en cada ordenación.

A partir de esta matriz, el problema TSP consiste en encontrar la ordenación circular que minimiza la suma de los costes de los desplazamientos entre muestras consecutivas. Para una ordenación candidata $\mathbf{o} = (o_1, \ldots, o_n)$, el coste total del recorrido se expresa como

$$L(\mathbf{o}) = \sum_{i=1}^{n-1} E_{o_i, o_{i+1}} + E_{o_n, o_1}.$$

El último término incorpora el regreso desde la última muestra hasta la primera, cerrando el recorrido circular. La solución óptima del TSP viene dada por

$$\widehat{\mathbf{o}}_{\text{TSP}} = \arg\min_{\mathbf{o} \in \mathcal{O}} L(\mathbf{o}),$$

donde $\mathcal{O}$ es el conjunto de permutaciones de las n muestras definido en la Sección 2.1.2. Cada permutación determina un ciclo hamiltoniano, de modo que la minimización permite

identificar el recorrido circular de menor coste agregado.

El problema es NP-difícil, y los autores lo abordan ejecutando varias heurísticas y quedándose con la mejor solución según la función objetivo. La implementación desarrollada sigue esa idea. Los recorridos de partida se obtienen con la heurística del vecino más cercano desde distintos orígenes, y cada uno se refina con movimientos *Or-opt*, que reinsertan un segmento de una a tres muestras consecutivas en otra posición sin invertirlo, ya que en un grafo dirigido invertir un tramo, como hace el 2-opt, cambiaría el coste de todas sus aristas interiores.

Entre los recorridos obtenidos mediante TSP3 se conservan los cinco de menor coste agregado, como en el paquete *isocir* de los propios autores [41], y se selecciona aquel que minimiza el error cuadrático medio circular (*Mean Sum of Circular Errors*, MSCE), propuesto por Barragán et al. [1]. Este criterio cuantifica, mediante regresión isotónica circular [42], la discrepancia entre las fases estimadas en las K repeticiones y las fases ajustadas para respetar un orden circular candidato. Los errores de las distintas repeticiones se combinan mediante una media ponderada con los pesos ω_k, de modo que un menor MSCE indica una mayor concordancia del orden candidato con las estimaciones originales. El criterio también puede utilizarse como medida descriptiva de la concordancia interna de un orden de consenso, pero no evalúa su proximidad al orden verdadero.

El procedimiento de Barragán et al. [1] incluye además una segunda etapa, común a todas sus variantes, en la que una búsqueda local recorre las ternas de muestras consecutivas y comprueba si alguna permutación mejora la función objetivo. No se ha incorporado aquí. Los propios autores señalan que apenas mejora los métodos cuya primera etapa ya da una buena solución, entre ellos TSP3 con el criterio MSCE, y su coste resulta prohibitivo con los tamaños muestrales de los atlas, porque cada pasada evalúa la función objetivo un número de veces proporcional a n y cada evaluación exige un estimador de regresión isotónica circular, de coste cúbico en n.

2.2.2.2.2 Agregación mediante la teoría de Hodge (HOD)

La segunda técnica de agregación también fue propuesta por Barragán et al. [1] y está basada en la teoría de Hodge. Utiliza las relaciones de orden entre ternas de muestras, en lugar de pares. Tres muestras constituyen el conjunto mínimo que permite establecer una orientación circular independiente del origen elegido. Por tanto, este enfoque permite combinar las K ordenaciones obtenidas mediante CIRCUST aunque sus puntos de partida sean diferentes.

Para cada ordenación $\mathbf{o}^{(k)}$, estas relaciones se representan mediante una hipermatriz antisimétrica $\mathbf{\Psi}^{(k)} \in \mathbb{R}^{n\times n\times n}$, cuyos elementos se definen como

$$\psi^{(k)}_{i_1 i_2 i_3} = \operatorname{sign}^{(k)}(i_1, i_2, i_3)\, \lambda^{(k)}_{i_1 i_2 i_3},$$

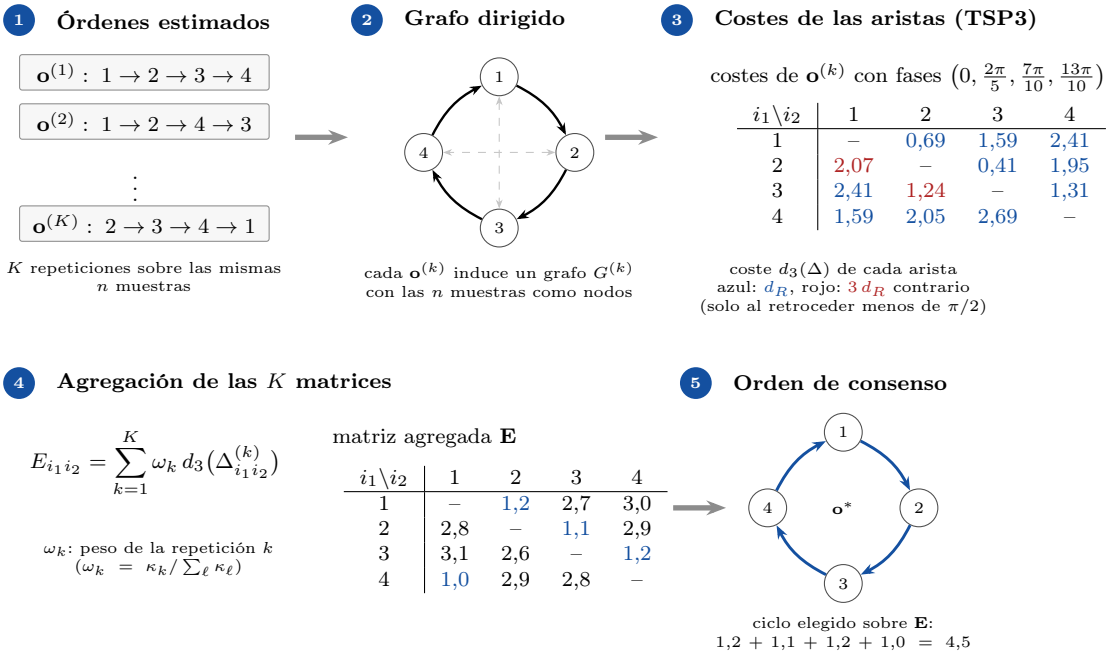


Figura 2.1: Esquema del procedimiento de agregación TSP3.

donde $\text{sign}^{(k)}(i_1, i_2, i_3)$ vale $+1$ o -1 según la orientación circular de las tres muestras y $\lambda^{(k)}_{i_1 i_2 i_3} \geq 0$ representa su grado de separación, definido según la variante del método. Así, las permutaciones cíclicas conservan el valor de ψ, mientras que intercambiar dos muestras cambia su signo. Esta propiedad, denominada *antisimetría*, garantiza que la representación no dependa del origen del recorrido circular.

Las hipermatrices correspondientes a las K ordenaciones se combinan mediante una agregación ponderada, con los pesos ω_k de la Sección 2.2.2.2, siguiendo el procedimiento de Barragán et al. [1]. El resultado es una hipermatriz $\overline{\mathbf{\Psi}}$ que resume las relaciones de orientación entre las ternas a lo largo de todas las ordenaciones. Sin embargo, esta hipermatriz agregada no tiene por qué representar una ordenación circular válida. Por ello, se busca la hipermatriz compatible con un orden circular que sea más próxima a la agregada, resolviendo

$$\widehat{\mathbf{\Psi}} = \underset{\mathbf{\Psi} \in \mathcal{H}_C}{\arg\min} \left\| \overline{\mathbf{\Psi}} - \mathbf{\Psi} \right\|^2,$$

donde $\mathcal{H}_C$ es el conjunto de hipermatrices compatibles con una ordenación circular y la norma representa la suma de las diferencias al cuadrado entre los elementos de ambas hipermatrices.

Una hipermatriz es compatible con un orden circular cuando procede de unas puntuaciones circulares $s_1, \ldots, s_n$. Fijada una muestra l, dicha hipermatriz vale $\psi_{l i_1 i_2} = s_{i_2} - s_{i_1}$ en las ternas que contienen a l y cero en el resto.

La resolución del problema anterior se realiza siguiendo el Teorema 4.1 de Barragán et al. [1], que permite obtener el orden circular de consenso a partir de la hipermatriz agregada. El procedimiento consiste en seleccionar una muestra de referencia, denominada

ancla, y calcular puntuaciones para las restantes muestras. Sea $\mathbf{Y}$ la matriz de elementos $Y_{i_1 i_2} = \frac{1}{n}\sum_{i_3} \bar{\psi}_{i_1 i_2 i_3}$. El ancla es

$$l_0 = \arg\operatorname*{máx}_l \sum_{i_2} Y_{l i_2}^2,$$

y las restantes muestras reciben las puntuaciones

$$s_{i_1} = -\frac{1}{n-1}\sum_{i_2 \neq l_0} Y_{i_1 i_2}, \qquad i_1 \neq l_0.$$

El consenso se obtiene situando el ancla como origen y ordenando las demás muestras de menor a mayor puntuación. Al igual que en TSP3, el resultado es un orden de las muestras y no un vector de fases.

Barragán et al. [1] proponen cuatro variantes del método, HODb, HODr, HODp y HODs, que se diferencian en la definición de $\lambda^{(k)}_{i_1 i_2 i_3}$ y se recogen en la Tabla 2.1. HODb asigna el mismo peso a todas las ternas y HODr utiliza su dispersión angular. Por su parte, HODp y HODs consideran únicamente las ternas que contienen un ancla l, utilizando las diferencias de posición y de fase, respectivamente. En estas dos últimas variantes el ancla debe fijarse antes de construir la hipermatriz, para lo cual los autores proponen una regla análoga a la del teorema, $l_0 = \arg\operatorname{máx}_l \gamma_l$ con $\gamma_l = \sum_{i_2, i_3} \bar{\psi}^2_{l i_2 i_3}$.

Tabla 2.1: Definición de $\lambda^{(k)}_{i_1 i_2 i_3}$ en las variantes del método de Hodge seleccionadas por Barragán et al. [1], con $V = \{1, \ldots, n\}$, $V^{(l)} = V \setminus \{l\}$ e i_1, i_2, i_3 las posiciones de las tres muestras en $\mathbf{o}^{(k)}$, y $R^{(k)}_{i_1 i_2 i_3}$ la longitud resultante media de $\varphi_{o^{(k)}_{i_1}}$, $\varphi_{o^{(k)}_{i_2}}$ y $\varphi_{o^{(k)}_{i_3}}$.

Variante	$\lambda^{(k)}_{i_1 i_2 i_3}$
HODb	1 para todo i_1, i_2, i_3
HODr	$1 - R^{(k)}_{i_1 i_2 i_3}$
HODp	$\begin{cases} 0 & \text{si } i_1, i_2, i_3 \in V^{(l)} \\ \frac{2\pi}{n}\lvert i_2 - i_3\rvert & \text{si } i_2, i_3 \in V^{(l)},\ i_1 = l \end{cases}$
HODs	$\begin{cases} 0 & \text{si } i_1, i_2, i_3 \in V^{(l)} \\ \lvert\varphi_{o^{(k)}_{i_2}} - \varphi_{o^{(k)}_{i_3}}\rvert & \text{si } i_2, i_3 \in V^{(l)},\ i_1 = l \end{cases}$

La implementación desarrollada incluye las cuatro variantes y utiliza HODs por defecto. En esta variante, las fases de cada ordenación se trasladan circularmente para situar el ancla en el origen. Si $a^{(k)}_i$ denota la fase trasladada de la muestra i en la ordenación k, el flujo se reduce a $\psi_{l_0 i_1 i_2} = a_{i_2} - a_{i_1}$, con a_i la media circular ponderada de las $a^{(k)}_i$, y el teorema da $s_i = (a_i - \bar{a})/n$, con $\bar{a}$ la media de las a_i con $i \neq l_0$. La solución puede obtenerse entonces directamente ordenando las fases agregadas, sin necesidad de construir las hipermatrices completas de n^3 elementos. Esto reduce el coste computacional a $O(Kn^2)$ operaciones, manteniendo la equivalencia con la aplicación directa del teorema,

comprobada en la implementación. En HODb y HODr, las $\mathbf{\Psi}^{(k)}$ se agregan mediante la media aritmética ponderada. La Figura 2.2 ilustra el procedimiento de agregación mediante HODs sobre los mismos órdenes de la Figura 2.1.

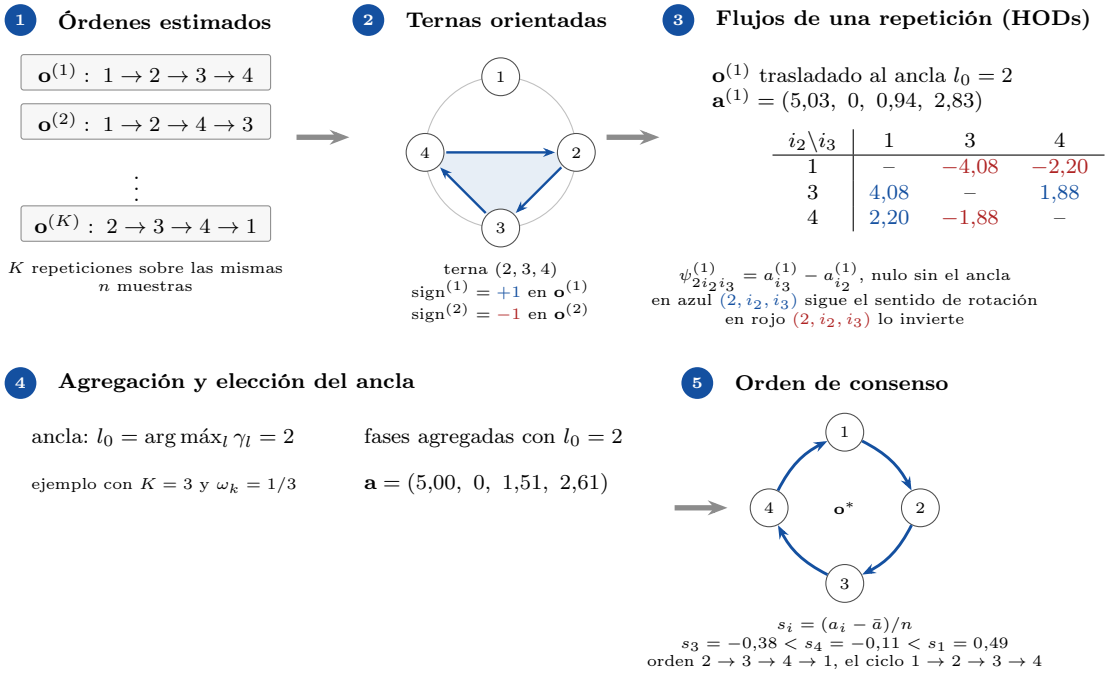


Figura 2.2: Esquema del procedimiento de agregación HOD en su variante HODs.

2.2.2.2.3 Agregación mediante la media circular

A diferencia de TSP3 y HOD, que utilizan relaciones entre muestras independientes del origen de las fases, este método agrega directamente las fases estimadas en las distintas repeticiones. Para ello, las K ordenaciones obtenidas mediante CIRCUST se sincronizan previamente, estableciendo un origen y un sentido de recorrido comunes. A partir de las fases $\varphi_{o_i^{(k)}}$, se calcula para cada muestra su media circular ponderada a lo largo de las K repeticiones, utilizando los pesos ω_k definidos en la Sección 2.2.2.2. El orden circular de consenso se obtiene ordenando las muestras según sus fases medias. De este modo, el procedimiento proporciona tanto una ordenación circular de consenso como una estimación agregada de la fase de cada muestra. Es el método empleado por defecto. Bajo un modelo de von Mises para las fases de cada muestra, la media circular ponderada es su estimador de máxima verosimilitud. En los métodos TSP3 y HOD, en cambio, hay que estimar las fases a partir del orden de consenso, como se describe en la Sección 2.2.2.3.

2.2.2.3. Estimación de las fases asociadas al orden de consenso

Los métodos TSP3 y HOD proporcionan una ordenación circular de consenso de las muestras, pero no determinan sus posiciones angulares. Sin embargo, el posterior ajuste

del modelo FMM requiere disponer de una fase estimada para cada muestra. Para obtenerlas, se utilizan las fases estimadas en las K repeticiones de CIRCUST, previamente sincronizadas, imponiendo que las fases finales respeten el orden de consenso.

Sea $\mathbf{o}^*$ la ordenación circular de consenso obtenida mediante TSP3 o HOD. Las fases finales se estiman mediante regresión isotónica circular (*Circular Isotonic Regression Estimator*, CIRE) [42], que consiste en minimizar la discrepancia circular entre las fases ajustadas y las observadas, bajo la restricción de respetar una ordenación circular determinada. En nuestro caso, el problema se expresa como

$$\boldsymbol{\varphi}^* = \underset{\boldsymbol{\varphi}' \in \Phi(\mathbf{o}^*)}{\arg\min} \sum_{k=1}^{K} \omega_k \sum_{i=1}^{n} \left[1 - \cos\left(\varphi_{o_i^{(k)}} - \varphi'_{o_i^{(k)}}\right)\right],$$

donde $\Phi(\mathbf{o}^*)$ representa el conjunto de vectores de fases compatibles con el orden de consenso, ω_k son los pesos de las repeticiones, definidos en la Sección 2.2.2.2, y $\boldsymbol{\varphi}^*$ es el vector de fases finalmente estimado.

Este ajuste puede realizarse directamente utilizando las fases de las K repeticiones o, de forma equivalente, calculando primero la media circular ponderada de las fases de cada muestra y aplicando CIRE a dichas medias, con pesos iguales a sus longitudes resultantes circulares. La equivalencia se cumple para la discrepancia circular $1 - \cos(\cdot)$.

De este modo, TSP3 y HOD proporcionan el orden circular de consenso, mientras que CIRE permite estimar unas fases compatibles con dicho orden. En el método de agregación mediante la media circular no se requiere este ajuste adicional, ya que el orden se obtiene directamente de las fases medias.

2.2.3. Mejora de CIRCUST: implementación modular y eficiencia

Las dos propuestas metodológicas descritas en las secciones anteriores requieren un soporte computacional sobre el que puedan integrarse. El punto de partida de este trabajo es la implementación original de CIRCUST, desarrollada en R como una colección de *scripts* que no se distribuye como paquete y carece de una estructura que facilite su reutilización por terceros. Dicho código reproduce fielmente el procedimiento descrito en Larriba et al. [26], pero sus etapas no se encuentran aisladas entre sí y los criterios de decisión aparecen fijados en el propio código (*hardcoded*). A ello se añade un coste computacional elevado, dominado por el ajuste del modelo FMM, que se realiza gen a gen y se repite en varias etapas del algoritmo.

Por este motivo, se ha desarrollado una reimplementación completa del algoritmo en Python, que no se limita a traducir el código y responde a tres objetivos complementarios:

- *Eficiencia computacional*, mediante la reorganización de los cálculos, el precálculo, la reutilización y la paralelización de las tareas más costosas.

- *Modularidad*, desacoplando las etapas del algoritmo de forma que puedan ejecutarse de manera independiente, sustituirse por una alternativa o ampliarse sin alterar el flujo de trabajo.
- *Flexibilidad*, explicitando los parámetros de decisión, como los umbrales, de manera que el comportamiento del algoritmo se controle desde la configuración.

Esta sección presenta los módulos desarrollados, tanto los que actualizan las etapas de CIRCUST como los que se incorporan en este trabajo. Cada módulo recibe datos y devuelve datos, sin depender de la estructura interna de los demás, de modo que la salida de uno es la entrada de los siguientes y cualquiera de ellos puede sustituirse, combinarse con otros o reutilizarse por separado. Se describen primero los módulos que implementan las etapas de CIRCUST, después la biblioteca de modelos de ajuste en la que se apoyan y, por último, las decisiones que mejoran la eficiencia computacional.

2.2.3.1. Implementación modular y extensiones de CIRCUST

Siguiendo la notación de Larriba et al. [26], se denota por $[R]$ la matriz de expresión de entrada, sin procesar ni ordenar, por $[N]$ la matriz preprocesada y normalizada, todavía sin ordenar, y por $[X]$ la matriz ordenada según el orden preliminar. A su vez, $[X^{TOP}]$ es la submatriz de los genes TOP de $[X]$, $[X_k^{TOP}]$ esa misma submatriz reordenada según el orden $\mathbf{o}^{(k)}$, $k = 1, \ldots, K$, y $[M^{TOP}]$ la matriz con las características circadianas de los genes TOP. Esta notación entre corchetes designa los objetos concretos que intercambian los módulos y no sustituye a la matriz genérica $\mathbf{X}$ de la Sección 2.1.1. Los siete módulos se encadenan como sigue, con el número del módulo sobre cada flecha:

$$[R] \xrightarrow{1} [\boldsymbol{N}] \xrightarrow{2,3,4} [\boldsymbol{X}] \xrightarrow{5} [\boldsymbol{X^{TOP}}] \xrightarrow{6} [\boldsymbol{X_k^{TOP}}] \xrightarrow{7} [M^{TOP}].$$

De cada módulo se indica la etapa de CIRCUST con la que se corresponde y lo que cambia respecto a ella, y un panel recoge sus entradas, sus hiperparámetros, con los valores por defecto de la implementación, y sus salidas. Cada objeto de datos conserva su color en todos los paneles, de modo que una salida aparece con el mismo color que la entrada de los módulos que la utilizan. Entre paréntesis figura su nombre en el código. Los pasos internos de cada módulo, en los que lo heredado de CIRCUST aparece en negro y las modificaciones o incorporaciones de este trabajo en azul, junto con la justificación de las diferencias respecto al original, se recogen en la Sección A.8 del Anexo.

2.2.3.1.1 Preprocesado

Implementa la Etapa 1 de CIRCUST y añade la carga de ficheros en distintos formatos y el tratamiento de los valores ausentes, los genes duplicados y los genes constantes, que

no admiten ni la descomposición en valores singulares del CPCA ni el ajuste del modelo FMM.

Módulo 1. Preprocesado

Entrada

- $[R]$: matriz de expresión, con los genes en filas y las muestras en columnas.

Hiperparámetros

- `sparse_threshold` = 0,3: umbral η de la fracción de ceros y de valores ausentes por gen.
- `zero_threshold`, `nan_threshold` = `None`: umbrales η_0 y η_{NA} de ceros y de ausentes por separado. Si no se indican, valen η.
- `norm_min` = -1, `norm_max` = 1: intervalo de normalización.

Salida → `PreprocessingResult`

- $[\boldsymbol{N}]$ (`expr_norm`): matriz preprocesada y normalizada en $[-1, 1]$.
- Genes y muestras descartados en cada filtro, genes imputados y número de celdas imputadas.

2.2.3.1.2 Selección de genes *core*

Implementa la Etapa 2 de CIRCUST y convierte la lista fija de genes *core* del código original en un componente configurable, que admite conjuntos predefinidos y listas propias. Las etapas posteriores exigen que el conjunto incluya *ARNTL* y *DBP*.

Módulo 2. Selección de genes *core*

Entrada

- $[\boldsymbol{N}]$ (`expr_norm`).

Hiperparámetros

- `preset` = `circust`: conjunto predefinido, `circust`, `zhang` o `ruben`.
- `custom_genes` = `None`: lista propia de genes *core*. Si se indica, prevalece sobre `preset`.

Salida → `CoreGeneResult`

- $\boldsymbol{\mathcal{C}}$ (`genes`): genes *core* presentes en $[N]$.
- Genes solicitados, genes ausentes de la matriz y nombre del conjunto utilizado.

2.2.3.1.3 CPCA y detección de *outliers*

Implementa la Etapa 3 de CIRCUST hasta la obtención del orden preliminar $\mathbf{o}^{(0)}$, todavía sin sincronizar. La detección de muestras atípicas sustituye los residuos del modelo FMM por los de un *spline* cúbico periódico (Sección A.9 del Anexo), y el criterio radial queda desactivado por defecto. Con CircaFMM, el módulo calibra el parámetro de regularización λ, que heredan los módulos siguientes.

Módulo 3. CPCA y detección de *outliers*

Entrada

- $[\boldsymbol{N}]$ (`expr_norm`).
- $\boldsymbol{\mathcal{C}}$ (`core_genes`).

Hiperparámetros

- `tight_radius` = 0,10, `loose_radius` = 0,15 y `use_radial_criterion` = `False`: umbrales del criterio radial e indicador de su activación.
- `spline_n_knots` = 5, `spline_gene_threshold` = 3,5, `spline_outlier_fraction` = 0,25: nodos m del *spline* periódico, umbral τ_s del residuo estandarizado y fracción ρ de genes *core* que deben superarlo para eliminar una muestra.
- `max_outlier_fraction` = 0,05: fracción máxima de muestras eliminables.
- `fmm_length_alpha_grid` = 48, `fmm_length_omega_grid` = 24, `fmm_num_reps` = 3: rejilla del ajuste FMM, con valores de α equiespaciados y de ω entre 10^{-4} y 1 en escala logarítmica, e iteraciones.
- `fmm_method` = `base`, `circafmm_kwargs` = `None`, `fmm_refine` = `False`: estimador FMM (base o CircaFMM), parámetros de CircaFMM e indicador del refinamiento local.
- `compute_fmm_fits` = `True`: con `False` se omiten la detección de muestras atípicas y el ajuste FMM de los genes *core*.

Salida → `CPCAResult`

- $[\widetilde{\boldsymbol{X}}]$ (`expr_norm_final`): $[N]$ sin las muestras atípicas, renormalizada y ordenada según $\mathbf{o}^{(0)}$.
- $\mathbf{o}^{(0)}$, $\boldsymbol{\varphi}^{(0)}$ (`sample_order`, `circular_scale`): orden preliminar sin sincronizar y fases de las muestras.
- $\widehat{\mathcal{F}}_{\mathcal{C}}$ (`fmm_fits_final`): ajustes FMM de los genes *core* sobre $\boldsymbol{\varphi}^{(0)}$.
- $\boldsymbol{\lambda}^*$ (`lambda_star`): parámetro de regularización calibrado, solo con CircaFMM.
- Muestras eliminadas y varianza explicada por las tres primeras componentes.

2.2.3.1.4 Sincronización del orden circular

Completa la Etapa 3 de CIRCUST fijando el origen y el sentido del orden mediante los genes ancla y de dirección (Sección A.5 del Anexo), y se aplica también a cada uno de los K órdenes del módulo 6. La verificación de la orientación generaliza la cadena fija de tres genes del original a una lista configurable de pares de genes (Sección A.10 del Anexo).

Módulo 4. Sincronización del orden circular

Entrada

- $[\widetilde{\boldsymbol{X}}]$, $\boldsymbol{\varphi}^{(0)}$ y $\widehat{\mathcal{F}}_{\mathcal{C}}$ (`expr_ordered`, `circular_scale`, `fmm_fits`).
- $\mathcal{C}$ (`core_genes`).

Hiperparámetros

- `anchor_gene` = *ARNTL*: gen ancla a, cuyo instante de máxima expresión se sitúa en π.
- `direction_gene` = *DBP*: gen de dirección d, cuyo instante de máxima expresión se espera en $[0, \pi)$ tras la rotación.
- `consistency_pairs` = [(*DBP*, *CRY1*), (*CRY1*, *ARNTL*)]: conjunto $\mathcal{P}$ de pares de genes *core* en los que se sabe a priori que el primero alcanza su máximo antes que el segundo.
- `consistency_r2_min` = 0,5: R^2_{FMM} mínimo que deben alcanzar los dos genes de un par para utilizarlo.

Salida → `SynchronizationResult`

- $[\boldsymbol{X}]$ (`expr_ordered`): matriz ordenada según el orden preliminar sincronizado.
- $\mathbf{o}^{(0)}$, $\boldsymbol{\varphi}^{(0)}$ (`sample_order`, `circular_scale`): orden preliminar sincronizado y fases de las muestras.
- Instantes de máxima expresión, R^2_{FMM} y parámetros FMM de los genes *core* en el nuevo marco, indicador de inversión del sentido y genes *core* diurnos y nocturnos.

2.2.3.1.5 Identificación de genes TOP

Implementa la Etapa 4 de CIRCUST. El cupo de genes TOP se reparte entre sectores de la circunferencia para preservar la cobertura de los instantes de máxima expresión, y el ajuste admite CircaFMM con el parámetro de regularización heredado del módulo 3.

Módulo 5. Identificación de genes TOP

Entrada

- $[\boldsymbol{X}]$ y $\boldsymbol{\varphi}^{(0)}$ (`expr_norm`, `circular_scale`).
- $\boldsymbol{\mathcal{C}}$ (`seed_genes`).
- $\boldsymbol{\lambda}^*$ (`lambda_star`), solo con CircaFMM.

Hiperparámetros

- `r2_ori_threshold` = 0,5, `r2_fmm_threshold` = 0,5, `omega_min` = 0,1: umbrales de los filtros ORI y FMM.
- `n_sectors` = 8: número n_s de sectores en que se divide la circunferencia para la cobertura.
- `top_fraction` = 0,1: fracción f del total de genes de la matriz que fija el cupo del conjunto TOP.
- `fmm_length_alpha_grid` = 48, `fmm_length_omega_grid` = 24, `fmm_num_reps` = 3: rejilla e iteraciones del ajuste FMM.
- `fmm_method` = `base`, `circafmm_kwargs` = `None`, `fmm_refine` = `False`: estimador FMM, parámetros de CircaFMM e indicador del refinamiento local.
- `n_jobs` = −1: número de trabajadores en paralelo con que se ajustan los genes, 1 para un ajuste secuencial y −1 para utilizar todos los núcleos.

Salida → `TopGeneResult`

- $[\boldsymbol{X}^{\boldsymbol{TOP}}]$ (`candidate_matrix`): submatriz de $[X]$ con los genes del conjunto TOP $\mathcal{T}$ (`gene_names`).
- R^2_{ORI}, R^2_{FMM}, ω, instante de máxima expresión y sector de cada gen TOP, genes *core* incorporados por no superar los filtros y número de genes que supera cada filtro.

2.2.3.1.6 Estimación iterativa de órdenes circulares

Implementa la Etapa 5 de CIRCUST. Cada uno de los K órdenes se sincroniza con el módulo 4 y, antes de utilizarlos, se comprueba que todos recorren el ciclo en el mismo sentido que el orden preliminar. Su salida es la colección de órdenes que la versión original entrega sin resumir.

Módulo 6. Estimación iterativa de órdenes circulares

Entrada

- $[\boldsymbol{X}^{TOP}]$ (`top_matrix`).
- $[\boldsymbol{X}]$ y $\boldsymbol{\varphi}^{(0)}$ (`expr_full_norm`, `theta_pre`).
- $\boldsymbol{\mathcal{C}}$ (`core_genes`).
- $\boldsymbol{\lambda}^*$ (`lambda_star`), solo con CircaFMM.

Hiperparámetros

- `n_reps` $= 5$, `sample_size_fraction` $= 2/3$: número K de repeticiones y fracción de genes TOP de cada subconjunto.
- `anchor_gene`, `direction_gene`, `consistency_pairs`: parámetros de la sincronización de cada orden, con los valores del módulo 4.
- `fmm_length_alpha_grid` $= 48$, `fmm_length_omega_grid` $= 24$, `fmm_num_reps` $= 3$: rejilla e iteraciones del ajuste FMM.
- `fmm_method` $=$ `base`, `circafmm_kwargs` $=$ `None`, `fmm_refine` $=$ `False`: estimador FMM, parámetros de CircaFMM e indicador del refinamiento local.
- `recalibrate_lambda_per_rep` $=$ `False`: indicador de la recalibración de λ en cada repetición.
- `seed` $=$ `None`: semilla del sorteo de genes, que hace reproducibles los K órdenes.
- `n_jobs` $= 1$: número de trabajadores en paralelo para el ajuste de los genes TOP.

Salida $\rightarrow$ `RobustRepetitions`

- $\mathbf{o}^{(k)}$, $\boldsymbol{\varphi}^{(k)}$, $\boldsymbol{k = 1, \ldots, K}$ (`sample_orders`, `circ_scales`): órdenes sincronizados y fases de las muestras, que definen las matrices $[X_k^{TOP}]$.
- $\widehat{\boldsymbol{\Theta}}^{(k)}$ (`stats_table`): parámetros FMM $(M, A, \alpha, \beta, \omega)$, instantes de máxima y mínima expresión t_U y t_L y R^2_{FMM} de cada gen TOP en cada $[X_k^{TOP}]$.
- Genes sorteados en cada repetición e indicador de inversión del sentido en su sincronización.

2.2.3.1.7 Orden final y caracterización de los genes TOP

Sustituye a la Etapa 6 de CIRCUST. Resume los K órdenes en un orden final de las muestras, mediante las alternativas de la Sección 2.2.2, y construye $[M^{TOP}]$ sobre ese orden en lugar de tomar las medianas de las K estimaciones. El cálculo del consenso reside en un módulo independiente, `circular_aggregation`, que solo recibe las fases de las K repeticiones y puede reutilizarse para agregar órdenes circulares de cualquier procedencia.

Módulo 7. Orden final y caracterización de los genes TOP

Entrada

- $\mathbf{o}^{(k)}$, $\boldsymbol{\varphi}^{(k)}$ y $\widehat{\boldsymbol{\Theta}}^{(k)}$, $\boldsymbol{k = 1, \ldots, K}$ (`RobustRepetitions`).
- $[\boldsymbol{X}^{TOP}]$ (`top_matrix`), para el reajuste del modelo FMM sobre el orden de consenso.

Hiperparámetros

- `method` $=$ `aggregate`: construir un consenso (`aggregate`) o seleccionar una ordenación (`best_k`).

- `aggregation_method` = `circmean`: método de consenso, media circular (`circmean`), TSP3 (`tsp`) o HOD (`hod`).
- `tsp_alpha` = 3, `hodge_variant` = `s`: penalización ξ del TSP y variante de Hodge, HODs por defecto.
- `selection_criterion` = `r2_median`: criterio de selección, mediana de R^2_{FMM} (`r2_median`), número de genes con $R^2_{\text{FMM}} \geq \tau$ (`n_well_fitted`) o medoide (`medoid`).
- `selection_r2_threshold` = 0,5: umbral τ del criterio `n_well_fitted`.
- `n_jobs` = -1: número de trabajadores en paralelo con que se reajustan los genes TOP.

Salida → `RobustOrderResult` y `build_atlas`

- $\mathbf{o}^*$, $\boldsymbol{\varphi}^*$ (`sample_order`, `circular_scale`): orden final de las muestras y fase de cada una, que no proporciona la versión original.
- $[M^{TOP}]$ (`build_atlas`): para cada gen TOP, R^2_{FMM}, los parámetros $(M, A, \alpha, \beta, \omega)$, t_U, t_L y su clasificación como diurno o nocturno, procedentes de la repetición elegida o del reajuste sobre el orden de consenso.
- Método aplicado, repetición elegida y valor de su criterio, MSCE del consenso y criterios de selección evaluados en cada repetición.

2.2.3.1.8 Modelos de ajuste

Los módulos anteriores se apoyan en una biblioteca de modelos para señales oscilatorias, independiente del algoritmo, que puede utilizarse por separado. Los modelos FMM y ORI comparten una misma interfaz. Reciben el perfil de expresión de un gen y las fases circulares de las muestras, y devuelven un objeto común (`FitResult`) con los valores ajustados, los parámetros estimados, el instante de máxima expresión, el coeficiente de determinación y los residuos. Gracias a esta interfaz, cada módulo puede cambiar de estimador sin modificar su código, como ocurre al elegir entre el modelo FMM y CircaFMM mediante el hiperparámetro `fmm_method`.

2.2.3.2. Eficiencia computacional

El coste de CIRCUST se concentra en el ajuste del modelo FMM, que se realiza gen a gen y se repite en varias etapas. En la Etapa 4 se ajusta a todos los genes que superan el filtro ORI y, en la Etapa 5, a todos los genes TOP en cada una de las K repeticiones. En la implementación original en R, estas dos etapas suponen más del 97 % del tiempo de ejecución. Por ello, las decisiones que se describen a continuación se centran en los módulos 5 a 7 y en la biblioteca de modelos de ajuste, y se agrupan en cuatro estrategias: compilar los núcleos de cálculo, precalcular lo que no depende del gen, paralelizar los ajustes y evitar cálculos innecesarios. La Tabla 2.2 relaciona cada estrategia con los módulos en que se aplica.

2.2.3.2.1 Herramientas de Python

La reimplementación se apoya en el ecosistema científico de Python. NumPy y SciPy realizan las operaciones vectoriales y matriciales sobre las bibliotecas de álgebra lineal BLAS y LAPACK, entre ellas la descomposición en valores singulares del CPCA, los ajustes por mínimos cuadrados y la optimización de Nelder-Mead. Numba compila a código máquina, en el momento de la primera ejecución, los bucles que no admiten una formulación vectorial. Joblib y la biblioteca estándar `concurrent.futures` reparten los ajustes entre los núcleos del procesador, pandas y pyarrow gestionan las matrices de expresión y su lectura desde formatos como Parquet, y scikit-learn proporciona la base del *spline* periódico. El código se distribuye como un paquete instalable, en el que Numba y la aceleración por GPU son dependencias opcionales, de modo que sin ellas el algoritmo produce los mismos resultados con mayor tiempo de ejecución. Una batería de pruebas automáticas permite comprobar, tras cada modificación, que los módulos siguen produciendo los resultados esperados.

2.2.3.2.2 Compilación de los núcleos de cálculo

La búsqueda en rejilla sobre (α, ω) del modelo FMM evalúa la fase de Möbius en cada muestra para cada uno de los 48×24 puntos de la rejilla. Su núcleo compilado aprovecha dos propiedades. La primera es que $\tan\big((t_i - \alpha)/2\big)$ no depende de ω, de modo que se calcula una sola vez por cada valor de α. La segunda es que, por las identidades del ángulo doble, $\cos\phi(t_i; \alpha, \omega)$ y $\sin\phi(t_i; \alpha, \omega)$ se obtienen mediante operaciones aritméticas a partir de $\sin\big((t_i - \alpha)/2\big)$ y $\cos\big((t_i - \alpha)/2\big)$, sin evaluar ninguna función trigonométrica en el bucle sobre ω. Con $n = 455$ muestras, el tiempo de cada búsqueda pasa de 21,4 a 1,14 ms. También se compilan la función objetivo de Nelder-Mead, el algoritmo PAVA y la búsqueda de extremos de ORI, la base trigonométrica y el refinamiento local de CircaFMM y la regresión isotónica circular (CIRE) que utiliza la agregación.

2.2.3.2.3 Precálculo y reutilización

En CircaFMM, la base trigonométrica, sus productos y el funcional de rugosidad $R(\alpha, \omega)$ dependen solo de las fases circulares y de la rejilla, y no del gen. Se calculan una vez por conjunto de datos y se reutilizan para todos los genes, de modo que el criterio $J(\alpha, \omega)$ de un gen se obtiene para toda la rejilla mediante dos productos matriz-vector. Además, la rugosidad no depende de α, por lo que se tabula como función de ω y se interpola durante el refinamiento local. La calibración de λ por Monte Carlo simula todas las réplicas nulas a la vez mediante productos matriciales, y el valor calibrado en el módulo 3 se hereda en las etapas posteriores. Cada calibración cuesta del orden de 27 s, y recalibrar en cada repetición suponía el 99 % del coste adicional de CircaFMM en la Etapa 5. En el modelo FMM, las iteraciones de refinamiento se detienen cuando los parámetros dejan de cambiar entre dos iteraciones consecutivas, con un efecto sobre la suma de cuadrados

residual inferior a 10^{-5} en términos relativos.

2.2.3.2.4 Paralelización

El ajuste de cada gen es independiente del de los demás, por lo que en los módulos 5 a 7 los ajustes se reparten entre trabajadores, cuyo número fija el hiperparámetro `n_jobs`. El tipo de trabajador depende del estimador. Con el modelo FMM se emplean procesos, ya que la optimización de Nelder-Mead se ejecuta en Python y no podría avanzar en paralelo dentro de un mismo proceso. Con CircaFMM se emplean hilos, que comparten en memoria el conjunto precalculado, de unos 23 MB, en lugar de copiarlo a cada proceso, y avanzan en paralelo porque las operaciones de BLAS y de Numba liberan el intérprete. La construcción del atlas sobre el orden de consenso, que se realizaba de forma secuencial, pasa así de 272 a 8,3 s. Cuando el propio estudio de simulación reparte los escenarios entre núcleos, los módulos se ejecutan con `n_jobs` $= 1$ para no anidar dos niveles de paralelismo.

2.2.3.2.5 Supresión de cálculos innecesarios

Algunas mejoras no aceleran un cálculo, sino que lo evitan. En cada repetición, el CPCA del módulo 6 solo proporciona el orden, por lo que se omiten la detección de muestras atípicas y el ajuste FMM de los genes *core* (`compute_fmm_fits` $=$ `False`), como ya hacía el código original. Esto evita en torno al 77 % del coste de cada repetición en la versión previa de la implementación. Del mismo modo, en cada repetición solo se ajusta a los genes TOP el modelo FMM, cuyos parámetros forman el atlas, mientras que el código original ajusta además los modelos Cosinor y ORI a cada gen. Otras decisiones reducen el orden de complejidad. La correlación de Fisher y Lee de la corrección de orientaciones se evalúa mediante sumas simples en $O(n)$ operaciones en lugar de la doble suma sobre pares, de coste $O(n^2)$, lo que con $n = 480$ reduce su tiempo de 11,6 ms a 108 μs. La variante HODs se resuelve en $O(Kn^2)$ operaciones sin construir las hipermatrices de n^3 elementos (Sección 2.2.2.2), y se omite la búsqueda local de Barragán et al. [1], cuyo coste es $O(Kn^4)$ por pasada.

Tabla 2.2: Estrategias de eficiencia computacional aplicadas en cada módulo.

Módulo	Técnicas
Modelos de ajuste	Búsqueda en rejilla del modelo FMM compilada y sin funciones trigonométricas en el bucle sobre ω, objetivo de Nelder-Mead compilado y parada temprana del refinamiento. ORI y CIRE compilados. En CircaFMM, base y rugosidad precalculadas por conjunto de datos, rugosidad tabulada en ω y calibración de λ vectorizada.
3. CPCA y detección de *outliers*	Descomposición en valores singulares sobre LAPACK. Calibración de λ una sola vez por conjunto de datos.
5. Identificación de genes TOP	Ajustes ORI y FMM de los genes repartidos entre trabajadores.
6. Estimación iterativa de órdenes	CPCA sin ajustes FMM ni detección de atípicas, λ heredado, ajuste exclusivo del modelo FMM a los genes TOP, ajustes en paralelo y correlación de Fisher y Lee en $O(n)$.
7. Orden final y caracterización	HODs en $O(Kn^2)$, CIRE compilado, sin búsqueda local y reajuste del atlas en paralelo.

El efecto conjunto se ha medido sobre una matriz de expresión real de 56,200 genes y 479 muestras, con la misma rejilla del modelo FMM y $K = 5$ en ambas implementaciones. La implementación original en R tarda 3050 s. La reimplementación tarda 831 s restringida a un único núcleo, 3,7 veces menos, y 110 s con los 24 hilos del procesador, 27,7 veces menos. Con un único núcleo, la identificación de genes TOP es 2,1 veces más rápida y la estimación iterativa de órdenes 42 veces más rápida, de modo que la ganancia de la primera procede sobre todo de la paralelización y la de la segunda del propio código. El capítulo de simulaciones recoge una comparación de tiempos en distintos escenarios.

Capítulo 3

Simulaciones

(En desarrollo...)Hablar del objetivo y de que debes evaluar varias dimensiones, la computacional, en un marco estandar de tiempos equiespaciados, ruido medio y patrones de onda simétricos y asimétricos en una proporción estandar de 5 % de rítmicos. La parte de la regularización del FMM y el muestreo irregular, aquí ocn varios escenarios de muestreo y de formas de onda, incluyendo simétricas y alguna asimétrica. La parte de la agragación de órdenes

3.0.1. Escenarios de simulaciones

Descripción

3.0.2. Validación

Tendrás que definir alguna medida de evaluación, corcondancia y coherencia de órdenes (el conocido y el estimado) habíamos hablado de correlación, puedes pensar en alguna más del paper de Larriba et al. 2019 cambiando el modelo ORI por el FMM .Estaría bien poder revisar hasta aquí en la siguiente iteración

Capítulo 4

Experimentos con datos reales

Lo último, podemos valorarlo en función de la dedicación que desees, la simulación ya es una gran aportación, aunque ya quedaría redondo con esto

4.0.1. Descripción del conjunto de datos

4.0.2. Resultados

Capítulo 5

Conclusiones y Trabajo Futuro

(En desarrollo...)

PENDIENTE — recuperar aquí las ventajas de CIRCUST.

Indicación de la tutora sobre la Sección 2.1.3: *«la parte de las ventajas es interesante, podemos recuperarlas en las conclusiones o discusión»*. La subsección *Aportaciones de CIRCUST frente a los métodos previos* se eliminó de la Metodología y debe re-escribirse aquí. Sus cinco bloques eran: transparencia e interpretabilidad estadística, descomposición modular del problema, flexibilidad del modelo FMM frente a la rigidez del Cosinor, sincronización explícita con el tiempo biológico y robustez.

El texto original está justo debajo de este aviso, comentado en el `.tex`. Al redactar el capítulo, descomentarlo, adaptarlo y borrar este recuadro.

Bibliografía

[1] Sandra Barragán, Cristina Rueda, and Miguel A. Fernández. Circular order aggregation and its application to cell-cycle genes expressions. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 14(4):819–829, 2017. doi: 10.1109/TCBB.2016.2565469.

[2] Deborah Bell-Pedersen, Vincent M. Cassone, David J. Earnest, Susan S. Golden, Paul E. Hardin, Terry L. Thomas, and Mark J. Zoran. Circadian rhythms from multiple oscillators: lessons from diverse organisms. *Nature Reviews Genetics*, 6(7): 544–556, 2005. doi: 10.1038/nrg1633.

[3] Joseph S. Takahashi. Transcriptional architecture of the mammalian circadian clock. *Nature Reviews Genetics*, 18(3):164–179, 2017. doi: 10.1038/nrg.2016.150.

[4] Franz Halberg. Chronobiology. *Annual Review of Physiology*, 31:675–725, 1969. doi: 10.1146/annurev.ph.31.030169.003331.

[5] Jennifer A. Mohawk, Carla B. Green, and Joseph S. Takahashi. Central and peripheral circadian clocks in mammals. *Annual Review of Neuroscience*, 35:445–462, 2012. doi: 10.1146/annurev-neuro-060909-153128.

[6] Ludovic S. Mure, Hiep D. Le, Giorgia Benegiamo, Max W. Chang, Lorena Rios, Navid Jillani, et al. Diurnal transcriptome atlas of a primate across major neural and peripheral tissues. *Science*, 359(6381):eaao0318, 2018. doi: 10.1126/science.aao0318.

[7] P. Gómez-Abellán, J. A. Madrid, J. M. Ordovás, and M. Garaulet. Aspectos cronobiológicos de la obesidad y el síndrome metabólico. *Endocrinología y Nutrición*, 59 (1):50–61, 2012. doi: 10.1016/j.endonu.2011.08.002.

[8] David C. Klein, Robert Y. Moore, and Steven M. Reppert, editors. *Suprachiasmatic Nucleus: The Mind's Clock*. Oxford University Press, Nueva York, 1991.

[9] Hiroki R. Ueda, Seiwa Hayashi, Wenbin Chen, Mamoru Sano, Masanao Machida, Yasufumi Shigeyoshi, Masamitsu Iino, and Shigeki Hashimoto. System-level identification of transcriptional circuits underlying mammalian circadian clocks. *Nature Genetics*, 37(2):187–192, 2005. doi: 10.1038/ng1504.

[10] Wei Ruan, Xiaoyi Yuan, and Holger K. Eltzschig. Circadian rhythm as a therapeutic target. *Nature Reviews Drug Discovery*, 20(4):287–307, 2021. doi: 10.1038/s41573-020-00109-w.

[11] Ahmed S. BaHammam and Abdulrouf Pirzada. Timing matters: the interplay between early mealtime, circadian rhythms, gene expression, circadian hormones, and metabolism – implications for metabolic disease prevention. *Frontiers in Neuroendocrinology*, 70:101082, 2023. doi: 10.3389/fnins.2023.1287933.

[12] Daniel P. Fudulu, Arnaldo Dimagli, Shubhra Sinha, and Gianni D. Angelini. Circadian variation in outcomes following cardiac surgery. *Journal of Clinical Medicine*, 10(21):4966, 2021. doi: 10.3390/jcm10214966.

[13] O. Marcu et al. Circadian medicine: harnessing biological rhythms for therapeutic benefit. *npj Biological Timing and Sleep*, 1:4, 2024. doi: 10.1038/s44323-024-00005-3.

[14] Louise M. Ince, Coline Barnoud, Yang Gao, Jan Pieter Konsman, and Deepak L. Bhatt. Circadian clocks and the immune response to infection. *The Lancet Microbe*, 4(11):e879–e889, 2023. doi: 10.1016/S2666-5247(23)00145-6.

[15] Gabriele Sulli, Emily N. C. Manoogian, Pam R. Taub, and Satchidananda Panda. Training the circadian clock, clocking the drugs, and drugging the clock to prevent, manage, and treat chronic diseases. *Trends in Pharmacological Sciences*, 39(9), 2018. doi: 10.1016/j.tips.2018.07.003.

[16] Saurabh Sahar and Paolo Sassone-Corsi. Metabolism and cancer: the circadian clock connection. *Nature Reviews Cancer*, 9(12):886–896, December 2009. doi: 10.1038/nrc2747. PMID: 19935677.

[17] Germaine Cornelissen. Cosinor-based rhythmometry. *Theoretical Biology & Medical Modelling*, 11:16, 2014. doi: 10.1186/1742-4682-11-16.

[18] Paul F. Thaben and Pal O. Westermark. Detecting rhythms in time series with RAIN. *Journal of Biological Rhythms*, 29(6):391–400, 2014. doi: 10.1177/0748730414553029.

[19] M. E. Hughes, J. B. Hogenesch, and K. Kornacker. Jtk_cycle: an efficient nonparametric algorithm for detecting rhythmic components in genome-scale data sets. *J Biol Rhythms*, 25(5):372–380, oct 2010. doi: 10.1177/0748730410379711.

[20] Yolanda Larriba, Cristina Rueda, Miguel A. Fernández, and Shyamal D. Peddada. Order restricted inference in chronobiology. *Statistics in Medicine*, 39(3):265–278, 2020. doi: https://doi.org/10.1002/sim.8397. URL `https://onlinelibrary.wiley.com/doi/abs/10.1002/sim.8397`.

[21] Cristina Rueda, Yolanda Larriba, and Shyamal Peddada. Frequency modulated möbius model accurately predicts rhythmic signals in biological and physical sciences. *Scientific Reports*, 9:18701, 2019. doi: 10.1038/s41598-019-54569-1.

[22] Rui Zhang, Nicholas F. Lahens, Heather I. Ballance, Michael E. Hughes, and John B. Hogenesch. A circadian gene expression atlas in mammals: Implications for biology and medicine. *Proceedings of the National Academy of Sciences of the United States of America*, 111(45):16219–16224, 2014. doi: 10.1073/pnas.1408886111.

[23] Kenneth A. Dyar, Dominik Lutter, Anna Artati, Nicholas J. Ceglia, Yu Liu, Danny Armenta, et al. Atlas of circadian metabolism reveals system-wide coordination and communication between clocks. *Cell*, 174(6):1571–1585, 2018. doi: 10.1016/j.cell.2018.08.042.

[24] Marc D. Ruben, Gang Wu, David F. Smith, Robert E. Schmidt, Lauren J. Francey, Yin Yeng Lee, et al. A database of tissue-specific rhythmically expressed human genes has potential applications in circadian medicine. *Science Translational Medicine*, 10 (458):eaat8806, 2018. doi: 10.1126/scitranslmed.aat8806.

[25] Hua Wei and Deepak L. Bhatt. Circadian rhythm in cardiovascular disease. *Nature Reviews Cardiology*, 19:726–727, 2022. doi: 10.1038/s41569-022-00746-9.

[26] Yolanda Larriba, Ian C. Mason, Richa Saxena, Frank A. J. L. Scheer, and Cristina Rueda. CIRCUST: A novel methodology for temporal order reconstruction of molecular rhythms; validation and application towards a daily rhythm gene expression atlas in humans. *PLOS Computational Biology*, 19(9):e1011510, 2023. doi: 10.1371/journal.pcbi.1011510.

[27] Michio Kimura, Kimihiko Murase, Michio Azuma, Yuki Toyama, Kazuhito Aihara, Toshihiro Oga, Kazuo Chin, and Kazuhisa Takahashi. Irregular sampling bias in post-mortem transcriptomic circadian studies. *Chronobiology International*, 40(4): 472–481, 2023. doi: 10.1080/07420528.2023.2178692.

[28] Michael T. Gorczyca and Sara Mostafavi. Characterizing circadian gene expression in the human brain using post-mortem RNA-seq data. *PLOS Computational Biology*, 21(1):e1012685, 2025. doi: 10.1371/journal.pcbi.1012685.

[29] GTEx Consortium. The GTEx consortium atlas of genetic regulatory effects across human tissues. *Science*, 369(6509):1318–1330, 2020. doi: 10.1126/science.aaz1776.

[30] Lorenzo Talamanca et al. Sex-dimorphic and age-dependent organization of 24-hour gene expression rhythms in humans. *Science*, 379(6631):478–483, 2023. doi: 10.1126/science.add0846.

[31] Ron C. Anafi, Lauren J. Francey, John B. Hogenesch, and Junhyong Kim. Cyclops reveals human transcriptional rhythms in health and disease. *Proceedings of the National Academy of Sciences*, 114(20):5312–5317, 2017. doi: 10.1073/pnas.1619320114. URL `https://www.pnas.org/doi/abs/10.1073/pnas.1619320114`.

[32] Jonathan A. Hammarlund. *CYCLOPS 2.0: improving and applying circadian phase reconstruction in confounded datasets*. PhD thesis, Drexel University, Filadelfia, Pensilvania, 2025.

[33] Abas Ansary Ogholbake and Qiang Cheng. PENN: Phase estimation neural network on gene expression data. In *Deep Learning, Big Data and Blockchain (DBB 2023)*, volume 768 of *Lecture Notes in Networks and Systems*, pages 59–67. Springer, 2023. doi: 10.1007/978-3-031-42317-8_5.

[34] A. Ansary Ogholbake and Q. Cheng. Protect: Protein circadian time prediction using unsupervised learning. *iScience*, 28(10):113605, sep 2025. doi: 10.1016/j.isci.2025.113605.

[35] Bharath Ananthasubramaniam and Ramji Venkataramanan. Rhythm profiling using cofe reveals multi-omic circadian rhythms in human cancers in vivo. *PLOS Biology*, 23(5):1–23, 05 2025. doi: 10.1371/journal.pbio.3003196. URL `https://doi.org/10.1371/journal.pbio.3003196`.

[36] Michael J. Kirby and Rick Miranda. Circular nodes in neural networks. *Neural Computation*, 8(2):390–402, 02 1996. ISSN 0899-7667. doi: 10.1162/neco.1996.8.2.390. URL `https://doi.org/10.1162/neco.1996.8.2.390`.

[37] Matthias Scholz. Analysing periodic phenomena by circular PCA. In *Bioinformatics Research and Development (BIRD 2007)*, pages 38–47. Springer, 2007.

[38] Itziar Fernández, Alejandro Rodríguez-Collado, Yolanda Larriba, Adrián Lamela, Christian Canedo, and Cristina Rueda. FMM: An R package for modeling rhythmic patterns in oscillatory systems. *The R Journal*, 2022. URL `https://journal.r-project.org/articles/RJ-2022-015`.

[39] J. S. Abston, Y. Larriba, and I. Fernández. CircaFMM: A flexible statistical framework for circadian rhythmicity detection in transcriptomics. Submitted, 2026.

[40] Kanti V. Mardia and Peter E. Jupp. *Directional Statistics*. Wiley, 2000. TODO: verificar datos exactos de la edición citada.

[41] Sandra Barragán, Miguel A. Fernández, Cristina Rueda, and Shyamal D. Peddada. isocir: An R package for constrained inference using isotonic regression for circular

data, with an application to cell biology. *Journal of Statistical Software*, 54(4):1–17, 2013. doi: 10.18637/jss.v054.i04.

[42] Cristina Rueda, Miguel A. Fernández, and Shyamal D. Peddada. Estimation of parameters subject to order restrictions on a circle with application to estimation of phase angles of cell cycle genes. *Journal of the American Statistical Association*, 104 (485):338–347, 2009. doi: 10.1198/jasa.2009.0120.

[43] Lorenzo Talamanca. *Statistical physics of periodic biological processes*. PhD thesis, EPFL, Lausanne, 2023. URL `https://infoscience.epfl.ch/handle/20.500.14299/194227`.

[44] Gang Wu, Marc D. Ruben, Robert E. Schmidt, Lauren J. Francey, David F. Smith, Ron C. Anafi, et al. Population-level rhythms in human skin with implications for circadian medicine. *Proceedings of the National Academy of Sciences of the United States of America*, 115(48):12313–12318, 2018. doi: 10.1073/pnas.1809442115.

[45] Karolina Lech, Katrin Ackermann, Victoria L. Revell, Oscar Lao, Debra J. Skene, and Manfred Kayser. Dissecting daily and circadian expression rhythms of clock-controlled genes in human blood. *Journal of Biological Rhythms*, 31(1):68–81, 2016. doi: 10.1177/0748730415611761.

[46] Katarzyna Bozek, Angela Relógio, Szymon M. Kielbasa, Markus Heine, Christoph Dame, Achim Kramer, et al. Regulation of clock-controlled genes in mammals. *PLOS ONE*, 4(3):e4882, 2009. doi: 10.1371/journal.pone.0004882.

[47] Nicholas I. Fisher and Alan J. Lee. A correlation coefficient for circular data. *Biometrika*, 70(2):327–332, 1983. doi: 10.1093/biomet/70.2.327.

[48] S. Rao Jammalamadaka and Ashis SenGupta. *Topics in Circular Statistics*. World Scientific, Singapore, 2001. doi: 10.1142/4031.

Anexo A

Material complementario

Listado de acrónimos

A continuación se recoge el significado de los acrónimos y abreviaturas empleados con mayor frecuencia a lo largo de esta memoria. No se incluyen en esta lista los símbolos de los genes citados (PER1, CLOCK, etc.), que siguen la nomenclatura estándar de HGNC.

ARN Ácido ribonucleico, molécula a partir de la cual se mide la expresión génica en los estudios transcriptómicos.

CHIRAL *Circular HIerarchical Reconstruction ALgorithm*: algoritmo probabilístico para la reconstrucción de la fase circadiana, aplicado tejido a tejido e integrado después por donante en estudios multitisulares [30, 43].

CIRCUST *CIRCular-robUST*: algoritmo de reconstrucción del orden temporal circadiano basado en CPCA y en el modelo FMM [26].

CIRE *Circular Isotonic Regression Estimator*: estimador de regresión isotónica circular, que proyecta un vector de ángulos sobre el conjunto de los que verifican un orden circular dado [42].

COFE Método de aprendizaje automático no supervisado que utiliza muestras ómicas para la reconstrucción de ritmos circadianos en cáncer humano [35].

CPCA *Circular Principal Component Analysis* (Análisis de Componentes Principales Circular) [36, 37].

CYCLOPS Algoritmo de reconstrucción de ritmos transcripcionales humanos basado en *autoencoders* circulares [31].

CYCLOPS 2.0
: Extensión de CYCLOPS que permite incorporar covariables durante la estimación del orden temporal [32].

FMM
: *Frequency Modulated Möbius*: familia de modelos paramétricos para el análisis de señales oscilatorias [21].

GTEx
: *Genotype-Tissue Expression*: proyecto que proporciona datos transcriptómicos *post mortem* de múltiples tejidos humanos [29].

HOD
: *Hodge Decomposition*: familia de métodos de agregación de órdenes circulares basados en la teoría de Hodge, que reduce a una matriz los flujos definidos sobre tripletes de elementos. La variante empleada en este trabajo es la de puntuaciones (*score-based*) [1].

HODb, HODr, HODp, HODs
: Variantes del método HOD que se diferencian en la definición del grado de separación de las ternas de muestras. HODb asigna el mismo peso a todas las ternas, HODr utiliza su dispersión angular y HODp y HODs consideran solo las ternas que contienen un ancla, con las diferencias de posición y de fase, respectivamente [1].

JTK_CYCLE
: Algoritmo no paramétrico para la detección de componentes rítmicos en datos de expresión a escala genómica [19].

MSCE
: *Mean Sum of Circular Errors* (error cuadrático medio circular): criterio que mide la concordancia de un orden circular de consenso con las ordenaciones estimadas en las K repeticiones [1]. Se emplea para elegir entre los recorridos candidatos de TSP3, véase la Sección 2.2.2.

NLPCA
: *Nonlinear Principal Component Analysis* (Análisis de Componentes Principales no lineal), generalización del PCA en la que las componentes son curvas en lugar de rectas.

ORI
: *Order Restricted Inference*: modelo no paramétrico de inferencia con restricciones de orden para señales oscilatorias [20].

PCA
: *Principal Component Analysis* (Análisis de Componentes Principales).

PENN
: *Phase Estimation Neural Network*: red neuronal para la estimación de fase a partir de datos de expresión génica [33].

PROTECT
: Método de predicción del tiempo circadiano a partir de datos proteómicos mediante aprendizaje profundo no supervisado [34].

RAIN
: Método estadístico no paramétrico y robusto diseñado para identificar y evaluar ritmos biológicos (con períodos predefinidos) en grandes conjuntos de datos [18].

TFG
: Trabajo de Fin de Grado.

TOD
: *Time of Death* (hora o instante de fallecimiento).

TOP
: Subconjunto de genes seleccionados por su elevada evidencia rítmica tras el filtrado inicial del algoritmo CIRCUST.

TSP
: *Traveling Salesman Problem* (Problema del Viajante de Comercio).

TSP3
: Variante del TSP adoptada en este trabajo para la agregación de órdenes circulares, que penaliza los desplazamientos en sentido contrario a la rotación [1].

A.1. Otros métodos de estimación del orden temporal

Como se señaló en la Sección 1.4, los algoritmos de estimación del orden temporal comparten tres pasos básicos: la definición de un conjunto de genes circadianos de referencia (genes core o semilla), la reducción de la dimensionalidad de la matriz de expresión restringida a dichos genes y la construcción de un espacio latente de naturaleza circular sobre el que se lee la fase de cada muestra. Esta sección describe siguiendo ese esquema los principales métodos alternativos a CIRCUST, esto es, CYCLOPS, CYCLOPS 2.0 y CHIRAL, precedidos en cada caso de las hipótesis biológicas en las que se sustentan.

A.1.1. CYCLOPS

Hipótesis biológicas

CYCLOPS [31] asume que la principal fuente de variación estructurada en el transcriptoma de un tejido es el proceso circadiano subyacente, de modo que los perfiles de expresión de los genes rítmicos describen una curva cerrada al recorrer el ciclo. Supone además que, aunque los tiempos individuales de recogida se desconozcan, una cohorte suficientemente amplia y heterogénea cubre de forma aproximadamente uniforme las 24 horas del día, condición sin la cual dicha curva no queda determinada.

Genes de referencia

El método parte de un conjunto de genes semilla (*seed genes*) formado por los homólogos humanos de genes con expresión rítmica en otras especies. En el trabajo original se emplean los homólogos de genes rítmicos de ratón, seleccionados según el tejido analizado, por lo que no se dispone de una lista fija de genes común a todos los tejidos. Se trata, por tanto, de información externa a los propios datos, que es la que define el subespacio sobre el que se aprende después la estructura circular.

Reducción de dimensionalidad

Sobre la submatriz de genes semilla se aplica un análisis de componentes principales, conservando las primeras componentes o *eigengenes* que explican una fracción prefijada de la variabilidad.

Espacio circular

La estructura circular se aprende mediante un *autoencoder*, una red neuronal entrenada para reproducir en su salida la misma entrada que recibe, obligada a comprimir la información en una capa intermedia de dimensión reducida. La particularidad de CYCLOPS es que dicha capa es un nodo circular, implementado como dos neuronas acopladas (u_i, v_i) que se proyectan sobre la circunferencia unidad, de manera que la fase asignada a la muestra i es un ángulo que se obtiene como $\operatorname{atan2}(v_i, u_i)$. La red se entrena minimizando el error de reconstrucción y, tras varios reinicios aleatorios, se conserva la solución de menor error.

Limitaciones

Cabe destacar tres. En primer lugar, no formula el problema dentro de un marco matemático que relacione la estadística direccional y el círculo con el proceso oscilatorio subyacente, lo que dificulta plantear de forma explícita la estimación del orden temporal y la sincronización del orden estimado. En segundo lugar, depende de información adicional, los genes homólogos de otras especies, de modo que si esta no es de calidad los resultados empeoran, y resulta difícil considerarla en condiciones experimentales patológicas, en las que la expresión de esos genes podría estar alterada. Por último, su rendimiento disminuye en muestras reducidas, lo que limita su aplicabilidad en cohortes pequeñas.

A.1.2. CYCLOPS 2.0

Hipótesis biológicas

CYCLOPS 2.0 [32] mantiene los supuestos de la versión original e incorpora la posibilidad de considerar fuentes de variabilidad no circadiana, como el *batch* experimental y características del donante, entre ellas la edad y el sexo. Para ello, asume que los efectos de estos factores sobre la expresión génica pueden separarse de la señal circadiana sin eliminar la información temporal necesaria para ordenar las muestras.

Pasos metodológicos

Los tres pasos metodológicos coinciden con los de CYCLOPS, incorporando una modificación para considerar fuentes de variabilidad no circadiana. Las covariables se representan mediante una codificación *multi-hot*. Sus efectos se ajustan mediante transformaciones de escala y desplazamiento cuyos parámetros se estiman conjuntamente con los del *autoencoder*. Estas transformaciones se aplican antes de la reducción de dimensionalidad y se invierten tras la reconstrucción, con el objetivo de separar la variabilidad asociada a las covariables de la señal circadiana.

A.1.3. CHIRAL

Hipótesis biológicas

CHIRAL (*Circular HIerarchical Reconstruction ALgorithm*) [30, 43] parte de un supuesto de tipo ergódico que, según sus autores, subyace a todos los métodos de reconstrucción de la fase circadiana. Dicho supuesto establece que el comportamiento del reloj circadiano de un donante a lo largo del tiempo coincide con el comportamiento observado entre donantes muestreados en instantes distintos, lo que permite sustituir el seguimiento temporal de un individuo por una muestra transversal de la población. Un segundo supuesto, específico de los atlas multitisulares como GTEx, establece que la fase de un tejido t en un donante d se descompone en dos términos aditivos, una primera componente que se corresponde con la fase interna propia del donante y un desfase específico del tejido que se asume común a todos los donantes, tomando uno de los tejidos como referencia.

Genes de referencia

El método se restringe a doce genes reloj de referencia, en concreto *DBP*, *PER1*, *PER2*, *PER3*, *TEF*, *NR1D1*, *NR1D2*, *NPAS2*, *ARNTL*, *CRY1*, *CRY2* y *CIART*. Nueve de ellos coinciden con el conjunto *core* que emplea CIRCUST por defecto, del que se diferencia en que CHIRAL incorpora *NR1D2*, *NPAS2* y *CIART* mientras que CIRCUST incluye *CLOCK*, *RORA* y *STAT3*.

Reducción de dimensionalidad

A diferencia de CYCLOPS, CHIRAL no utiliza componentes principales ni *autoencoders* para reducir la dimensionalidad. En su lugar, emplea un modelo probabilístico de regresión armónica de primer orden, en el que la expresión de cada gen se representa mediante un nivel medio y dos coeficientes armónicos, mientras que cada muestra se caracteriza por una fase circadiana latente. El modelo incorpora una mezcla de dos estados, correspondientes a genes rítmicos y no rítmicos, que permite modular la contribución de cada gen a la estimación temporal según la evidencia de ritmicidad.

Espacio circular

Las fases circadianas se consideran variables latentes circulares con una distribución a priori uniforme. Bajo el supuesto de errores gaussianos y distribuciones a priori gaussianas para los coeficientes armónicos, estos últimos se integran analíticamente para obtener la distribución a posteriori de las fases. Su estimación se realiza mediante maximización de dicha distribución, utilizando un procedimiento iterativo basado en el algoritmo de esperanza-maximización (EM). La naturaleza circular de las fases se garantiza imponiendo una restricción de norma unidad sobre su representación bidimensional.

Estructura jerárquica

En su aplicación al atlas multitisular, CHIRAL se ejecuta de forma independiente para cada tejido, obteniéndose una estimación de la fase circadiana de sus muestras. Posteriormente, las fases estimadas para los distintos tejidos de un mismo donante se combinan mediante un procedimiento adicional, independiente del modelo probabilístico. Concretamente, se identifica la región de mayor concentración de fases y se calcula la media circular de aquellas situadas dentro de una ventana de dos horas alrededor de la moda principal. Esta estrategia busca obtener una fase representativa del donante, reduciendo la influencia de tejidos cuyas estimaciones temporales presentan menor concordancia con el resto.

Limitaciones

La estimación de una fase circadiana común por donante requiere disponer de información de varios tejidos de un mismo individuo, lo que limita la aplicación de esta estrategia de integración a estudios multitisulares. Además, los autores señalan una inestabilidad inherente a los algoritmos de ordenación de fases, asociada a la colinealidad de los transcritos del reloj, dado que la mayoría de ellos alcanzan su máximo en la fase de *ARNTL* o en la opuesta, lo que resulta especialmente problemático en tejidos con relojes débiles o confundidos.

A.2. Metodología CPCA

El análisis de componentes principales circular (CPCA) es la técnica de reducción de dimensionalidad sobre la que CIRCUST construye la estimación del orden circular. En este anexo se describe la versión que se emplea en CIRCUST y que se ha implementado en este trabajo basada en los trabajos de Kirby and Miranda [36] y Scholz [37]. Detallando la construcción de los *eigengenes* y la obtención de la escala circular a partir de ellos.

A.2.1. Fundamentos: componentes circulares en PCA no lineal

El PCA clásico representa la variabilidad de los datos mediante direcciones en un espacio euclídeo. Cuando el fenómeno observado es periódico, la nube de puntos describe una trayectoria cerrada y ninguna combinación lineal de las variables puede reproducirla adecuadamente. El PCA no lineal (NLPCA) generaliza las componentes de rectas a curvas mediante una red neuronal autoasociativa o *autoencoder* [37].

A.2.2. CPCA en CIRCUST: construcción de los *eigengenes* y de la escala circular

Basado en los trabajos de Kirby and Miranda [36] y Scholz [37], CIRCUST conserva la restricción circular sobre las coordenadas latentes, y la aplica directamente sobre el plano generado por las dos primeras componentes de la reducción lineal, sin necesidad de ajustar iterativamente la red neuronal. La justificación es doble. Por un lado, la submatriz sobre la que se trabaja está formada por genes seleccionados por su carácter rítmico, cuyos perfiles son aproximadamente oscilatorios y desfasados entre sí, de modo que la trayectoria de las muestras en el plano de las dos primeras componentes ya describe una estructura próxima a una circunferencia. Por otro lado, el coste computacional es determinante, puesto que en cada tejido el procedimiento se ejecuta de forma iterativa. La normalización radial en el círculo unidad posterior proporciona la coordenada angular que determina la posición relativa de la muestra en el orden circular.

Sea $\mathcal{C} \subseteq \{1, \ldots, G\}$ el subconjunto de genes sobre el que se aplica CPCA, con $p = |\mathcal{C}|$, y sea $\mathbf{X}_{\mathcal{C}} \in \mathbb{R}^{p \times n}$ la submatriz de expresión correspondiente, obtenida tras el preprocesado y la normalización descritos en la Sección 2.1.3. El procedimiento consta de las siguientes etapas.

1. *Centrado por genes.* La expresión de cada gen g se centra de acuerdo con su valor promedio, eliminando el nivel basal de expresión de cada gen,

$$\widetilde{X}_{gi} = X_{gi} - \frac{1}{n}\sum_{j=1}^{n} X_{gj}, \qquad g \in \mathcal{C}, \quad i = 1, \ldots, n.$$

2. *Escalado por muestras.* Cada columna se divide por su desviación estándar,

$$s_i = \sqrt{\frac{1}{p-1}\sum_{g\in\mathcal{C}} \widetilde{X}_{gi}^{\,2}}, \qquad Z_{gi} = \frac{\widetilde{X}_{gi}}{s_i}.$$

   De este modo, todas las muestras contribuyen con el mismo peso a la descomposición y la información retenida es el patrón relativo de expresión conjunta de los genes en cada muestra, no su magnitud global.

3. *Descomposición en valores singulares.* Se descompone la matriz escalada $\mathbf{Z}$ como

$$\mathbf{Z} = \mathbf{U}\mathbf{D}\mathbf{V}^{\mathsf{T}}, \qquad \mathbf{D} = \operatorname{diag}(d_1, \ldots, d_r), \quad d_1 \geq \cdots \geq d_r \geq 0,$$

   donde $r = \min(p, n)$. Las columnas de $\mathbf{U} \in \mathbb{R}^{p\times r}$ representan los patrones de contribución de los genes a cada componente, mientras que las columnas $\mathbf{v}_1, \ldots, \mathbf{v}_r \in \mathbb{R}^n$ de $\mathbf{V}$ son los denominados *eigengenes*. Cada *eigengen* $\mathbf{v}_j = (v_{j1}, \ldots, v_{jn})^{\mathsf{T}}$ recoge un patrón de expresión conjunta de los genes de $\mathcal{C}$. En datos con estructura circadiana clara los primeros eigengenes concentran una fracción elevada de dicha variabilidad y presentan perfiles oscilatorios subyacentes.

4. *Proyección sobre la circunferencia unidad.* Cada muestra queda representada por sus coordenadas en el plano de los dos primeros *eigengenes*, (v_{1i}, v_{2i}). Su norma radial es

$$\mathrm{LE}_i = \sqrt{v_{1i}^2 + v_{2i}^2},$$

   y la restricción circular se impone normalizando dichas coordenadas,

$$\left(\frac{v_{1i}}{\mathrm{LE}_i}, \frac{v_{2i}}{\mathrm{LE}_i}\right).$$

5. *Fase circadiana relativa y orden circular.* La posición de cada muestra sobre la circunferencia se resume en el ángulo

$$\varphi_i = \operatorname{atan2}\left(\frac{v_{2i}}{\mathrm{LE}_i}, \frac{v_{1i}}{\mathrm{LE}_i}\right) \bmod 2\pi \in [0, 2\pi),$$

   que constituye la estimación de la fase circadiana relativa de la muestra i. El orden circular $\mathbf{o} = (o_1, \ldots, o_n)$ es la permutación que ordena las muestras según dicha fase,

$$\varphi_{(1)} \leq \varphi_{(2)} \leq \cdots \leq \varphi_{(n)}.$$

   Los subíndices entre paréntesis indican la posición de cada muestra en el orden estimado, y no su índice original. Así, $\varphi_{(i)} = \varphi_{o_i}$ representa la fase de la muestra situada en la posición i de dicho orden, siendo o_i su índice original. El vector de

fases ordenadas

$$\boldsymbol{\varphi}^{\mathbf{o}} = \left(\varphi_{(1)}, \ldots, \varphi_{(n)}\right)$$

define la escala circular asociada al orden.

Este procedimiento se aplica tanto a la submatriz de genes *core*, de la que se obtiene el orden preliminar $\mathbf{o}^{(0)}$, como a cada uno de los K subconjuntos aleatorios de genes TOP, de los que se obtienen los órdenes $\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}$. Sus respectivas escalas circulares se denotan $\boldsymbol{\varphi}^{(0)}$ y $\boldsymbol{\varphi}^{(1)}, \ldots, \boldsymbol{\varphi}^{(K)}$, esto es, $\boldsymbol{\varphi}^{(k)} = \boldsymbol{\varphi}^{\mathbf{o}^{(k)}}$ para $k = 0, 1, \ldots, K$. Nótese, por último, que el orden circular resultante está definido salvo el punto de inicio del ciclo y el sentido del recorrido, lo que da lugar a las $2n$ representaciones equivalentes mencionadas en la Sección 2.1.3.

A.3. Genes Core

El conjunto de genes *core* es el único elemento del algoritmo de CIRCUST que incorpora información biológica previa. Está formada por los doce genes *PER1*, *PER2*, *PER3*, *CRY1*, *CRY2*, *ARNTL*, *CLOCK*, *NR1D1*, *RORA*, *DBP*, *TEF* y *STAT3*. Los once primeros forman parte del reloj molecular descrito en la Introducción, es decir, del bucle de retroalimentación que genera la oscilación circadiana en cada tejido, y su carácter rítmico se ha confirmado de forma consistente en los principales atlas de expresión circadiana disponibles, tanto en mamíferos [22, 6] como en humanos [24, 44]. Mientras que la inclusión de *STAT3* justificada por su comportamiento rítmico diferenciador en tejidos humanos como sangre [45, 46].

Nótese que los instantes de máxima expresión de este conjunto de genes presenta, para la mayoría de tejidos con evidencia biológica circadiana, una distribución equilibrada a lo largo de las 24 horas. De este modo, restringir el análisis CPCA a una submatriz de genes core, se pretende con ellos representar la variación circadiana y evitando así que las primeras componentes queden dominadas por el ruido de fondo de los miles de genes no rítmicos de la matriz completa; o bien infraestimando el periodo de oscilación, en caso de garantizar una distribución equilibrada en instantes de máxima expresión a lo largo del ciclo. Dentro del algoritmo, estos genes intervienen en dos etapas con papeles distintos: en la estimación del orden preliminar actúan como semilla del CPCA, y en la sincronización. En este último caso, se considera un subconjunto de ellos, para los que se conoce sus instantes de máxima expresión y coordinación entre tejidos y se emplean como referencia para fijar el origen de la escala circular y el sentido del recorrido.

A.4. Detección de muestras atípicas

En CIRCUST, la metodología basada en CPCA descrita en la sección anterior desempeña un doble papel. Además de proporcionar la estimación del orden circular, sus salidas se utilizan, junto con los residuos del modelo FMM, para identificar muestras atípicas antes de continuar con el resto del procedimiento [26].

La detección se realiza sobre la submatriz de genes *core* $\mathcal{C}$ y sobre el orden preliminar $\mathbf{o}^{(0)}$, y combina dos criterios que responden a dos tipos distintos de anomalía.

A.4.1. Criterio radial sobre los *eigengenes*

El primer criterio se basa en la geometría de la representación en el plano de los dos primeros *eigengenes*. Si el patrón circadiano de una muestra está bien definido, sus coordenadas (v_{1i}, v_{2i}) se sitúan cerca de la circunferencia y su ángulo φ_i está bien determinado. Por el contrario, las muestras cuya proyección se localiza en un entorno del origen $(0, 0)$ su estimación angular asociada resulta especialmente sensible a perturbaciones en las coordenadas, de modo que pequeñas variaciones pueden producir cambios importantes en la fase asignada. Por tanto, las muestras próximas al origen presentan una menor estabilidad geométrica en la estimación de su posición circular y pueden introducir incertidumbre en la ordenación preliminar.

Formalmente, se emplea la norma radial definida en la sección anterior,

$$\mathrm{LE}_i = \sqrt{v_{1i}^2 + v_{2i}^2}, \qquad i = 1, \ldots, n,$$

y se declaran candidatas a atípicas las muestras que verifican

$$\mathrm{LE}_i < 0{,}1.$$

La implementación de referencia examina a lo sumo el 5 % de las muestras con menos norma radial y, cuando ninguna de ellas alcanza el umbral anterior, aplica un umbral de respaldo más laxo, $\mathrm{LE}_i \leq 0{,}15$. Esta relajación evita descartar situaciones límite en tejidos con ritmicidad circadiana débil, en los que la nube de puntos se concentra en radios pequeños y ninguna muestra supera el criterio estricto.

A.4.2. Criterio basado en los residuos del modelo FMM

El segundo criterio detecta muestras atípicas presentes de forma simultánea en varios genes, como las derivadas de errores de medida del dispositivo o de problemas en el procesado de la muestra, que no tienen por qué manifestarse como una norma radial pequeña. Para ello se ajusta un modelo FMM monocomponente al perfil de cada gen *core*

$g \in \mathcal{C}$, utilizando como instantes de observación la escala circular $\boldsymbol{\varphi}^{(0)}$ inducida por el orden preliminar. A partir de los residuos del ajuste,

$$e_{gi} = X_{g,o_i^{(0)}} - \widehat{X}_{g,o_i^{(0)}}, \qquad g \in \mathcal{C}, \quad i = 1, \ldots, n,$$

se calculan los residuos estandarizados

$$r_{gi} = \frac{e_{gi} - \bar{e}_g}{s_g}, \qquad \bar{e}_g = \frac{1}{n}\sum_{j=1}^{n} e_{gj}, \qquad s_g^2 = \frac{1}{n-1}\sum_{j=1}^{n} (e_{gj} - \bar{e}_g)^2,$$

y se declara candidata a atípica toda muestra que verifique

$$|r_{gi}| > 3 \qquad \text{para algún } g \in \mathcal{C}.$$

La estandarización se realiza gen a gen, de modo que el criterio es comparable entre genes con distinta amplitud de oscilación y distinta calidad de ajuste. Conviene destacar que el uso de los residuos del modelo FMM, podría suponer una limitación en términos de sobreajuste al ser este mismo modelo el empleado por el algoritmo CIRCUST en la estimación de la señal subyacente de los genes. Este modelo podría reemplazarse en este paso por cualquier otro modelo para señales oscilatorias.

A.4.3. Criterio para la detección de *outliers*

Ambos criterios se combinan mediante una regla disyuntiva, es decir, una muestra se declara atípica cuando incumple cualquiera de los dos. El número total de muestras eliminadas está limitado a

$$\lceil 0{,}05\, n \rceil,$$

lo que garantiza que el procedimiento no descarte más de un 5 % de las observaciones disponibles. Esta restricción es necesaria porque los criterios anteriores son puramente descriptivos y, en tejidos con oscilación circadiana poco marcada, podrían descartar una fracción elevada de muestras, situación en la que el problema no es la presencia de observaciones anómalas sino la ausencia de ritmicidad detectable. La implementación original en R refina esta regla distinguiendo entre atípicos multivariantes, que incumplen el criterio de residuos con umbral 3 y además han sido identificados por el criterio radial, y atípicos univariantes, que superan un umbral más exigente, $|r_{gi}| > 4$, en algún gen *core*.

Cuando se detectan muestras atípicas, estas se eliminan de la matriz de expresión, la submatriz de genes *core* se vuelve a normalizar sobre las muestras restantes y se repite el CPCA, obteniéndose el orden preliminar definitivo $\mathbf{o}^{(0)}$ y su escala circular asociada. Si no se detecta ninguna, el orden obtenido en la primera aplicación del CPCA se mantiene sin cambios.

A.5. Sincronización del orden circular

El segundo papel de los genes *core* dentro del algoritmo CIRCUST es la sincronización de los órdenes circulares estimados. Como se ha señalado en la Sección 2.1.3, un orden circular $\mathbf{o}$ y la escala $\boldsymbol{\varphi}^{\mathbf{o}}$ que induce quedan determinados salvo el punto de inicio del recorrido y su sentido, lo que da lugar a $2n$ representaciones equivalentes, correspondientes a las n rotaciones posibles y a los dos sentidos de giro. Mientras esa indeterminación no se resuelva, las fases estimadas solo admiten una lectura relativa y no son comparables entre tejidos ni entre los distintos órdenes $\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}$. La etapa de sincronización fija ambos elementos utilizando exclusivamente información procedente del conjunto $\mathcal{C}$ de genes *core*.

Supuestos biológicos

El procedimiento de sincronización que incorpora CIRCUST se apoya en tres supuestos relativos a la fase de los genes del reloj molecular, documentados de forma consistente en los principales atlas de expresión circadiana [3, 22, 6].

(S1) El instante de máxima expresión de *ARNTL* se sitúa en π. Este supuesto fija el origen de la escala y facilita la comparación entre tejidos. Además, dado que en mamíferos *ARNTL* alcanza su máximo anticipando el inicio del periodo de inactividad, los semicírculos $[0, \pi)$ y $[\pi, 2\pi)$ se interpretan como los periodos inferidos de luz y de oscuridad.

(S2) El instante de máxima expresión de *DBP* guarda una relación de orden conocida con el de los genes de fase ROR, esto es, *ARNTL*, *NPAS* y *CLOCK*.

(S3) La mayor parte de los genes *core* alcanzan su máximo durante el periodo activo $[0, \pi)$.

El primer supuesto determina el punto de inicio del ciclo y los dos últimos el sentido del recorrido.

Procedimiento de sincronización

Sea $\widehat{t}_{U,g}$, con $g \in \mathcal{C}$, el instante de máxima expresión estimado para el gen g a partir de la estimación de los parámetros del modelo FMM en los instantes de tiempo dados por la escala circular $\boldsymbol{\varphi}^{\mathbf{o}}$. Denótese por a el gen ancla, *ARNTL* por defecto, y por d el gen de dirección, *DBP* por defecto.

El supuesto (S1) se impone mediante la rotación

$$\varphi_{o_i} \longmapsto \widetilde{\varphi}_{o_i} = \left(\varphi_{o_i} - \widehat{t}_{U,a} + \pi\right) \text{ mód } 2\pi, \qquad i = 1, \ldots, n,$$

que traslada el máximo del gen ancla a π. Al tratarse de una traslación de los instantes de observación, no es necesario reajustar el modelo FMM, ya que basta con reparametrizar los ajustes disponibles mediante $\alpha \mapsto \left(\alpha - \widehat{t}_{U,a} + \pi\right)$ mód 2π, permaneciendo M, A, β y ω invariantes.

El sentido del recorrido se determina a continuación a partir de la posición del gen de dirección en la escala rotada,

$$\widetilde{t}_{U,d} = \left(\widehat{t}_{U,d} - \widehat{t}_{U,a} + \pi\right) \text{ mód } 2\pi.$$

Anclado *ARNTL* en π, los supuestos (S2) y (S3) sitúan el pico de d en el semicírculo $[0, \pi)$. Por tanto, si $\widetilde{t}_{U,d} < \pi$ la orientación se conserva y, en caso contrario, se invierte. La inversión actúa sobre la escala como la reflexión $\widetilde{\boldsymbol{\varphi}} \mapsto (2\pi - \widetilde{\boldsymbol{\varphi}})$ mód 2π, acompañada de la inversión del orden $\mathbf{o}$, y sobre los parámetros del modelo FMM como

$$(\alpha, \beta) \longmapsto ((2\pi - \alpha) \text{ mód } 2\pi,\ (2\pi - \beta) \text{ mód } 2\pi)\,,$$

dejando de nuevo M, A y ω invariantes.

Dado que un criterio basado en un único gen puede resultar poco fiable cuando su pico estimado se encuentra próximo a la frontera entre ambos semicírculos, se incorpora una fase adicional de verificación. Esta se activa cuando se cumple alguna de las siguientes condiciones:

(I) el máximo de expresión del gen de dirección está próximo a 0 o a π, evaluado mediante la distancia circular $1 - \cos(\cdot)$, es decir, $1 - \cos\left(\widetilde{t}_{U,d}\right) \leq 0{,}1$ o $1 - \cos\left(\widetilde{t}_{U,d} - \pi\right) \leq 0{,}1$,

(II) el número de genes *core* distintos del ancla y del gen de dirección cuyo máximo de expresión $\widetilde{t}_U$ cae en $[0, \pi)$ es inferior a $\lfloor (|\mathcal{C}| - 2)/2 \rfloor$, lo que constituye una violación del supuesto (S3).

En el procedimiento original, la orientación se verifica mediante la relación de fases esperada entre tres genes, $\widehat{t}_{U,d} < \widehat{t}_{U,c} < \widehat{t}_{U,a}$, utilizando *CRY1* como gen de consistencia c por defecto, y se mantiene únicamente si dicha relación se cumple.

En la implementación desarrollada, esta verificación se realiza mediante un conjunto $\mathcal{P}$ de pares ordenados de genes *core* (g_1, g_2), cuya relación de fases se conoce *a priori*. En concreto, se espera que el pico de expresión de g_2 se produzca después del pico de g_1, con una separación angular inferior a π. Por defecto, se consideran los pares $\mathcal{P} = \{(\textit{DBP}, \textit{CRY1}), (\textit{CRY1}, \textit{ARNTL})\}$.

La comprobación utiliza únicamente los pares cuyos dos genes pertenecen al conjunto *core* y presentan un ajuste FMM con $R^2_{\text{FMM}} \geq 0{,}5$. Denotando por $\mathcal{P}^*$ este subconjunto,

se calcula

$$S = \sum_{(g_1,g_2)\in\mathcal{P}^*} \sin\left(\widehat{t}_{U,g_2} - \widehat{t}_{U,g_1}\right).$$

La orientación se invierte si $S < 0$. Si no existen pares utilizables, se mantiene la orientación provisional. Esta comprobación se realiza siempre que $\mathcal{P}^*$ no esté vacío, mientras que las condiciones anteriores se conservan como indicadores diagnósticos.

A.6. Parámetros del modelo FMM e interpretación circadiana

El modelo FMM monocomponente presentado en la Sección 2.1.4 describe el perfil de expresión de un gen a lo largo de un ciclo mediante los cinco parámetros $(M, A, \alpha, \beta, \omega)$. En esta sección se precisa el papel de cada uno de ellos en la forma de la señal, se introducen las características circadianas que se derivan del ajuste y se define la medida de bondad de ajuste utilizada. La Tabla A.1 recoge un resumen de todas estas cantidades.

A.6.1. Parámetros del modelo

La señal esperada del modelo como

$$\mu(t) = M + A\cos(\beta + \phi(t;\alpha,\omega)), \qquad \phi(t;\alpha,\omega) = 2\arctan\left(\omega\tan\left(\frac{t-\alpha}{2}\right)\right),$$

los parámetros se agrupan de forma natural en dos bloques. El par (M, A) fija la escala vertical de la señal y la tupla (α, β, ω) actúa sobre el eje temporal, determinando la posición y la forma de la oscilación.

El parámetro M es el nivel basal alrededor del cual oscila el perfil y A es la amplitud, es decir, la semidiferencia entre los niveles máximo y mínimo alcanzados dentro del ciclo. Conviene tener presente que en CIRCUST la expresión de cada gen se normaliza previamente al intervalo $[-1, 1]$, por lo que M y A resultan comparables entre genes pero no representan niveles absolutos de expresión.

El parámetro α es un parámetro de localización de la fase. Un cambio en α traslada el perfil a lo largo del ciclo sin alterar su forma. Los parámetros β y ω describen la forma de la señal. Para ello debe considerarse que la transformación de Möbius recorre la circunferencia a velocidad no constante cuando $\omega < 1$, pues

$$\phi'(t;\alpha,\omega) = \frac{\omega}{1 - (1-\omega^2)\sin^2\left(\frac{t-\alpha}{2}\right)},$$

expresión que toma el valor ω en $t = \alpha$ y el valor $1/\omega$ en $t = \alpha + \pi$. Así, cuanto menor es ω se obtienen perfiles más apuntados y asimétricos, con una fase de subida y otra de bajada

de duraciones distintas. El parámetro β determina cuál de los dos extremos, el máximo o el mínimo, es el que aparece apuntado, así como el sentido de la asimetría. En el caso límite $\omega = 1$ la fase avanza uniformemente, $\phi(t; \alpha, 1) = t - \alpha$, y el modelo se reduce al Cosinor [17],

$$\mu(t) = M + A\cos(t - \alpha + \beta)\,,$$

cuyo máximo se alcanza en $t = \alpha - \beta$, cantidad directamente relacionada con la acrofase clásica de este modelo. El modelo FMM contiene por tanto al Cosinor como caso particular y añade, mediante ω y β, la capacidad de representar los perfiles no sinusoidales que son habituales en expresión génica circadiana, en los que la subida hacia el máximo suele ser más rápida que el descenso posterior.

A.6.2. Parámetros FMM

En las aplicaciones cronobiológicas son de especial interés los instantes de máxima y mínima expresión parámetros que podemos derivar del modelo FMM, denotados por t_U y t_L, que en el modelo FMM admiten expresión cerrada [21],

$$t_U = \alpha + 2\arctan\left(\frac{1}{\omega}\tan\left(\frac{-\beta}{2}\right)\right), \qquad t_L = \alpha + 2\arctan\left(\frac{1}{\omega}\tan\left(\frac{\pi-\beta}{2}\right)\right),$$

Así mismo los niveles de expresión alcanzados en ellos se obtienen como

$$Z_U = M + A, \qquad Z_L = M - A.$$

Nótese que t_U coincide con α únicamente cuando $\beta = 0$, es decir, el parámetro de localización no es en general el instante del pico, lo que hace necesario el cálculo anterior.

El instante de máxima expresión t_U es la característica de mayor relevancia biológica, ya que indica el momento del ciclo en el que la transcripción del gen alcanza su nivel más alto. Es la cantidad que permite comparar estos instantes de un mismo gen entre tejidos, ordenar temporalmente los procesos fisiológicos que regulan y verificar relaciones conocidas del reloj molecular, como la oposición de fase entre *ARNTL* y los genes *PER* o *NR1D1* descrita en la Introducción. Dado que en este trabajo el ciclo se identifica con el intervalo $[0, 2\pi)$, la conversión a la escala horaria de un periodo de 24 horas es inmediata,

$$t_{\text{horas}} = \frac{24}{2\pi}\, t_U.$$

Debe subrayarse, que solo tras la etapa de sincronización, que fija el origen y el sentido de recorrido de la escala a partir de los genes *core*, dichos instantes resultan interpretables en términos de hora del día y comparables entre tejidos.

Cantidad	Rango	Interpretación
M	$\mathbb{R}$	Nivel basal de expresión
A	$[0, \infty)$	Amplitud de la oscilación
α	$[0, 2\pi)$	Localización de la fase
β	$[0, 2\pi)$	Dirección del pico y asimetría
ω	$(0, 1]$	Apuntamiento del perfil
t_U, t_L	$[0, 2\pi)$	Instantes de máxima y mínima expresión
Z_U, Z_L	$\mathbb{R}$	Niveles de máxima y mínima expresión
R^2_{FMM}	$[0, 1]$	Proporción de variabilidad explicada

Tabla A.1: Parámetros del modelo FMM monocomponente y características circadianas derivadas del ajuste.

A.6.3. Medida de bondad de ajuste

La evidencia de ritmicidad de un gen se cuantifica mediante una medida descriptiva de tipo R^2. Para un gen g con perfil observado $\mathbf{X}_{g\cdot} = (X_g(t_1), \ldots, X_g(t_n))$ y ajuste $\widehat{X}_g(t_i)$ obtenido con el modelo FMM, se define

$$R^2_{\text{FMM}}(\mathbf{X}_{g\cdot}) = 1 - \frac{\sum_{i=1}^{n} \left(X_g(t_i) - \widehat{X}_g(t_i)\right)^2}{\sum_{i=1}^{n} \left(X_g(t_i) - \bar{X}_g\right)^2}, \qquad \bar{X}_g = \frac{1}{n}\sum_{i=1}^{n} X_g(t_i),$$

de modo que R^2_{FMM} cuantifica la proporción de variabilidad de la expresión del gen, medida respecto a su valor medio observado, que es explicada por el modelo FMM ajustado. El coeficiente R^2_{ORI} empleado como filtro previo se define de forma análoga, sustituyendo el ajuste FMM por el ajuste no paramétrico del modelo ORI.

La elección de una medida descriptiva en lugar de un contraste de hipótesis con su correspondiente p-valor es deliberada [26].

A.6.4. Criterios para la identificación de genes TOP

En la Sección 2.1.3 el conjunto de genes TOP se define a partir de tres criterios: un valor elevado de R^2_{FMM}, perfiles no *spiked*, esto es, con $\omega > 0{,}1$, y una distribución de los instantes de máxima expresión t_U aproximadamente uniforme sobre la circunferencia. A continuación se detalla y se justifica cada uno de ellos.

El primer criterio, basado en un valor elevado de R^2_{FMM}, permite identificar genes cuya variabilidad de expresión entre muestras queda explicada en gran medida por el perfil oscilatorio estimado mediante el modelo FMM. Estos genes presentan una estructura de expresión compatible con la organización circadiana y constituyen candidatos para aportar información sobre la posición relativa de las muestras a lo largo del ciclo.

El segundo, excluye los perfiles *spiked* mediante la condición $\omega > 0{,}1$, como candidatos a genes TOP, evitando de este modo incluir genes con transiciones muy localizadas

donde su variación se concentra en un entorno muy reducido del ciclo. En datos transcriptómicos *post mortem* estos perfiles responden con frecuencia a un conjunto reducido de observaciones extremas que podría representar tanto caracterizaciones oscilatorias, si bien no representativas como comportamientos atípicos. Y su estimación es además inestable, en la implementación del modelo FMM considerada en CIRCUST, llevando en casos extremos $\omega \approx 0$ a estimaciones degeneradas de la señal subyacente. Esta inestabilidad del ajuste para valores pequeños de ω es la que motiva la propuesta de regularización descrita en la Sección 2.2.1.

El tercero de los criterios, requiere de una cobertura aproximadamente uniforme de la circunferencia por los instantes de máxima expresión de los genes TOP, garantizando así que el conjunto TOP contenga genes que alcanzan su máximo en momentos distintos del ciclo. Si todos los genes seleccionados presentaran instantes de máxima expresión muy agrupados o distribuidos únicamente en la mitad de la circunferencia la representación en el plano de los dos primeros *eigengenes* perdería la estructura circular lo que no permitiría reconstruir adecuadamente su posición relativa a lo largo del ciclo circadiano.

En concreto CIRCUST divide la circunferencia en ocho sectores circulares idénticos tomando como origen la mediana circular de los máximos instantes de expresión estimados mediante el modelo Cosinor por R^2_{ORI} conservandose únicamente los genes de mayor R^2_{FMM} hasta alcanzar un umbral máximo de genes por sector. Este reparto por regiones es lo que produce, de forma indirecta, una cobertura razonable del ciclo. No obstante, si una región no contiene ningún gen candidato, el procedimiento simplemente la omite, de manera que la ausencia de cobertura en alguna zona del ciclo no se detecta ni se corrige.

En la implementación desarrollada en este trabajo la circunferencia se divide en un número por defecto de ocho sectores, y con un mínimo de cuatro para garantizar que se cubran al menos los cuatro cuadrantes exigidos en CIRCUST. El origen es la mediana circular de los puntos de máxima expresión $\widehat{t_U}$ estimados con el modelo FMM. Cuando un sector no contiene ningún gen que supere los filtros, la situación se notifica de forma expresa, pero no se fuerza la inclusión de ningún gen. La fracción prefijada de genes se reparte después a partes iguales entre los sectores no vacíos y se ordena por R^2_{FMM} dentro de cada uno. Las plazas que un sector no llega a cubrir por tener menos genes que su cupo se redistribuyen entre los sectores que aún tienen candidatos.

Por último, estas mismas cantidades son las que caracterizan a cada gen TOP al término del procedimiento. Para cada uno de ellos se dispone de K ajustes, uno por cada orden circular $\mathbf{o}^{(1)}, \ldots, \mathbf{o}^{(K)}$. CIRCUST resume esa colección calculando la mediana de las K estimaciones de cada parámetro, tal y como se ha descrito en la Sección 2.1.3.

En la implementación desarrollada en este trabajo la caracterización final es, en cambio, la inducida por el orden definitivo del tejido, y difiere según el modo en que este se haya obtenido. Cuando el orden procede de uno de los criterios de selección de la Sección 2.2.2, los parámetros son los del ajuste correspondiente a la repetición elegida.

Cuando procede de un procedimiento de agregación, el modelo FMM se reajusta sobre la escala circular asociada al orden de consenso. La razón de no promediar sobre las K repeticiones es que la mediana mezclaría ajustes calculados sobre escalas circulares distintas, entre ellas las de los órdenes que el propio criterio acaba de descartar por ser peores, y proporcionaría unos parámetros que no se corresponden con el orden que finalmente se reporta.

A.7. Regularización de la estimación del modelo FMM

Esta sección recoge los detalles del procedimiento de estimación del modelo FMM propuesto en CircaFMM [39] y presentado en la Sección 2.2.1.

A.7.1. Riesgo de sobreajuste para valores pequeños de ω

El parámetro ω controla la deformación de la fase en el modelo FMM. Cuando toma valores próximos a cero, la función de fase de Möbius presenta variaciones muy rápidas en un intervalo reducido del ciclo, dando lugar a perfiles oscilatorios con transiciones abruptas. Este comportamiento puede observarse a partir de su derivada:

$$\phi'(t;\alpha,\omega) = \frac{\omega}{\cos^2\left(\frac{t-\alpha}{2}\right) + \omega^2 \sin^2\left(\frac{t-\alpha}{2}\right)}.$$

En particular, su valor máximo es $1/\omega$, alcanzado en $t = \alpha + \pi$ módulo 2π, por lo que aumenta conforme ω se aproxima a cero.

Aunque esta flexibilidad permite representar perfiles de expresión no sinusoidales, también puede favorecer el sobreajuste cuando la señal es débil, el tamaño muestral es limitado o existen observaciones aisladas con gran influencia. En estas circunstancias, la minimización de la suma de cuadrados residual puede favorecer soluciones con valores excesivamente pequeños de ω, que ajustan fluctuaciones locales de los datos en lugar de reflejar una estructura oscilatoria global.

Para reducir este riesgo, CircaFMM introduce un criterio de alineamiento ponderado entre el perfil observado y las funciones base del modelo, combinado con una penalización de rugosidad que limita la selección de perfiles excesivamente apuntados.

A.7.2. Funcional de rugosidad $R(\alpha,\omega)$

El funcional $R(\alpha,\omega)$ penaliza la curvatura de las funciones base $C_{\alpha,\omega}$ y $S_{\alpha,\omega}$, con el objetivo de evitar la selección de perfiles excesivamente apuntados. Sean $t_1 \le \cdots \le t_n$ los instantes de observación ordenados sobre la circunferencia y sean los incrementos circulares

$$\Delta t_i = t_{i+1} - t_i, \quad i = 1,\dots,n-1, \qquad \Delta t_n = t_1 + 2\pi - t_n.$$

Para un par (α, ω) fijo se denotan $C_i = C_{\alpha,\omega}(t_i)$ y $S_i = S_{\alpha,\omega}(t_i)$, tal que $C_{n+1} = C_1$ y $S_{n+1} = S_1$. A partir de las primeras diferencias $\Delta C_i = C_{i+1} - C_i$ y $\Delta S_i = S_{i+1} - S_i$ se definen las pendientes locales

$$\mathrm{pend}_i^C = \frac{\Delta C_i}{\Delta t_i}, \qquad \mathrm{pend}_i^S = \frac{\Delta S_i}{\Delta t_i},$$

y las variaciones de pendiente, de nuevo con indexación circular,

$$\Delta\mathrm{pend}_i^C = \mathrm{pend}_{i+1}^C - \mathrm{pend}_i^C, \qquad \Delta\mathrm{pend}_i^S = \mathrm{pend}_{i+1}^S - \mathrm{pend}_i^S.$$

El funcional de rugosidad calculado sobre los instantes observados es entonces

$$R_{\mathrm{obs}}(\alpha, \omega) = \sum_{i=1}^{n} \left(\Delta\mathrm{pend}_i^C\right)^2 + \sum_{i=1}^{n} \left(\Delta\mathrm{pend}_i^S\right)^2.$$

Cuando los instantes de observación están distribuidos de forma irregular, el cálculo de la rugosidad puede verse afectado por la presencia de intervalos sin observaciones o de tiempos muy próximos entre sí. En el primer caso, pueden quedar sin detectar transiciones abruptas de la fase; en el segundo, las pendientes calculadas mediante diferencias finitas pueden resultar inestables. Para evitar esta dependencia del diseño temporal, la rugosidad se evalúa sobre una rejilla densa y equiespaciada de n_d puntos en $[0, 2\pi)$, definida por

$$T_d = \{u_j\}_{j=1}^{n_d}, \qquad u_j = \frac{2\pi(j-1)}{n_d}, \quad j = 1, \ldots, n_d.$$

Sobre esta rejilla se calculan las diferencias finitas circulares de las funciones base $C_{\alpha,\omega}$ y $S_{\alpha,\omega}$, obteniéndose $R_{\mathrm{dense}}(\alpha, \omega)$. Se utiliza $n_d = 512$, de modo que la medida depende únicamente de (α, ω) y puede calcularse previamente para toda la rejilla de búsqueda. En adelante, se denota por $R(\alpha, \omega)$ esta medida de rugosidad.

La construcción sobre los instantes observados se ha presentado porque es la definición natural de la medida y porque sus limitaciones son las que motivan la elección, pero no se emplea en este trabajo. La razón es que ambas situaciones descritas arriba concurren en CIRCUST, donde los instantes de observación no proceden de un diseño experimental regular sino de la escala circular inducida por el CPCA, y son por tanto irregulares por construcción. Es también la elección que realizan los autores del método cuando lo aplican a un conjunto de datos cuyos tiempos han sido igualmente inferidos a partir de un orden estimado.

A.7.3. Modulación de la penalización

Para concentrar la regularización en los valores pequeños de ω, asociados a perfiles potencialmente localizados o abruptos, se introduce la función

$$g(\omega) = \left(\frac{\omega_0}{\omega + \omega_0}\right)^p, \qquad \omega_0 \in (0,1), \quad p \geq 1,$$

donde ω_0 controla la escala de transición y p determina la rapidez con la que disminuye la penalización. En CircaFMM se utilizan los valores $\omega_0 = 0{,}1$ y $p = 3$.

De este modo, la penalización tiene mayor influencia para valores pequeños de ω y disminuye conforme el perfil se aproxima a una forma sinusoidal. El criterio de selección de los parámetros no lineales es, por tanto,

$$J(\alpha, \omega) = P(\alpha, \omega) - \lambda\, g(\omega)\, R(\alpha, \omega).$$

A.7.4. Calibración del parámetro de regularización λ

El parámetro $\lambda \geq 0$ controla la intensidad de la penalización y se calibra mediante Monte Carlo de acuerdo con lo descrito en CircaFMM [39]. El objetivo es seleccionar un valor que reduzca el riesgo de obtener perfiles excesivamente apuntados, sin limitar innecesariamente la flexibilidad del modelo FMM.

Para ello, se generan perfiles sin estructura oscilatoria, simulados como ruido gaussiano sobre los instantes de observación y utilizando los mismos pesos que en el ajuste original. Se define una rejilla de valores candidatos de λ y, para cada uno, se ajusta el modelo FMM a los perfiles simulados. El grado de apuntamiento de cada curva ajustada se cuantifica mediante la máxima diferencia absoluta entre los valores predichos en dos instantes consecutivos, considerando también la continuidad circular entre el último y el primero. Este indicador permite identificar ajustes con transiciones abruptas que pueden aparecer al adaptar el modelo a fluctuaciones aleatorias de los datos.

Para cada valor de λ, se calcula el cuantil de orden 0,975 de los saltos máximos obtenidos en las simulaciones. A partir de la evolución de este cuantil en función de λ, se selecciona el valor λ^* mediante un criterio de codo, identificando el punto a partir del cual un aumento de la penalización produce reducciones comparativamente menores en el grado de apuntamiento de los ajustes.

De este modo, se obtiene un único valor de λ para cada conjunto de datos, determinado a partir del diseño temporal y no de los perfiles de expresión génica observados. Los detalles del procedimiento de calibración se describen en Abston et al. [39].

A.7.5. Refinamiento local

Una vez obtenido el par $(\widehat{\alpha}, \widehat{\omega})$ que maximiza el criterio penalizado $J(\alpha, \omega)$ sobre la rejilla de búsqueda, puede aplicarse un refinamiento local para reducir los efectos de la discretización. Este procedimiento sigue una estrategia de búsqueda por patrones (*pattern search*) que explora ocho puntos vecinos de la solución actual, mediante pequeños desplazamientos de α, modificaciones multiplicativas de ω y combinaciones de ambos movimientos.

En cada iteración se evalúa el criterio penalizado en los puntos candidatos y se seleccionan aquellos cuyos valores son próximos al máximo local. Entre estos se elige el que minimiza la suma del error residual ponderado y el término de penalización. Si varios candidatos presentan valores equivalentes, se prefiere aquel con mayor ω, para evitar desplazamientos innecesarios hacia perfiles excesivamente apuntados.

La solución seleccionada se acepta únicamente si mejora el valor actual de $J(\alpha, \omega)$. En caso contrario, se mantiene la solución anterior y se reduce el tamaño del entorno de búsqueda. El procedimiento se limita a un número reducido de iteraciones, tres por defecto. Finalmente, los coeficientes lineales del modelo se reestiman mediante mínimos cuadrados ponderados.

A.8. Pasos de los módulos de la implementación

Esta sección detalla los pasos internos de los módulos presentados en la Sección 2.2.3.1, junto con la justificación de las diferencias respecto a la implementación original. En cada panel, lo heredado de CIRCUST aparece en negro y las modificaciones o incorporaciones de este trabajo en azul.

A.8.1. Módulo 1. Preprocesado

Módulo 1. Pasos

1. Descartar las muestras sin ningún valor numérico.
2. Eliminar las filas sin identificador.
3. Si el gen *ARNTL* no está presente pero sí su alias *BMAL1*, renombrarlo.
4. Eliminar los genes con una fracción de ceros superior a η. El filtro se extiende a los valores ausentes, y los umbrales η_0 y η_{NA} de ceros y de ausentes pueden fijarse por separado.
5. Resolver los genes duplicados conservando la fila de mayor desviación absoluta mediana.
6. Imputar los valores ausentes restantes con la mediana de los valores observados del gen.
7. Descartar los genes constantes.
8. Normalizar cada gen al intervalo $[-1, 1]$ mediante *min-max*.

A.8.2. Módulo 2. Selección de genes *core*

Módulo 2. Pasos

1. Fijar la lista de genes solicitados. Por defecto son los doce de CIRCUST, *PER1, PER2, PER3, CRY1, CRY2, ARNTL, CLOCK, NR1D1, RORA, DBP, TEF* y *STAT3*. Se admiten además una lista propia y los conjuntos predefinidos de Zhang et al. [22], de diez genes, y de Ruben et al. [24], de 54 genes.
2. Comprobar la presencia de cada gen solicitado en la matriz y descartar los ausentes, registrándolos.
3. Interrumpir la ejecución si ninguno de los genes solicitados está en la matriz.

A.8.3. Módulo 3. CPCA y detección de *outliers*

El criterio de detección de muestras atípicas se describe en la Sección A.9. El indicador `compute_fmm_fits` permite omitir la detección y el ajuste FMM de los genes *core* cuando solo se necesita el orden, como ocurre en las repeticiones del módulo 6.

Módulo 3. Pasos

1. Aplicar CPCA a la submatriz de genes *core*, con centrado por gen, escalado por muestra y descomposición en valores singulares. Obtener la fase φ_i y la norma radial LE_i de cada muestra a partir de las dos primeras componentes, como se describe en la Sección A.2.
2. Ajustar un *spline* periódico a cada gen *core* sobre el orden inicial y calcular sus residuos estandarizados.
3. Detectar y eliminar las muestras atípicas, hasta un máximo del 5 % de las muestras, mediante los residuos estandarizados del modelo FMM y el criterio radial. Se sustituyen los residuos FMM por los del *spline*. Una muestra se elimina si su residuo supera τ_s en al menos una fracción ρ de los genes *core*. El criterio radial queda desactivado por defecto y, si se activa, se combina con el anterior por unión.
4. Si se han eliminado muestras, renormalizar la submatriz *core* y repetir el CPCA.
5. Ordenar las muestras por su fase, obtener la escala circular y ajustar el modelo FMM a los genes *core* sobre ese orden. Con CircaFMM, en este ajuste se calibra el parámetro de regularización λ, que heredan los módulos siguientes.

A.8.4. Módulo 4. Sincronización del orden circular

La implementación conserva la rotación y la elección del sentido con *ARNTL* y *DBP*, y generaliza la verificación posterior, que se describe en la Sección A.10. La comprobación se aplica siempre que haya pares utilizables, y el aviso del original pasa a ser un indicador. Si no los hay, se mantiene la orientación, en lugar de invertirla como hace el original.

Módulo 4. Pasos

1. Rotar la escala para llevar el máximo del gen ancla a a π, $\widetilde{\varphi} = (\varphi - \widehat{t}_{U,a} + \pi)$ mód 2π, y reordenar las muestras.
2. Fijar el sentido con el gen de dirección d. Si $(\widehat{t}_{U,d} - \widehat{t}_{U,a} + \pi)$ mód $2\pi < \pi$ se conserva el orden. En caso contrario se invierte el orden y se refleja la escala, $2\pi - \widetilde{\varphi}$.
3. Reparametrizar los ajustes FMM de los genes *core* en el nuevo marco, sin reajustarlos: $\alpha \mapsto (\alpha - \widehat{t}_{U,a} + \pi)$ mód 2π y, si se invirtió el sentido, $(\alpha, \beta) \mapsto (2\pi - \alpha,\ 2\pi - \beta)$.
4. Clasificar los genes *core*, salvo el ancla y el de dirección, en diurnos, con máximo en $[0, \pi)$, y nocturnos, con máximo en $[\pi, 2\pi)$.
5. Verificar la orientación cuando el máximo de d queda próximo a 0 o a π, o cuando menos de la mitad de los genes *core* tienen su máximo en $[0, \pi)$, comprobando la cadena $DBP \prec CRY1 \prec ARNTL$. La cadena se sustituye por la suma $S = \sum_{(g_1,g_2)\in\mathcal{P}^*} \operatorname{sin}(\widehat{t}_{U,g_2} - \widehat{t}_{U,g_1})$ sobre los pares $\mathcal{P}^* \subseteq \mathcal{P}$ con ambos genes presentes y $R^2_{\text{FMM}} \geq 0{,}5$, que se evalúa siempre que haya pares utilizables, y se invierte si $S < 0$. Si no hay pares utilizables o falta el gen de dirección, se mantiene la orientación del paso 2.

A.8.5. Módulo 5. Identificación de genes TOP

La circunferencia se divide en n_s sectores, con origen en la mediana circular de los instantes de máxima expresión de los genes que superan los filtros, y el cupo se reparte a partes iguales entre los sectores con genes candidatos. En cada sector se toman los de mayor R^2_{FMM}, y las plazas que un sector no llega a cubrir se redistribuyen entre los demás. Se reparte por sectores y no de forma global porque un orden global tiende a concentrar la selección en una única región de la circunferencia y deshace la cobertura que se busca.

Módulo 5. Pasos

1. Ajustar el modelo ORI a cada gen de la matriz sobre el orden preliminar y calcular R^2_{ORI}.
2. Conservar los genes con $R^2_{\text{ORI}} \geq 0{,}5$.
3. Ajustar el modelo FMM a los genes conservados. El estimador puede ser el base o CircaFMM, con el parámetro de regularización heredado del módulo 3, y los ajustes se reparten entre trabajadores.
4. Conservar los genes con $\omega > 0{,}1$ y $R^2_{\text{FMM}} \geq 0{,}5$.
5. Comprobar que los máximos t_U cubren la circunferencia. Se divide la circunferencia en n_s sectores, con origen en la mediana circular de los t_U de los genes conservados. Los sectores vacíos solo se registran.
6. Retener una fracción prefijada del total de genes, los de mayor R^2_{FMM}. El cupo es $N = \text{máx}\big(n_s, \text{round}(f\,G)\big)$, con G el número de genes de la matriz. Se reparte a partes iguales entre los sectores con candidatos, se toman en cada uno los de mayor R^2_{FMM} y se redistribuyen las plazas que un sector no cubre. Si hay menos candidatos que el cupo, se conservan todos.
7. Incorporar los genes *core* que no estén en el conjunto, ajustando su modelo FMM.

8. Asignar cada gen TOP a su sector y volver a comprobar la cobertura, ya que los genes *core* incorporados pueden desplazar el origen de los sectores.
9. Construir la matriz de los genes TOP, con los genes en filas y las muestras en el orden preliminar.

A.8.6. Módulo 6. Estimación iterativa de órdenes circulares

El procedimiento sigue el del original, con tres diferencias principales. La primera es que los pares de consistencia del módulo 4 se restringen, en cada repetición, a los que tienen sus dos genes en el subconjunto sorteado. Un par ajeno al sorteo no aporta información sobre el orden que ese sorteo ha producido, y aplicarlo a todas las repeticiones las sesgaría en el mismo sentido, anulando la diversidad que busca el muestreo. La segunda es la comprobación de que todas las repeticiones recorren el ciclo en el mismo sentido que el orden preliminar. La regla del módulo 4 decide cada orden por separado y es frágil cuando los máximos de *ARNTL* y *DBP* están próximos a la antifase, de modo que puede invertir alguna repetición aunque acierte en las demás. Una sola repetición invertida contamina cualquier resumen posterior, por lo que la corrección se aplica antes de usar la colección. Para ello se emplea la correlación circular de Fisher and Lee [47] y no la de Jammalamadaka y Sarma [48], porque esta resta a cada escala su dirección media, que está mal determinada cuando las muestras cubren todo el ciclo. En 720 escenarios de inversión conocida, la primera acertó el sentido en el 100 % de los casos y la segunda en el 95,3 %. La tercera es que, con CircaFMM, el parámetro de regularización λ se hereda del módulo 3 y no se recalibra en cada repetición. Sobre una misma escala y cambiando solo la semilla, la calibración devuelve valores entre 1,23 y 8,76, una dispersión mayor que la observada entre repeticiones, y recalibrar suponía el 99 % del coste adicional de CircaFMM en esta etapa.

Módulo 6. Pasos

1. Fijar el tamaño de cada subconjunto, $\lceil \frac{2}{3} |\mathcal{T}| \rceil$. Para cada repetición $k = 1, \ldots, K$:
2. Sortear sin reemplazo un subconjunto de genes de $\mathcal{T}$. El sorteo se realiza sobre el conjunto TOP completo, incluidos los genes *core* incorporados, ya que todos han superado los filtros del módulo 5.
3. Aplicar el CPCA del módulo 3 a la submatriz del subconjunto, sin eliminar muestras atípicas, y reordenar la matriz TOP según el orden obtenido. Se omiten los ajustes FMM internos del CPCA (`compute_fmm_fits = False`), ya que de él solo se utiliza el orden.
4. Ajustar el modelo FMM a los genes *core* sobre la nueva escala y sincronizar el orden con el módulo 4. Solo se emplean los pares de consistencia con ambos genes en el subconjunto sorteado.
5. Comprobar que el orden es factible, es decir, que la distancia angular máxima entre muestras consecutivas es inferior a π y no supera la del orden preliminar. En caso contrario,

volver al paso 2. Se admiten hasta 50 sorteos por repetición, tras los que se acepta el último y se emite un aviso, en lugar de interrumpir la ejecución.

6. Ajustar el modelo FMM a cada gen TOP sobre la escala de la repetición y reparametrizar sus parámetros al marco sincronizado, como en el módulo 4. El estimador puede ser el base o CircaFMM, con λ heredado del módulo 3, y los ajustes se reparten entre trabajadores.
7. Corregir la orientación de las repeticiones. Se invierte cada orden cuya correlación circular de Fisher y Lee con el orden preliminar sea negativa, reflejando su escala y los parámetros FMM de sus genes, $(\alpha, \beta) \mapsto (2\pi - \alpha,\ 2\pi - \beta)$. El origen no se modifica.

A.8.7. Módulo 7. Orden final y caracterización de los genes TOP

La versión original no proporciona un orden final de las muestras. La fase que asocia a cada muestra es la del orden preliminar, y los parámetros de cada gen se obtienen como la mediana de sus K estimaciones. En la implementación desarrollada esa mediana se sustituye. Al seleccionar una ordenación, $[M^{TOP}]$ recoge los parámetros de la repetición elegida, para que sea coherente con el orden que se publica junto a ella. La mediana mezclaría órdenes que el propio criterio de selección ha descartado, y la mediana de cada parámetro por separado no corresponde al ajuste del gen sobre ningún orden. Con un consenso, el orden no coincide con ninguna de las repeticiones, por lo que el modelo FMM se reajusta a cada gen TOP sobre el orden de consenso. De la propuesta de Barragán et al. [1] se implementa solo el primer paso.

Módulo 7. Pasos

1. Resumir los parámetros FMM de cada gen TOP mediante la mediana de sus K estimaciones. Este paso del original se sustituye por los pasos 2 a 5.
2. Calcular, para cada repetición, la mediana de R^2_{FMM} y el número de genes con $R^2_{\text{FMM}} \geq \tau$ sobre los genes TOP.
3. Si `method` = `best_k`, elegir la repetición k^* que optimiza el criterio de selección, con desempate por la mediana de R^2_{FMM} en `n_well_fitted`. El orden final es $\mathbf{o}^* = \mathbf{o}^{(k^*)}$, con sus fases, y $[M^{TOP}]$, los parámetros FMM de esa repetición.
4. Si `method` = `aggregate`, construir la matriz $K \times n$ de fases $\varphi_{o_i^{(k)}}$ y los pesos ω_k de la Sección 2.2.2.2, y obtener el consenso con el método elegido. Con la media circular, el orden se deriva de las fases medias. Con TSP3 y HOD, las fases se estiman con CIRE bajo el orden de consenso (Sección 2.2.2.3).
5. Construir $[M^{TOP}]$ con la función `build_atlas`. Con `best_k` recoge los parámetros de la repetición elegida. Con el consenso reajusta el modelo FMM a cada gen TOP sobre el orden y las fases finales, con el mismo estimador y la misma rejilla del módulo 6 y repartiendo los ajustes entre trabajadores.

A.9. Detección de muestras atípicas con *splines* cúbicos periódicos

Esta sección detalla el criterio de detección de muestras atípicas que emplea la implementación en lugar de los residuos del modelo FMM de los genes *core*, y que se resume en el módulo de CPCA de la Sección 2.2.3.1. A diferencia de las secciones anteriores, no describe un procedimiento publicado, sino una propuesta de este trabajo.

A.9.1. Spline cúbico periódico

Un *spline* cúbico es una función definida a trozos mediante polinomios de grado tres sobre los intervalos que determinan unos puntos llamados nodos, empalmados de modo que la función y sus dos primeras derivadas sean continuas. Es periódico, de periodo 2π, cuando además la función y esas derivadas coinciden en los dos extremos del ciclo, de manera que describe una curva cerrada, sin discontinuidad en el punto donde se corta la circunferencia. Esta propiedad lo hace adecuado para señales circadianas, cuyo origen en la escala circular es arbitrario.

Se emplean m nodos equiespaciados sobre el ciclo completo, $\zeta_l = 2\pi(l-1)/(m-1)$ con $l = 1, \ldots, m$, y no repartidos según el rango de las muestras, de modo que la forma del *spline* no depende de cómo se distribuyan los instantes de observación. Con esta elección el espacio de *splines* periódicos tiene dimensión $m-1$ y se representa mediante una base de $m-1$ funciones B-*spline* periódicas, $B_1, \ldots, B_{m-1}$, de modo que

$$f(t) = \sum_{j=1}^{m-1} c_j \, B_j(t), \qquad t \in [0, 2\pi).$$

Las funciones de la base suman uno en todo punto, por lo que el modelo incluye implícitamente un nivel medio. Con los $m = 5$ nodos por defecto el *spline* tiene 4 coeficientes, un número muy inferior al de muestras. Por ello no puede pasar por cada punto, como haría un *spline* interpolante, y una desviación real de una muestra deja un residuo visible.

A.9.2. Ajuste y residuos estandarizados

Para cada gen g del conjunto *core* se ajusta el *spline* sobre la escala circular φ_i del orden preliminar, por mínimos cuadrados ordinarios,

$$\widehat{\mathbf{c}}_g = \arg\min_{\mathbf{c}} \; \sum_{i=1}^{n} \Big(X_g(\varphi_i) - \sum_{j=1}^{m-1} c_j \, B_j(\varphi_i) \Big)^2 .$$

Los residuos $e_{gi} = X_g(\varphi_i) - \widehat{X}_g(\varphi_i)$ se estandarizan dividiéndolos por su desviación típica muestral, $r_{gi} = e_{gi}/s_g$, donde s_g es la desviación típica de los residuos del gen g. Este ajuste es independiente del modelo FMM que se emplea después sobre los mismos datos, lo que evita detectar las muestras atípicas con el mismo modelo que luego se ajustará a ellas.

La Figura A.1 ilustra la base, el ajuste y los residuos sobre un gen simulado con una muestra atípica.

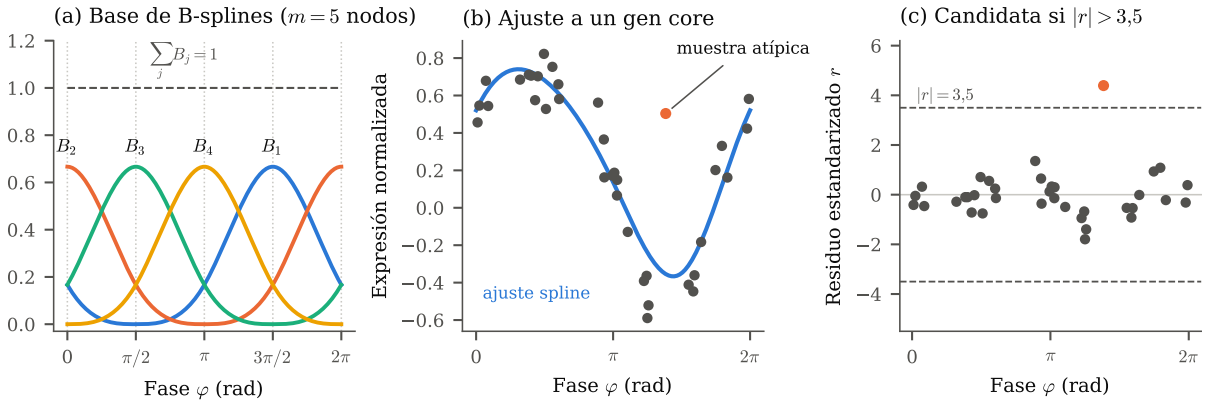


Figura A.1: Detección de muestras atípicas con *splines* cúbicos periódicos. (a) Base de $m = 5$ nodos, con cuatro funciones B-*spline* periódicas que suman uno. (b) Ajuste a un gen *core* simulado, con una muestra atípica en naranja. (c) Residuos estandarizados y umbrales $\pm 3{,}5$. Los datos son sintéticos.

A.9.3. Regla de decisión

Un gen g declara candidata a la muestra i cuando $|r_{gi}| > \tau_s$, con $\tau_s = 3{,}5$ por defecto. La muestra se elimina cuando la proporción de genes *core* que la declaran candidata es al menos ρ, con $\rho = 0{,}25$ por defecto. Exigir la coincidencia de varios genes evita descartar una muestra por la desviación aislada de un único gen, y permite detectar desviaciones coordinadas entre genes, que son las que perturban el CPCA.

El número de muestras eliminadas no supera $\lceil 0{,}05\, n \rceil$. Cuando hay más candidatas que ese límite, se eliminan las más atípicas, esto es, las que declara candidatas una mayor proporción de genes *core* y, a igualdad de proporción, las de mayor residuo medio absoluto. El criterio radial del procedimiento original puede combinarse con este mediante una unión, aunque está desactivado por defecto.

A.9.4. Alcance

El criterio es fiable a partir de unas 24 muestras. Con menos, el *spline* también se ajusta en exceso a los datos y puede dejar un residuo pequeño en una observación atípica, la misma limitación que presenta el modelo FMM. En pruebas con contaminación sintética

controlada, mantiene las muestras con una desviación aislada de un solo gen y detecta las desviaciones coordinadas entre varios genes a partir de ese tamaño.

A.10. Verificación de la orientación mediante pares de genes

Esta sección detalla la verificación de la orientación que realiza la implementación tras fijar el sentido del orden con el gen de dirección, y que se resume en el módulo de sincronización de la Sección 2.2.3.1. Generaliza la comprobación con una cadena fija de tres genes descrita en la Sección A.5.

A.10.1. Por qué es necesaria una verificación

El sentido del recorrido se decide con un único gen, el de dirección d, a partir de la posición de su instante de máxima expresión una vez rotada la escala para que el del gen ancla a quede en π. Cuando el instante de máxima expresión de d queda cerca de 0 o de π, como ocurre al estar *ARNTL* y *DBP* casi en antifase, una perturbación pequeña de su estimación cambia el semicírculo en que cae y, con ello, el sentido del orden. Una verificación basada en varios genes con una relación de fase conocida reduce la dependencia de uno solo.

A.10.2. Relación de orden entre dos genes sobre la circunferencia

Se parte de un conjunto $\mathcal{P}$ de pares ordenados de genes *core* (g_1, g_2), para los que se conoce a priori que el instante de máxima expresión de g_2 sigue al de g_1 con una separación inferior a media vuelta. Por defecto $\mathcal{P} = \{(DBP, CRY1), (CRY1, ARNTL)\}$, que reproduce la cadena $DBP \prec CRY1 \prec ARNTL$ del procedimiento original.

Los instantes $\widehat{t}_U$ son ángulos, por lo que la afirmación «g_2 pica después de g_1» no puede comprobarse con la desigualdad $\widehat{t}_{U,g_1} < \widehat{t}_{U,g_2}$, que es lineal y depende de dónde se sitúe el corte de la circunferencia. Por ejemplo, con g_1 a las 23 h y g_2 a la 1 h, el gen g_2 pica dos horas después de g_1 y, sin embargo, $23 < 1$ es falso. El seno de la diferencia,

$$\sin(\delta), \qquad \delta = \widehat{t}_{U,g_2} - \widehat{t}_{U,g_1},$$

es en cambio 2π-periódico, por lo que no depende del corte. Es positivo cuando g_2 se encuentra entre 0 y media vuelta por delante de g_1 y negativo cuando se encuentra por detrás, que es precisamente la noción circular de «ir después».

La Figura A.2 muestra el ejemplo anterior sobre la circunferencia y la aportación del seno de la diferencia.

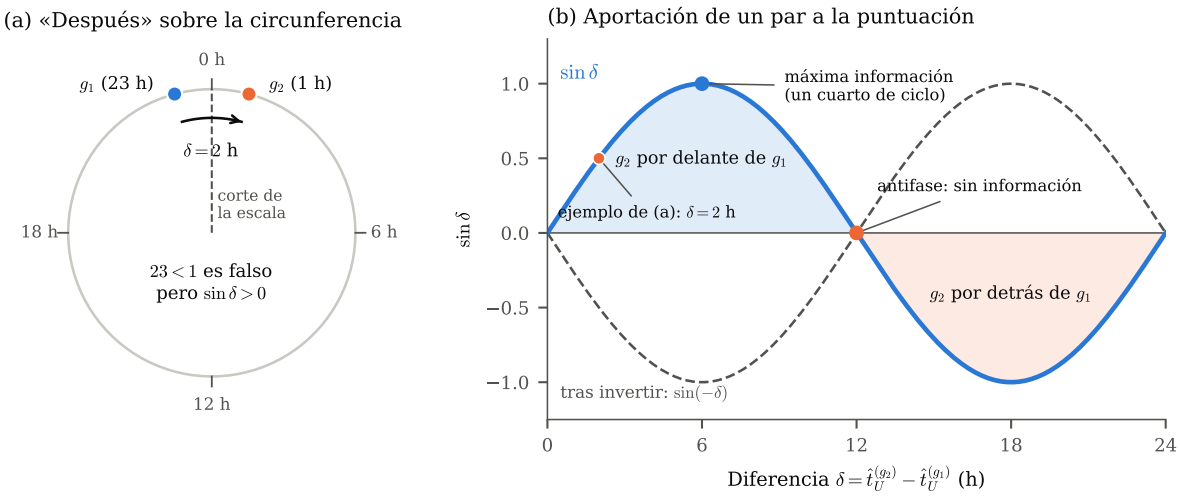


Figura A.2: Verificación de la orientación con el seno de la diferencia. (a) Un par con g_1 a las 23 h y g_2 a la 1 h. La comparación lineal falla por el corte de la escala, mientras que el seno de la diferencia es positivo. (b) Aportación $\sin\delta$ de un par según la separación entre sus máximos, y su opuesto tras invertir la orientación.

A.10.3. Puntuación y decisión

Sea $\mathcal{P}^* \subseteq \mathcal{P}$ el subconjunto de pares utilizables, esto es, aquellos cuyos dos genes están entre los genes *core* y tienen un ajuste FMM con $R^2_{\mathrm{FMM}} \geq 0{,}5$, para no basar la decisión en máximos mal estimados. Se calcula la puntuación

$$S = \sum_{(g_1,g_2)\in\mathcal{P}^*} \sin\!\left(\widehat{t}_{U,g_2} - \widehat{t}_{U,g_1}\right),$$

y la orientación se invierte si $S < 0$. La inversión actúa sobre la escala como la reflexión $t \mapsto (2\pi - t)$ mód 2π, que transforma δ en $-\delta$ y, por tanto, S en $-S$. La puntuación cambia de signo al invertir el orden, de modo que su signo distingue una orientación correcta de una invertida. Si $\mathcal{P}^*$ está vacío no hay evidencia a priori con la que decidir y se mantiene la orientación fijada con el gen de dirección. La comprobación se aplica siempre que existan pares utilizables, y el aviso por proximidad del instante máximo de d a 0 o a π se registra únicamente como diagnóstico.

La magnitud $|\sin(\delta)|$ pondera además la información que aporta cada par. Es máxima cuando los instantes de máxima expresión distan un cuarto de ciclo y es nula cuando distan medio ciclo, porque en un ciclo de 24 horas «12 horas después» y «12 horas antes» corresponden a la misma posición, y ese par no puede distinguir el sentido. Esto es relevante porque *ARNTL* y *DBP* se sitúan casi en antifase. Una regla lineal asignaba a un par así un voto completo y, como la reflexión deja invariantes los instantes 0 y π, un par anclado en ellos seguía cumpliéndose tras invertir el orden, lo que con dos pares podía producir un empate y dejar pasar una inversión incorrecta.

A.10.4. Alcance

Las relaciones de orden a priori no son universales. En particular, la relación $CRY1 \prec ARNTL$ se invierte en algunos tejidos, como el músculo esquelético humano, y ampliar la lista de pares con otros genes del reloj no la hace más fiable de forma general. La verificación mejora la robustez de la orientación en los casos habituales, pero no la garantiza.