

Universidad de Valladolid

Universidad de Valladolid

Facultad de Ciencias

Extensión y optimización del procedimiento CIRCUST de reconstrucción temporal

Trabajo de Fin de Grado en Estadística

Autor:
Samuel Ortega Bustos

Tutores:
Yolanda Larriba González
Juan Camilo Yepes Borrero

Curso Académico 2025-2026

29 de junio de 2026

Resumen

La estimación de la fase circadiana a partir de datos transcriptómicos representa un reto central en cronobiología, especialmente en estudios humanos donde las etiquetas temporales suelen ser inaccesibles por restricciones éticas o clínicas. El algoritmo CIRCUST, basado en el Análisis de Componentes Principales Circulares (CPCA), ha demostrado ser una herramienta prometedora para la reconstrucción del orden temporal. Sin embargo, su implementación actual carece de la modularidad necesaria y de mecanismos para ajustar covariables o manejar muestreos dispersos.

Este trabajo presenta una re-implementación modular y eficiente de CIRCUST en Python, junto con un refinamiento metodológico profundo. Las mejoras incluyen la integración de ajustes por covariables y una optimización de la ordenación circular para mejorar la inferencia de fase. Además, se ha desarrollado un marco de simulación para evaluar sistemáticamente la robustez del modelo frente a perturbaciones como el ruido y los efectos por lotes. Finalmente, el pipeline mejorado se valida utilizando conjuntos de datos transcriptómicos reales del cerebro humano post-mortem, demostrando una mayor precisión y relevancia biológica.

Palabras clave: Cronobiología, Transcriptómica, Ordenación Circular, CPCA, Python.

Abstract

Estimating circadian phase from transcriptomic data is a central challenge in chronobiology, particularly in human studies where time-of-day labels are often unavailable. The CIRCUST algorithm, based on Circular Principal Component Analysis (CPCA), offers a promising approach for temporal order reconstruction. However, its current implementation lacks modularity, extensibility, and built-in mechanisms to adjust for covariates or to handle sparse sampling patterns.

This project presents a modular and efficient re-implementation of CIRCUST in Python, alongside a deep methodological refinement. Improvements include the integration of covariate adjustments and enhanced circular ordering for better phase inference. Furthermore, a simulation framework is developed to systematically evaluate robustness against perturbations such as noise and batch effects. Finally, the improved pipeline is validated using real post-mortem human brain transcriptomic datasets, demonstrating improved accuracy and biological relevance.

Keywords: Chronobiology, Transcriptomics, Circular Ordering, CPCA, Python.

Índice general

Índice de figuras III

Índice de tablas IV

1. Introducción 1

1.1. El sistema circadiano: ritmos, reloj molecular y genes circadianos 1

1.2. Análisis de genes circadianos humanos: modelos para el análisis de señales oscilatorias 3

1.3. Atlas de expresiones circadianas humanas. El problema de estimación del orden temporal 4

1.4. Objetivos del trabajo 7

1.5. Asignaturas relacionadas con el Trabajo de Fin de Grado 8

2. Metodología 9

2.1. El algoritmo CIRCUST 9

2.1.1. Visión general del flujo de trabajo 10

2.1.2. Los genes reloj de partida 11

2.1.3. Ordenación circular mediante CPCA 12

2.1.4. Sincronización con el tiempo biológico 12

2.1.5. Modelado de la ritmicidad: del Cosinor al modelo FMM 13

2.1.6. Selección de genes rítmicos y orden robusto 13

2.1.7. Aportaciones de CIRCUST frente a los métodos previos 14

2.2. Otros métodos de estimación del orden temporal 16

2.2.1. Métodos basados en *autoencoders*: CYCLOPS y PENN 16

2.2.2. Métodos para datos multi-tejido: CHIRAL 18

2.3. Fundamentos matemáticos de CPCA y FMM 18

2.3.1. Preliminares de estadística circular 19

2.3.2. Ordenación circular mediante CPCA 19

2.3.3. El modelo FMM 20

2.3.4. Inferencia con restricciones de orden (ORI) 21

2.4. Mejora de CIRCUST: implementación modular y eficiencia 21

2.4.1. Estructura modular 21
2.4.2. Eficiencia en Python 22
2.5. Modelo FMM robusto 23
2.6. El problema de sincronización de órdenes circulares 25
2.6.1. Formulación del problema y los $2n$ órdenes 25
2.6.2. Sincronización mediante genes ancla 26
2.7. Ordenación agregada: orden de consenso 27
2.8. Marco de validación y métricas de similitud 28

3. Resultados y Simulaciones **29**

4. Conclusiones y Trabajo Futuro **30**

Bibliografía **31**

Índice de figuras

1.1. Esquematización del ritmo circadiano subyacente en datos de expresión de un gen circadiano en 24 horas. 1
1.2. Organización jerárquica del sistema circadiano. 2

2.1. Flujo de trabajo del algoritmo CIRCUST. 10
2.2. Arquitectura del *autoencoder* circular de CYCLOPS. 17

Índice de tablas

Capítulo 1

Introducción

1.1. El sistema circadiano: ritmos, reloj molecular y genes circadianos

Los ritmos circadianos subyacen a una gran variedad de procesos biológicos en prácticamente todos los organismos vivos, desde cianobacterias hasta seres humanos [3]. Estos ritmos se manifiestan en distintos niveles de organización biológica, incluyendo procesos fisiológicos (como la temperatura corporal o el ritmo cardíaco), hormonales (como la secreción de cortisol y melatonina) y moleculares (como la expresión génica). Sincronizados principalmente por el ciclo diario de luz y oscuridad, los ritmos circadianos desempeñan un papel fundamental en la regulación y coordinación temporal de procesos fisiológicos, metabólicos y conductuales a lo largo de las 24 horas del día [1, 2, 4, 43].

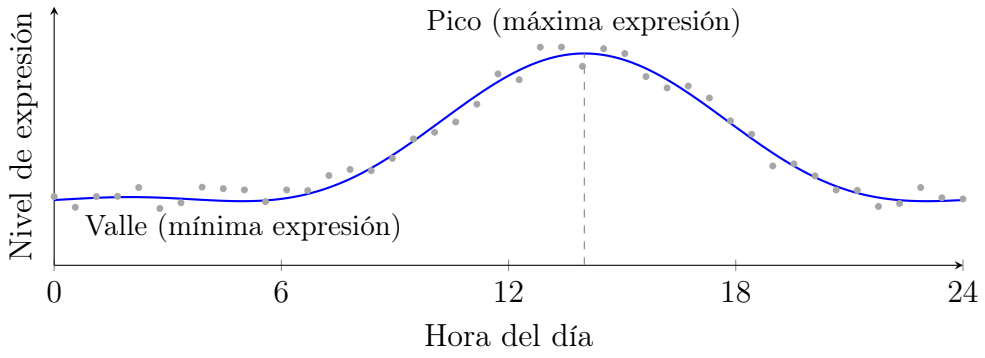


Figura 1.1: Esquematización del ritmo circadiano subyacente en datos de expresión de un gen circadiano en 24 horas. Los puntos representan las observaciones de expresión y la curva el ritmo subyacente. El pico marca el instante de máxima expresión y se relaciona con el momento del día en que el gen realiza su función biológica.

En mamíferos, la organización del sistema circadiano es jerárquica [5]: un oscilador central, conocido como reloj circadiano central y localizado en el núcleo supraquiasmático del hipotálamo [6], recibe información lumínica desde la retina y la utiliza para sincronizarse

con el ciclo externo de luz y oscuridad. Este reloj actúa como marcapasos y coordina osciladores periféricos presentes en órganos y tejidos. La correcta sincronización entre estos relojes resulta esencial para mantener la coordinación temporal de los procesos fisiológicos y metabólicos del organismo, así como su adecuada adaptación a las condiciones ambientales. La Figura 1.2 muestra una esquematización de dicha estructura jerárquica.

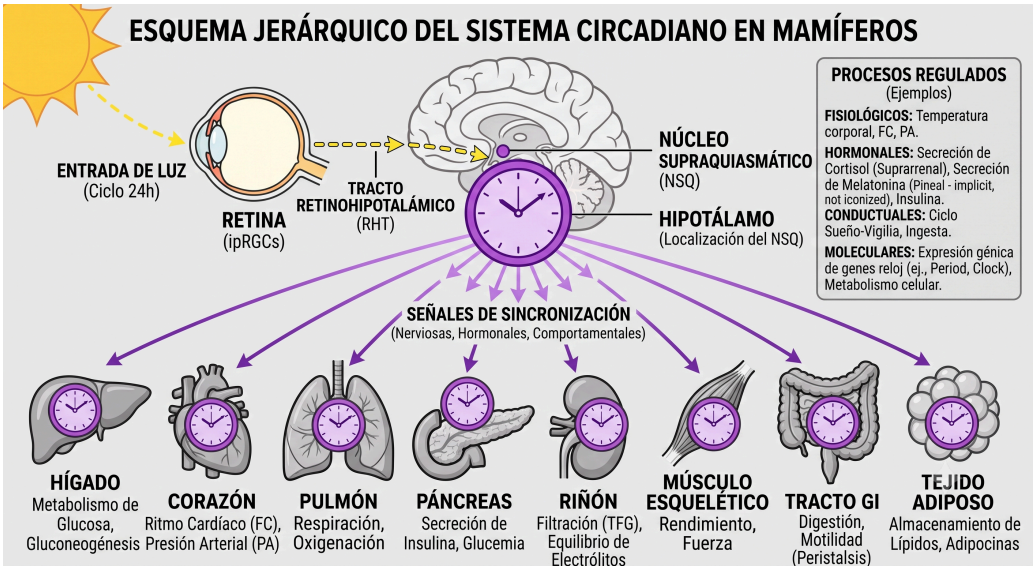


Figura 1.2: Esquematización de la organización jerárquica del sistema circadiano: el reloj central (NSQ) se sincroniza con la luz a través de la retina, así como con los relojes periféricos de los distintos órganos o tejidos.

Esta arquitectura jerárquica da lugar a patrones de expresión génica rítmica específicos de cada tejido. Denominaremos genes circadianos a aquellos cuya expresión presenta oscilaciones con un periodo aproximado de 24 horas en un tejido determinado (véase Figura 1.1). Estos genes desempeñan un papel fundamental en la regulación temporal de procesos celulares y fisiológicos, favoreciendo que las distintas funciones biológicas se ejecuten de forma coordinada a lo largo del día. En particular, el instante de máxima expresión génica (pico de expresión) se encuentra estrechamente relacionado con el momento del día en que el gen ejerce su función biológica principal [13, 14].

En el contexto de la biología circadiana humana, ámbito en el que se centra este trabajo, la relevancia biomédica de estos ritmos ha sido ampliamente documentada, existiendo evidencia de variaciones temporales en resultados clínicos y en la respuesta a distintas intervenciones terapéuticas, como la cirugía cardíaca, la quimioterapia o la respuesta inmune [15, 16, 17]. En contraposición, se ha evidenciado que la desalineación crónica del reloj circadiano, asociada al trabajo por turnos (*shift work*), al *jet lag* social o a la exposición nocturna a luz artificial, constituye un factor de riesgo para trastornos metabólicos (diabetes tipo 2, obesidad), enfermedades cardiovasculares, trastornos neurodegenerativos y diversos tipos de cáncer [11, 12].

1.2. Análisis de genes circadianos humanos: modelos para el análisis de señales oscilatorias

La identificación y caracterización de los genes circadianos a partir de modelos para el análisis de señales oscilatorias resulta fundamental en el ámbito de la biología circadiana humana.

Los modelos más empleados en cronobiología para describir ritmos circadianos son los modelos armónicos sinusoidales, normalmente con un único componente de periodo fijado, por ejemplo 24 horas, entre los que destaca el modelo Cosinor [48]. Este enfoque representa la señal mediante una función sinusoidal, habitualmente con un periodo prefijado, y permite estimar parámetros interpretables como la amplitud, la fase y el nivel medio de expresión. Este tipo de aproximación resulta útil por su sencillez e interpretabilidad, pero puede ser limitada cuando las señales presentan formas asimétricas o patrones de oscilación más complejos.

Como alternativa, existen métodos no paramétricos como *RAIN* [38] o *JTK_CYCLE* [39], que permiten identificar patrones rítmicos sin imponer una forma funcional tan rígida. Sin embargo, no siempre proporcionan parámetros directamente interpretables desde el punto de vista biológico, lo que puede dificultar la caracterización posterior de las diferencias entre grupos o regiones.

En este contexto, destacan los modelos FMM (*Frequency Modulated Möbius*) [27], una familia de modelos paramétricos flexibles que permite representar señales periódicas con formas diversas y, al mismo tiempo, obtener parámetros interpretables. Estos modelos ofrecen una alternativa adecuada para describir curvas de expresión génica cuando la forma de la oscilación no se ajusta necesariamente a una onda sinusoidal simple.

La identificación y caracterización precisa de genes circadianos, así como de sus relaciones tanto intra- como inter-tisulares, es uno de los retos de la cronobiología, ya que resulta fundamental para comprender la regulación y coordinación de los relojes circadianos entre tejidos humanos y su interacción con el entorno. Esta visión integradora se materializa en los denominados atlas de expresión circadiana, que describen la regulación temporal de la expresión génica a escala del organismo y constituyen un recurso clave para el descubrimiento de biomarcadores temporales y el desarrollo de estrategias terapéuticas *time-aware* [9, 40, 43, 37, 41, 23]. Hasta la fecha se dispone de atlas de expresiones circadianas humanas para un número muy reducido de tejidos, generalmente periféricos. Esto ha llevado a recurrir tradicionalmente a estudios en especies homólogas, como ratones o babuinos, donde es posible obtener muestras in vivo. Aunque estos modelos han servido como referencia para guiar la toma de decisiones en humanos, es evidente que pueden introducir sesgos relevantes.

1.3. Atlas de expresiones circadianas humanas. El problema de estimación del orden temporal

Para abordar el problema de la identificación y caracterización de genes circadianos humanos orientado al avance en la construcción de atlas de expresión génica circadiana en humanos, así como al estudio de la interrelación entre tejidos de estos genes, resulta imprescindible disponer de matrices de datos de expresión génica humana a lo largo de las 24 horas en una amplia colección de tejidos y órganos. Sin embargo, la obtención de dichos datos transcriptómicos longitudinales no es viable por razones clínicas y éticas, lo que motiva el uso de datos de expresión *post mortem* en estudios transcriptómicos humanos.

Limitaciones de los datos de expresión humana

A diferencia de lo que ocurre en estudios experimentales con modelos animales, donde la variable temporal puede observarse de forma controlada mediante muestreos realizados a distintas horas del día, en humanos este tipo de diseño no es viable debido al riesgo que implica la obtención de biopsias seriadas de tejidos internos a lo largo del día. Como consecuencia, el análisis transcriptómico en humanos habitualmente se realiza a partir de estudios transversales con muestras *post mortem*, en las que el tiempo biológico interno de cada individuo no se observa directamente y debe ser inferido a partir de la información disponible.

Como solución aproximada a este problema, algunos estudios proponen el uso de la hora de muerte (*TOD*, del inglés *Time of Death*). Sin embargo, utilizar directamente la hora de fallecimiento podría inducir una ordenación temporal inadecuada de las muestras, puesto que esta hora no tiene por qué coincidir con la fase circadiana real del individuo. Factores como el cronotipo, los hábitos de sueño, la enfermedad, la medicación o las condiciones previas al fallecimiento pueden provocar discrepancias entre el tiempo externo registrado y el estado circadiano interno.

A esta primera limitación deben añadirse el hecho de que los estudios genómicos muestran una elevada variabilidad técnica, derivada de la degradación del ARN en las muestras biológicas, de errores sistemáticos o aleatorios en los dispositivos de medición y de la heterogeneidad de los protocolos experimentales entre laboratorios.

Además, al tratarse de datos transversales procedentes de individuos distintos, existe una elevada heterogeneidad biológica y clínica. Variables como la edad, el sexo, la causa de la muerte, el estado clínico o la historia individual de sueño pueden influir en la expresión génica y dificultar la separación entre variabilidad interindividual y variabilidad asociada al momento circadiano.

Por último, los estudios transcriptómicos humanos *post mortem* suelen presentar una

cobertura temporal irregular a lo largo del ciclo circadiano, ya que determinadas franjas horarias se encuentran sobrerrepresentadas mientras que otras apenas disponen de muestras [44, 45]. Esta distribución desigual puede comprometer la identificación y el análisis de genes circadianos, especialmente en modelos restrictivos como el Cosinor.

Estas limitaciones han condicionado significativamente los avances en biología circadiana humana. De hecho, gran parte del conocimiento inicial sobre ritmicidad circadiana procede de modelos animales mantenidos bajo condiciones experimentales altamente controladas, que no reproducen la complejidad ni la variabilidad inherentes a la fisiología humana [9]. También se han desarrollado atlas transcriptómicos en especies filogenéticamente próximas, como el babuino [43], aunque su reducido tamaño muestral limita la reproducibilidad y generalización de los resultados. Como consecuencia, actualmente no se dispone de conjuntos de referencia de expresión génica circadiana humana suficientemente amplios, lo que dificulta tanto la validación objetiva de nuevas metodologías como la comparación sistemática entre tejidos.

Atlas de expresión circadiana humana

Las limitaciones asociadas al acceso a datos de expresión génica humana han ralentizado el desarrollo de estos atlas, ya que requieren una estimación previa del tiempo biológico de las muestras, problema conocido en estadística como estimación del orden temporal.

Los escasos trabajos centrados en humanos se basan principalmente en muestras *post mortem*, en su mayoría procedentes del proyecto GTEx (*Genotype-Tissue Expression*) [22], principal referencia para el estudio de la expresión génica en tejidos humanos *post mortem*. Aunque GTEx registra para cada donante una estimación del instante de fallecimiento (*Time of Death*, TOD), esta medida suele ser imprecisa y no refleja necesariamente la fase circadiana interna del individuo.

Los atlas de expresión circadiana humana desarrollados durante la última década se han construido a partir de distintas estrategias de estimación del orden temporal. Entre ellos destacan el atlas de 13 tejidos propuesto por Ruben et al. [37], basado en *CYCLOPS* y en información circadiana conservada entre ratón y humano; el atlas de 34 tejidos desarrollado por Larriba et al. [23], construido exclusivamente a partir de información transcriptómica humana mediante *CIRCUST*; y el atlas más reciente de Talamanca et al. [36], que amplía el análisis a 54 tejidos mediante el algoritmo bayesiano *CHIRAL*.

En este contexto, la estimación del orden temporal de las muestras constituye un problema central para la construcción de atlas circadianos humanos. Sin embargo, su resolución resulta particularmente compleja debido a la elevada incertidumbre y heterogeneidad inherentes a los datos transcriptómicos *post mortem*, pudiendo una estimación incorrecta del mismo condicionar la posterior identificación de genes circadianos.

Algoritmos de estimación del orden temporal

Los algoritmos de estimación del orden temporal comparten generalmente varios elementos metodológicos comunes: la selección o definición de un conjunto de genes circadianos de referencia (*core genes* o *seed genes*), la reducción de dimensionalidad de la matriz de expresión génica a partir de dichos genes, y la construcción de un espacio latente de naturaleza circular que permita representar la trayectoria circadiana subyacente de las muestras.

Entre los métodos más utilizados destacan *CYCLOPS* [30], *CYCLOPS 2.0* [31], *PENN* [32], *CIRCUST* [23] y *CHIRAL* [36]. *CYCLOPS* constituye el método de referencia en este ámbito. Su estrategia combina una reducción de dimensionalidad basada en componentes principales con un autoencoder de geometría circular que proyecta las muestras sobre una representación latente en la que la posición angular se interpreta como tiempo circadiano. Aunque ha demostrado un excelente rendimiento en aplicaciones reales, su dependencia de conjuntos de genes definidos en otras especies y la disminución de rendimiento en muestras reducidas constituyen algunas de sus principales limitaciones. *CYCLOPS 2.0* extiende este enfoque permitiendo incorporar covariables durante la estimación del orden temporal. Otros algoritmos que comparten la misma filosofía de autoencoders circulares son *PENN* [32], *PROTECT* [33] o *COFE* [34].

CHIRAL, basado en un marco de inferencia bayesiana, permite incorporar simultáneamente información procedente de múltiples tejidos mediante la estimación conjunta de una fase circadiana global para cada donante y de fases específicas para cada tejido. La formulación bayesiana facilita además la integración de distintas fuentes de incertidumbre y de información previa sobre la organización temporal del sistema circadiano. Su principal diferencia respecto a otros enfoques radica en asumir la existencia de una fase circadiana común compartida por todos los tejidos de un mismo individuo, una hipótesis biológica todavía controvertida y cuya validez puede verse comprometida en tejidos altamente heterogéneos o bajo condiciones experimentales no estandarizadas.

A diferencia de los algoritmos anteriores, *CIRCUST* aborda el problema desde una perspectiva diferente, fundamentada en estadística direccional y en el modelo para el análisis de señales oscilatorias FMM (*Frequency Modulated Möbius*). Su principal aportación radica en proporcionar un marco matemático explícito para formular la estimación del orden temporal como un problema de optimización sobre un espacio circular, aprovechando la naturaleza intrínsecamente periódica de los ritmos circadianos. Para ello, el método combina la selección de un conjunto inicial de genes core, una reducción de dimensionalidad no lineal mediante *CPCA* (*Circular Principal Component Analysis*) y el uso del modelo paramétrico FMM, cuya formulación incorpora de manera natural la geometría circular de las señales oscilatorias.

Además, *CIRCUST* incorpora procedimientos iterativos de refinamiento de la esti-

mación del orden temporal con el propósito de proporcionar una caracterización robusta de marcadores circadianos, como los instantes de máxima expresión, frente a la elevada variabilidad característica de los estudios transcriptómicos *post mortem*. El método ha mostrado resultados competitivos en la caracterización de genes circadianos robustos mediante parámetros interpretables del modelo FMM, como fases, amplitudes e instantes de máxima expresión génica, a partir de estimaciones iterativas del orden temporal obtenidas en un atlas de 34 tejidos humanos de GTEx. Sin embargo, su rendimiento depende en gran medida de la calidad y representatividad de los genes de referencia utilizados, así como de la capacidad de identificar de forma fiable señales rítmicas que permitan refinar progresivamente la estimación temporal, y no proporciona una única solución al problema de estimación temporal.

1.4. Objetivos del trabajo

El objetivo principal de este trabajo es el desarrollo de nuevas metodologías y herramientas de *software* estadístico orientadas a la extensión y optimización del algoritmo CIRCUST para la estimación del orden temporal. En particular, se persigue incrementar su flexibilidad metodológica, mejorar su eficiencia computacional y ampliar su aplicabilidad en estudios transcriptómicos humanos a gran escala, favoreciendo así su potencial uso en investigación biomédica. Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. Re-implementación modular en Python del algoritmo *CIRCUST*. Diseñar e implementar una arquitectura modular en la que cada etapa original de *CIRCUST* quede aislada en componentes independientes, reproducibles, fáciles de extender y acoplar en etapas futuras, y computacionalmente eficiente. La implementación se acompañará de una guía y ejemplos de uso.

2. Incorporación del modelo FMM robusto. Incorporar una variante del modelo FMM que incluya ponderación basada en el diseño temporal y mecanismos de regularización para estabilizar la estimación de perfiles oscilatorios no sinusoidales bajo condiciones de muestreo irregular.

3. Incorporación de un módulo de estimación de orden circular. Desarrollar un módulo de consenso para la estimación del orden temporal que permita obtener un único orden circular a partir de las distintas estimaciones generadas durante el proceso iterativo. Se evaluarán estrategias basadas en la minimización de discrepancias circulares y en la agregación de órdenes circulares, con el objetivo de mejorar la robustez, estabilidad y reproducibilidad de la estimación final.

4. Diseño de un experimento de simulación y validación. Diseñar un marco de validación basado en datos sintéticos que reproduzca las características de los estudios transcriptómicos circadianos, permitiendo evaluar de forma sistemática la precisión, robustez y estabilidad de la metodología propuesta para la estimación del orden temporal bajo distintos escenarios experimentales.

5. Aplicación a un conjunto de datos reales. Evaluar la eficiencia de la metodología propuesta en conjuntos de datos de expresión humana *post mortem*, así como en modelos animales. (A concretar cuando se haya realizado.)

1.5. Asignaturas relacionadas con el Trabajo de Fin de Grado

El desarrollo de este trabajo se apoya en competencias adquiridas en varias asignaturas del Grado en Estadística:

- Estadística Descriptiva e Inferencia Estadística I y II. Proporcionan el marco para la validación de los resultados, la interpretación de los p-valores y la evaluación de modelos, aspectos centrales en la metodología de validación propuesta en este trabajo.

- Análisis de Datos y Análisis Multivariante. Aportan las técnicas de análisis multivariante y, en particular, el Análisis de Componentes Principales, que constituye la base del CPCA sobre el que se sustenta *CIRCUST*.

- Regresión y Anova y Modelos Lineales. Estas materias conforman el pilar del modelado estadístico del grado. Aportan el marco teórico y práctico necesario para abordar la modelización de la expresión génica realizada en este trabajo.

- Computación Estadística. Fundamenta la programación y la implementación computacional del algoritmo, así como su optimización.

Capítulo 2

Metodología

2.1. El algoritmo CIRCUST

CIRCUST (*CIRCular-robUST*) [23] es una metodología para reconstruir el orden temporal de los ritmos moleculares a partir de una matriz de expresión génica que carece de etiquetas temporales fiables. A diferencia de las aproximaciones de caja negra basadas en redes neuronales, CIRCUST se sustenta íntegramente en estadística clásica e interpretable: cada etapa del procedimiento admite una lectura estadística directa y produce magnitudes con significado biológico, como la fase asignada a cada muestra, el instante de máxima expresión de un gen (su pico), su amplitud o su grado de ritmicidad. Esta transparencia es, precisamente, la que permite en este trabajo intervenir y refinar etapas concretas del método sin necesidad de tratarlo como un bloque opaco.

Formalmente, se parte de una matriz de expresión $\mathbf{X} \in \mathbb{R}^{G \times n}$, en la que las G filas corresponden a genes (del orden de decenas de miles) y las n columnas a las muestras. El objetivo es doble: asignar a cada muestra i una fase $\varphi_i \in [0, 2\pi)$ que refleje su posición dentro del ciclo de 24 horas y, a partir del orden inducido por esas fases, caracterizar qué genes son rítmicos y cuándo alcanzan su pico. Conviene recordar (véase la Introducción) que la fase estimada es de naturaleza *circular*: queda determinada salvo una rotación global y un sentido de giro, que deben fijarse después mediante información biológica externa.

El método se organiza como una **secuencia de etapas bien delimitadas** (Figura 2.1), cada una con una entrada y una salida claras. Esta descomposición no es meramente expositiva: es la que da pie a la re-implementación modular descrita en la Sección 2.4, donde cada etapa se aísla en un componente independiente. A continuación se describe primero el flujo de trabajo de forma general y, después, se detallan sus dos pilares estadísticos, el Análisis de Componentes Principales Circular (CPCA) y el modelo FMM además de las aportaciones que CIRCUST introduce frente a los métodos previos.

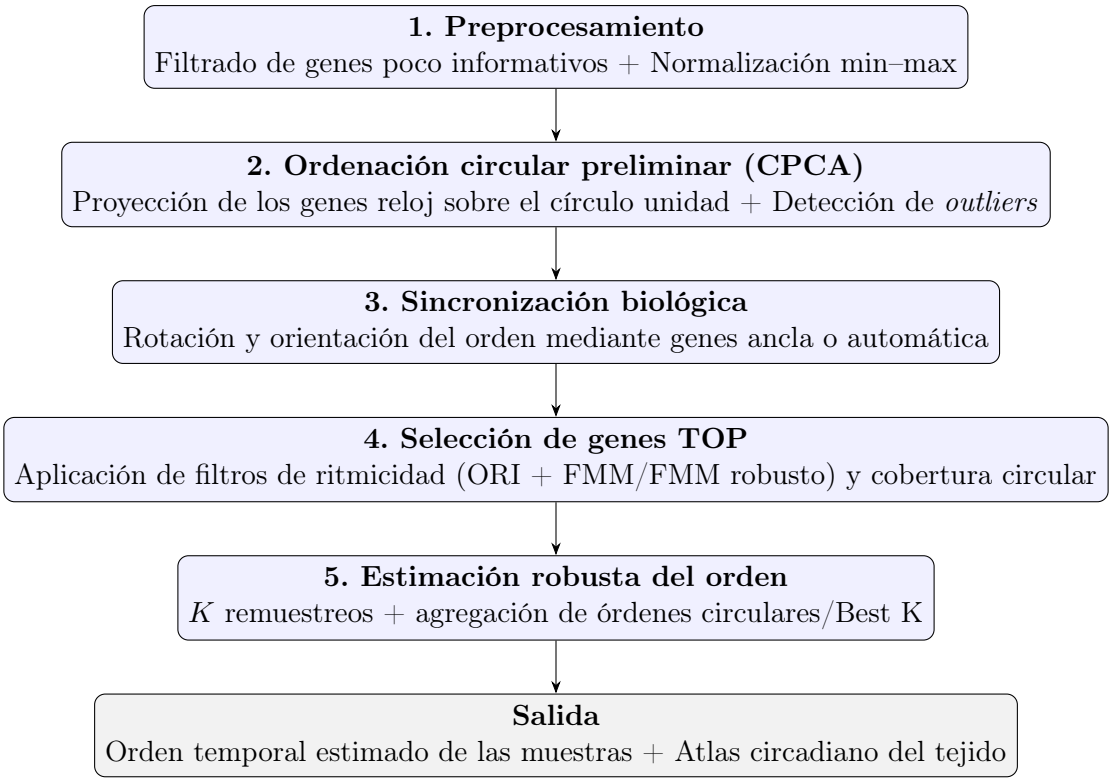


Figura 2.1: Flujo de trabajo del algoritmo CIRCUST. Cada etapa transforma la salida de la anterior; los dos pilares estadísticos son el CPCA (etapa 2) y el modelo FMM, presente en las etapas 2, 4 y 5.

2.1.1. Visión general del flujo de trabajo

Las etapas que componen el algoritmo son las siguientes:

1. **Preprocesamiento:** Se descartan los genes poco informativos, es decir, aquellos con una fracción de valores nulos o ausentes por encima de un umbral especificado y se aplica una normalización *min–max* gen a gen, que lleva la expresión de cada gen al intervalo $[-1, 1]$. Con ello todos los genes contribuyen en una escala común y se evita que los de mayor varianza absoluta dominen el análisis posterior.

2. **Ordenación circular preliminar mediante CPCA:** Sobre un subconjunto reducido de *genes reloj* centrales se aplica un Análisis de Componentes Principales Circular [28]. Los dos primeros componentes proyectan cada muestra sobre el plano, y su posición angular respecto al origen proporciona un primer orden circular de todas las muestras. En esta misma etapa se detectan y eliminan muestras anómalas (*outliers*).

3. **Sincronización biológica:** El orden que devuelve el CPCA es correcto salvo una rotación y un sentido de giro arbitrarios. Esta etapa fija ambos grados de libertad anclando la escala a genes de fase conocida, de modo que el orden circular pase a estar alineado con el tiempo biológico real.

4. **Selección de genes TOP:** No todos los genes son rítmicos. Esta etapa identifica el subconjunto de genes que oscilan de forma fiable sobre el orden estimado, combinando dos criterios de bondad de ajuste (los modelos ORI y FMM) y exigiendo que sus picos cubran de forma razonable todo el ciclo.

5. **Estimación robusta del orden:** Para reducir la dependencia de un único subconjunto de genes, el orden se reestima K veces sobre remuestreos de los genes TOP y los resultados se consolidan en un orden de consenso. Esta etapa concentra una de las aportaciones del trabajo (que se detallan más adelante en este mismo capítulo) y se apoya en técnicas de agregación de órdenes circulares.

El resultado final es, por un lado, el **orden temporal de las muestras** (una fase $\varphi_i \in [0, 2\pi)$, traducible a horas) y, por otro, el **atlas circadiano** del tejido: para cada gen rítmico, sus parámetros estimados (amplitud, fase del pico, asimetría y bondad de ajuste).

2.1.2. Los genes reloj de partida

Antes de detallar las etapas conviene presentar el ingrediente que varias de ellas comparten, el conjunto de *genes reloj* de partida, también llamados genes semilla o genes *core*. CIRCUST no trabaja con los miles de genes de la matriz de expresión, sino con un subconjunto reducido y fijo de genes del reloj circadiano cuya expresión está bien caracterizada. La lista por defecto la forman los doce genes del *core clock*: *PER1–3*, *CRY1–2*, *ARNTL*, *CLOCK*, *NR1D1*, *RORA*, *DBP*, *TEF* y *STAT3*. Esta selección recoge genes identificados como rítmicos en atlas de expresión circadiana de mamíferos y humanos [9, 30, 37, 42, 43]. El carácter rítmico de *STAT3*, menos evidente que el del resto, se ha documentado además en sangre humana [46, 47].

La elección tiene una justificación estadística. Estos genes son rítmicos por construcción biológica, ya que forman parte del bucle de retroalimentación que gobierna el reloj molecular (el *core clock* descrito en la Introducción). Por ello, la principal fuente de variación entre sus perfiles de expresión es la hora del día, y restringir el análisis a ellos concentra la señal circadiana frente al ruido de fondo de los genes no rítmicos.

Estos genes intervienen en dos etapas del algoritmo con papeles distintos. En la ordenación preliminar actúan como semilla del CPCA, que calcula la proyección circular únicamente sobre su submatriz. En la sincronización, un subconjunto de ellos, de fase conocida, actúa como ancla. En concreto, *ARNTL* fija el origen de la escala y *DBP*, junto con *CRY1*, determina el sentido de giro (Sección 2.6.2).

El conjunto de genes de partida no está fijado en el código, sino que es un parámetro del método. Puede sustituirse por otras listas predefinidas o por una selección propia, adaptada al conjunto de datos o a la especie en estudio, lo que enlaza con la arquitectura

modular descrita en la Sección 2.4. En cualquier caso, la estimación es robusta frente a la elección concreta de la lista. Un análisis de sensibilidad que recalcula el orden dejando fuera un gen semilla cada vez muestra una correlación circular mediana de aproximadamente 0,969 entre el orden original y los recalculados [23], lo que indica que ningún gen individual condiciona el resultado. Por su papel en la sincronización, *ARNTL*, *DBP* y *CRY1* se mantienen siempre en el conjunto.

2.1.3. Ordenación circular mediante CPCA

El primer pilar de CIRCUST es la obtención de un orden circular preliminar. En lugar de aplicar el Análisis de Componentes Principales (PCA) a los miles de genes de la matriz, CIRCUST lo restringe a la submatriz de los genes reloj de partida presentados en la Sección 2.1.2. Concentrar el PCA en genes rítmicos por construcción biológica hace que las primeras componentes capturen la señal circadiana en vez del ruido de fondo.

A partir de la matriz normalizada de genes reloj, el CPCA extrae las dos primeras componentes principales y trata sus puntuaciones para cada muestra i como coordenadas en el plano, $(\mathrm{PC1}_i, \mathrm{PC2}_i)$. La posición angular de cada muestra respecto al origen define su fase preliminar:

$$\varphi_i = \operatorname{atan2}(\mathrm{PC2}_i,\ \mathrm{PC1}_i) \bmod 2\pi, \qquad \rho_i = \sqrt{\mathrm{PC1}_i^2 + \mathrm{PC2}_i^2}\,, \tag{2.1}$$

donde ρ_i es la distancia al origen. Ordenando las muestras por φ_i se obtiene el orden circular preliminar. La interpretación geométrica es directa: si la expresión de los genes reloj oscila a lo largo del día, las muestras se disponen sobre una circunferencia y su ángulo refleja el momento del ciclo en que fueron tomadas. La distancia ρ_i actúa además como medida de fiabilidad: una muestra muy próxima al origen ($\rho_i \approx 0$) no tiene una fase bien definida y es candidata a *outlier*. CIRCUST descarta tales muestras combinando este criterio radial con un segundo criterio basado en residuos atípicos del ajuste rítmico, y reejecuta el CPCA sobre los datos depurados. La formalización de la variante circular del PCA y la justificación de la proyección (2.1) se desarrollan en la Sección 2.3.

2.1.4. Sincronización con el tiempo biológico

El orden de la ecuación (2.1) es *circular*, y como tal queda indeterminado en dos aspectos: el origen ($\varphi = 0$ puede caer en cualquier punto del ciclo) y el sentido de avance (horario o antihorario son a priori equivalentes). Recuperar el tiempo biológico real exige fijar ambos. CIRCUST lo resuelve anclando la escala a genes de fase conocida: sitúa el pico de un *gen ancla* de fase bien caracterizada (por defecto *ARNTL*) en una posición de referencia de la escala, y emplea un segundo *gen de dirección* (por defecto *DBP*) para decidir la orientación, invirtiendo el sentido de giro cuando su pico cae en la mitad

incorrecta del ciclo. Tras esta operación, el orden circular deja de ser relativo y pasa a estar sincronizado con el reloj biológico. Esta etapa es, además, una de las que el presente trabajo amplía, al avanzar hacia una selección automática del ancla (más adelante en este mismo capítulo).

2.1.5. Modelado de la ritmicidad: del Cosinor al modelo FMM

Una vez ordenadas las muestras, CIRCUST modela la curva de expresión de cada gen a lo largo del ciclo para decidir si es rítmico y, en caso afirmativo, estimar sus parámetros. El enfoque clásico para datos circadianos es el modelo **Cosinor** [48], que ajusta una sinusoide:

$$y(t) = M + A\cos(t - \phi) + \varepsilon, \tag{2.2}$$

donde M es el nivel medio (*mesor*), A la amplitud y ϕ la fase del pico (*acrófase*). Su limitación es la rigidez: la ecuación (2.2) impone una onda perfectamente simétrica, mientras que la expresión de muchos genes circadianos presenta picos agudos y valles anchos (o viceversa). Forzar una sinusoide sobre esos perfiles asimétricos sesga la estimación del pico, y la alternativa habitual es añadir armónicos, gana flexibilidad a costa de sobreajustar el ruido.

CIRCUST adopta en su lugar el modelo **FMM** (*Frequency Modulated Möbius*) [27], que introduce la asimetría sin renunciar a la interpretabilidad. El FMM deforma el argumento del coseno mediante una transformación de Möbius del círculo:

$$y(t) = M + A\cos\Big(\beta + 2\arctan\big(\omega\,\tan\tfrac{t-\alpha}{2}\big)\Big) + \varepsilon, \tag{2.3}$$

con M el nivel medio, $A > 0$ la amplitud, α la localización de la región del pico, β un parámetro de forma y $\omega \in (0, 1]$ el parámetro que gobierna la *asimetría* de la onda. El comportamiento de ω es la clave del modelo: cuando $\omega = 1$ la transformación de Möbius se reduce a la identidad y la ecuación (2.3) recupera una onda cosenoidal simétrica, es decir, el modelo Cosinor es un caso particular del FMM, mientras que al disminuir ω hacia 0 la onda se vuelve progresivamente más asimétrica y apuntada. De este modo, un único parámetro adicional permite cubrir desde el coseno simétrico hasta picos marcadamente agudos, conservando una lectura directa de la fase y la amplitud. Las propiedades de la transformación de Möbius y el procedimiento de estimación de (2.3) se detallan en la Sección 2.3.

2.1.6. Selección de genes rítmicos y orden robusto

La calidad del orden final depende de que se construya sobre genes genuinamente rítmicos. CIRCUST cuantifica la ritmicidad de cada gen mediante coeficientes de deter-

minación R^2, que miden la fracción de variabilidad explicada por el ajuste rítmico,

$$R^2 = 1 - \frac{\sum_i \left(y_i - \hat{y}_i\right)^2}{\sum_i \left(y_i - \bar{y}\right)^2}, \tag{2.4}$$

y combina dos modelos complementarios. Por un lado, el enfoque no paramétrico **ORI** (*Order Restricted Inference*) [29], que describe la oscilación mediante restricciones de desigualdad (un patrón unimodal de subida y bajada) sin imponer una forma funcional concreta, el modelo paramétrico FMM de la ecuación (2.3). Se seleccionan como **genes TOP** aquellos cuya expresión es bien explicada por ambos modelos (R^2 por encima de un umbral especificado en cada uno) y que, además, no producen ondas degeneradas (se exige un valor mínimo de ω). Para que el orden quede bien determinado a lo largo de todo el ciclo se impone también que los picos de los genes seleccionados cubran de forma equilibrada las distintas regiones de la circunferencia. El uso conjunto de un criterio no paramétrico (ORI) y otro paramétrico (FMM) hace la selección más exigente: solo sobreviven los genes cuyo carácter rítmico es robusto frente al tipo de modelo empleado.

Finalmente, para que la estimación no dependa de un subconjunto concreto de genes, CIRCUST reestima el orden sobre varios remuestreos de los genes TOP y consolida los resultados en un orden de consenso. El refinamiento de esta última etapa, mediante técnicas de agregación de órdenes circulares, constituye una de las aportaciones de este trabajo y se desarrolla más adelante en este mismo capítulo.

2.1.7. Aportaciones de CIRCUST frente a los métodos previos

Una vez descrito el flujo de trabajo, conviene situar a CIRCUST respecto a los métodos que lo precedieron, que se detallan en la Sección 2.2. Las diferencias no son solo de rendimiento, sino de filosofía e implementación y pueden agruparse en cuatro aportaciones.

Transparencia e interpretabilidad estadística. La aportación más característica de CIRCUST es que cada etapa es un procedimiento estadístico con una lectura explícita. Las componentes de la ecuación (2.1) son las direcciones de máxima varianza de los genes reloj, los parámetros de la ecuación (2.3) son la amplitud, la fase y la asimetría de cada gen y el R^2 de la ecuación (2.4) es una bondad de ajuste interpretable. Frente a ello, los métodos basados en *autoencoders* como CYCLOPS o PENN comprimen la señal en un espacio latente cuyos pesos no admiten una interpretación biológica directa: aciertan a ordenar las muestras, pero no ofrecen una trazabilidad estadística de *por qué* lo hacen. Esta transparencia tiene además una consecuencia práctica determinante para este trabajo: permite intervenir, sustituir o reforzar etapas concretas (por ejemplo, la función de pérdida del ajuste FMM o la regla de sincronización) sin desmontar el método completo.

Descomposición modular del problema. CIRCUST aborda la reconstrucción del orden temporal descomponiéndola en subproblemas estadísticos bien delimitados; reducción de dimensionalidad, sincronización, selección de genes y agregación de órdenes. En lugar de resolverla de un solo paso con un modelo monolítico, como hace un autoencoder entrenado de extremo a extremo. Esta modularidad conceptual facilita razonar sobre cada etapa por separado, diagnosticar dónde falla la estimación y reemplazar componentes de forma aislada. Es también el principio que vertebra la re-implementación desarrollada en este trabajo (Sección 2.4), que materializa cada etapa en un módulo independiente, frente al *script* monolítico de la versión original.

Flexibilidad del modelo FMM frente a la rigidez del Cosinor. A diferencia del enfoque clásico Cosinor (ecuación (2.2)), que impone una sinusoide simétrica, el modelo FMM (ecuación (2.3)) captura los picos asimétricos característicos del transcriptoma a través del parámetro ω, recuperando el coseno como caso particular ($\omega = 1$). Logra así un equilibrio que los armónicos múltiples no alcanzan: gana flexibilidad para representar formas de onda complejas sin incurrir en el sobreajuste que provoca añadir términos, y conserva una interpretación directa de la fase del pico, que es precisamente la magnitud de interés biológico.

Sincronización explícita con el tiempo biológico. CIRCUST incorpora una etapa dedicada a alinear el orden circular indeterminado en origen y sentido con el reloj biológico, mediante genes ancla de fase conocida (Sección 2.1.4). Este paso resuelve de forma explícita y trazable un problema que los métodos previos tratan de manera implícita o lo dejan sin abordar: los *autoencoders* (CYCLOPS, PENN) entregan una fase relativa que requiere realineamiento posterior, y CHIRAL afronta la coherencia entre tejidos de un mismo donante pero no la sincronización con un marco temporal absoluto a partir de genes de referencia. Disponer de esta etapa como un componente propio es, además, lo que hace viable extenderla hacia una selección automática del ancla, una de las aportaciones de este trabajo.

Otras observaciones. Conviene señalar, por último, dos rasgos transversales. El primero es la *robustez*, recogida en el propio nombre del método (*CIRCular-robUST*): la detección de *outliers* en la etapa de CPCA y la reestimación del orden sobre múltiples remuestreos de genes buscan que el resultado no dependa de muestras anómalas ni de una selección concreta de genes. El segundo es su *aplicabilidad en escenarios de pocos datos*: al no requerir el entrenamiento de una red neuronal, CIRCUST no sufre el sobreajuste típico de esos modelos cuando el número de muestras es reducido, y opera sobre un solo tejido sin necesitar la estructura multi-tejido que CHIRAL aprovecha. Estos rasgos lo hacen especialmente adecuado para las cohortes pequeñas y heterogéneas habituales en

transcriptómica humana.

2.2. Otros métodos de estimación del orden temporal

CIRCUST no es el único método que aborda la reconstrucción del orden temporal. Conviene situarlo frente a las principales alternativas, presentadas ya de forma previa en la Introducción, ahora con algo más de detalle pero sin entrar en su formulación completa. El propósito es entender en qué se distinguen, qué supuestos hacen y dónde residen sus limitaciones, lo que justifica las aportaciones de este trabajo.

Una primera distinción separa los enfoques *supervisados* de los *no supervisados*. Los métodos supervisados como ZeitZeiger [49] o TimeSignature [50] aprenden la relación entre expresión y hora del día a partir de un conjunto de entrenamiento con etiquetas temporales conocidas y predicen después la fase de muestras nuevas. Son precisos cuando se dispone de ese material de entrenamiento, pero resultan inaplicables al escenario que motiva este trabajo: en tejido humano post-mortem no existen etiquetas temporales fiables con las que entrenar. Por ello el interés se concentra en los métodos *no supervisados*, que reconstruyen el orden a partir únicamente de la estructura interna de los datos de expresión. Dentro de estos, la familia dominante es la basada en redes neuronales, junto a la de CIRCUST, de base estadística clásica.

2.2.1. Métodos basados en *autoencoders*: CYCLOPS y PENN

CYCLOPS (*CYclic Ordering by Periodic Structure*) [30] es el método de referencia de esta familia. Su punto de partida es una observación clásica sobre los datos de expresión periódicos: al descomponerlos en valores singulares se obtienen unos patrones característicos (los *eigengenes*), y los primeros de ellos se comportan como oscilaciones sinusoidales desfasadas entre sí. Representadas dos de esas oscilaciones una frente a otra, las muestras se disponen aproximadamente sobre una *elipse*, y su posición angular sobre esa elipse proporciona el orden de las muestras dentro del ciclo, con independencia de la hora real de recogida.

CYCLOPS aprende esa estructura elíptica mediante un *autoencoder*: una red neuronal entrenada para reproducir en su salida la misma entrada que recibe, obligada a comprimir la información en una capa intermedia (*cuello de botella*) de dimensión reducida. La particularidad de CYCLOPS es que ese cuello de botella es un *nodo circular*, implementado como dos neuronas acopladas (u_i, v_i) que se proyectan sobre el círculo unidad; la fase asignada a cada muestra i es entonces el ángulo

$$\varphi_i = \operatorname{atan2}(v_i,\ u_i) \in [0, 2\pi). \tag{2.5}$$

La red se entrena minimizando el error de reconstrucción entre su entrada y su salida;

tras varios reinicios aleatorios se conserva la solución con menor error. El paralelismo con CIRCUST es notable, ambos reducen la dimensionalidad y proyectan las muestras sobre una circunferencia para leer su fase como un ángulo (compárese con la ecuación (2.1)), pero CYCLOPS realiza esa proyección de forma no lineal y no interpretable, mientras que el CPCA lo hace con una transformación lineal trazable.

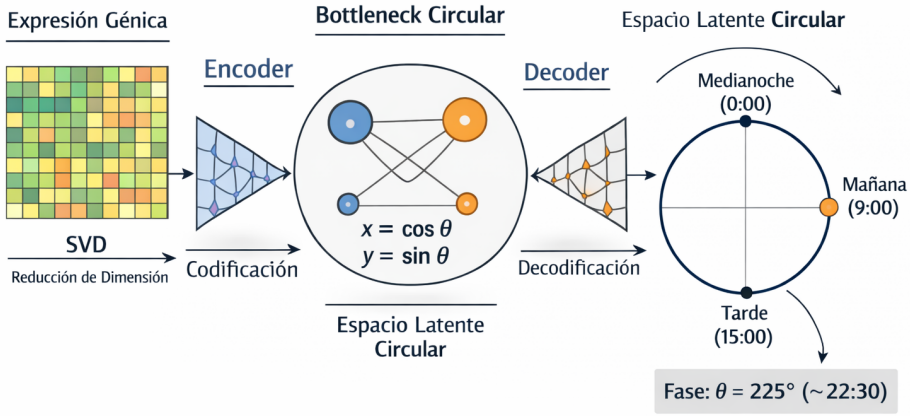


Figura 2.2: Arquitectura resumida del *autoencoder* de cuello de botella circular empleado en CYCLOPS. La red comprime la expresión en un único nodo circular, cuya fase ordena las muestras.

Conviene señalar tres rasgos de CYCLOPS que condicionan su uso. Primero, requiere que las muestras cubran todo el ciclo para que la elipse quede bien definida y, en la práctica, un número elevado de ellas (sus autores estiman que del orden de varios cientos). Segundo, el orden que produce es *relativo*: no fija ni el origen ni el sentido, por lo que necesita información externa para anclarlo al tiempo biológico (en sus aplicaciones, los autores fijan el origen con la fase media de un grupo de factores de transcripción de fase conocida). Tercero, al derivarse la fase de los propios datos de expresión, los contrastes de ritmicidad posteriores tienden a ser demasiado liberales, lo que obliga a usar umbrales de significación más estrictos.

Su evolución, **CYCLOPS 2.0** [31], mantiene esta arquitectura y añade una **corrección de covariables**: mediante una codificación *multi-hot* que indica qué factores (tejido, lote de laboratorio, características del paciente) afectan a cada muestra, ajusta los datos de entrada para atenuar esas fuentes de variación ajenas al ritmo antes de comprimirlos en el cuello de botella, y revierte el ajuste tras la reconstrucción.

PENN (*Phase Estimation Neural Network*) [32] comparte el esqueleto de CYCLOPS reducción previa de la dimensionalidad mediante componentes principales y un *autoen-*

coder con un nodo circular que asigna la fase según la ecuación (2.5), pero modifica el criterio de entrenamiento. CYCLOPS solo minimiza el error de reconstrucción y, por tanto, no aprovecha que la expresión de los genes rítmicos debe describir una curva periódica al ordenarse por fase. PENN incorpora esa información añadiendo un segundo término a la función de pérdida, que exige que cada gen se ajuste a una onda cosenoidal cuando las muestras se colocan en el orden estimado:

$$\mathcal{L} = \underbrace{\frac{1}{m}\sum_{i=1}^{m}\left\|x_i - \hat{x}_i\right\|^2}_{\text{reconstrucción}} + \lambda \underbrace{\frac{1}{m}\sum_{i=1}^{m}\frac{1}{n}\sum_{g=1}^{n}\left(x_i^{(g)} - \hat{y}_i^{(g)}\right)^2}_{\text{ajuste a coseno}}, \tag{2.6}$$

donde $\hat{x}_i$ es la reconstrucción de la muestra x_i, $\hat{y}_i^{(g)}$ es el valor predicho para el gen g por una curva cosenoidal de la fase estimada y λ pondera ambos objetivos. Esta regularización geométrica estabiliza la estimación y, según sus autores, mejora la precisión del orden frente a CYCLOPS sin alterar la arquitectura básica. Aun así, comparte con él la naturaleza de caja negra: la fase se obtiene de los pesos de una red, sin una lectura estadística directa.

2.2.2. Métodos para datos multi-tejido: CHIRAL

Por último, **CHIRAL** [35] responde a un escenario distinto: el de los grandes atlas multi-tejido, como GTEx, en los que de cada donante se dispone de muestras de varios órganos. En lugar de tratar todos los tejidos como un único bloque, CHIRAL opera de forma jerárquica: estima primero una fase interna específica de cada tejido a partir de sus genes reloj y la integra después, para los tejidos de un mismo donante, en una fase interna global del individuo. Así separa la variabilidad propia de cada tejido de la fase circadiana sistémica del donante. Su contrapartida es que esa misma fortaleza lo hace dependiente de la estructura multi-tejido: pierde eficacia en estudios de un solo tejido o en cohortes pequeñas, donde no existe esa jerarquía sobre la que apoyar la estimación.

2.3. Fundamentos matemáticos de CPCA y FMM

Las secciones anteriores han descrito CIRCUST y sus alternativas a un nivel operativo. Esta sección desarrolla las herramientas matemáticas que sustentan el método y, con ellas, las aportaciones de las secciones siguientes. Se parte de unos preliminares de estadística circular que fijan la notación, se formaliza después la ordenación circular mediante CPCA y, por último, se presentan los dos modelos de ritmicidad que emplea CIRCUST: el paramétrico FMM y el no paramétrico ORI.

2.3.1. Preliminares de estadística circular

El rasgo distintivo del problema es que el tiempo se representa sobre una circunferencia, no sobre una recta. Un instante del ciclo se codifica como un ángulo $\theta \in [0, 2\pi)$, identificado con el punto $(\cos\theta, \sin\theta)$ del círculo unidad; la hora 0 y la hora 24 son el mismo punto. Esto obliga a sustituir los estadísticos lineales habituales por sus análogos circulares.

Dirección media y concentración. La media aritmética de un conjunto de ángulos no es un buen resumen (el promedio de 1° y 359° debería ser 0°, no 180°). En su lugar se promedian los vectores unitarios asociados. Dados $\theta_1, \ldots, \theta_n$, se define el *vector resultante medio* a partir de

$$C = \sum_{i=1}^{n} \cos\theta_i, \qquad S = \sum_{i=1}^{n} \sin\theta_i, \tag{2.7}$$

de donde la *dirección media* y la *longitud resultante media* son

$$\bar{\theta} = \operatorname{atan2}(S, C), \qquad \bar{R} = \frac{\sqrt{C^2 + S^2}}{n} \in [0, 1]. \tag{2.8}$$

La dirección media $\bar{\theta}$ es el centro del conjunto de ángulos, y $\bar{R}$ mide su *concentración*: vale 1 cuando todos los ángulos coinciden y se acerca a 0 cuando se reparten de forma uniforme por el círculo.

Orden circular. Ordenar n muestras según su ángulo produce un *orden circular*: una disposición cíclica en la que no hay primero ni último, sino solo posiciones relativas sobre la circunferencia. Dos consecuencias son centrales para todo el trabajo. Primera, el orden circular queda determinado únicamente *salvo una rotación* (el origen es arbitrario) *y una reflexión* (el sentido de giro, horario o antihorario, es a priori intercambiable), fijar ambos grados de libertad es el problema de sincronización, del que se ocupa la Sección 2.6. Segunda, la distancia natural entre dos ángulos no es $|\,\alpha - \beta\,|$, sino la distancia geodésica sobre el círculo,

$$d(\alpha, \beta) = \min\left(|\alpha - \beta|,\ 2\pi - |\alpha - \beta|\right) \in [0, \pi], \tag{2.9}$$

que es la que emplean las técnicas de agregación y validación de las Secciones 2.7 y 2.8.

Otras herramientas de estadística circular se introducen más adelante, allí donde se emplean: la distribución de von Mises como núcleo de ponderación temporal en la Sección 2.5 y los coeficientes de correlación circular para evaluar reconstrucciones del orden en la Sección 2.8.

2.3.2. Ordenación circular mediante CPCA

El primer pilar de CIRCUST es el Análisis de Componentes Principales Circular (CP-CA) [28], un método previo que el algoritmo adopta sin modificarlo. Su función es reducir

la dimensionalidad de la expresión de los genes reloj para obtener un orden circular de las muestras. Para ello aplica un Análisis de Componentes Principales a esa submatriz, toma los dos primeros componentes como coordenadas de cada muestra en el plano y lee su posición angular como fase, según la proyección ya presentada en la ecuación (2.1).

La razón de que esa proyección recupere el tiempo se entiende a partir de la forma de la señal. Si un gen reloj oscila de modo aproximadamente sinusoidal a lo largo del día, su expresión en una muestra tomada en el instante t puede escribirse como

$$x_g(t) = a_g \cos(t - \phi_g) = a_g \cos\phi_g \, \cos t + a_g \sin\phi_g \, \sin t, \tag{2.10}$$

esto es, como una combinación lineal de las mismas dos señales, $\cos t$ y $\sin t$, sea cual sea su fase ϕ_g. En ausencia de ruido, la matriz de los genes reloj tiene por tanto rango dos y toda su información esencial vive en un plano. El Análisis de Componentes Principales identifica precisamente ese plano de máxima variación. Sus dos primeros componentes se comportan como dos oscilaciones en cuadratura, de manera que las muestras se sitúan sobre una elipse y su ángulo reproduce el instante del ciclo.

De ahí la proyección sobre el círculo unidad de la ecuación (2.1). La fase de cada muestra es su ángulo φ_i y su distancia al origen ρ_i mide la fiabilidad de esa fase. Ordenar las muestras por φ_i produce el orden circular preliminar. Las muestras con ρ_i próximo a cero carecen de una fase bien definida y se tratan como *outliers*. El problema que resuelve el CPCA es, en consecuencia, doble. Convierte una matriz de expresión de alta dimensión en un único orden circular interpretable y proporciona a la vez un criterio de calidad por muestra.

2.3.3. El modelo FMM

El segundo pilar es el modelo de ritmicidad. El enfoque clásico, el Cosinor [48] de la ecuación (2.2), ajusta una sinusoide simétrica, su rigidez sesga la estimación cuando los genes presentan picos asimétricos y la alternativa de añadir armónicos tiende a sobreajustar el ruido. CIRCUST adopta en su lugar el modelo FMM (*Frequency Modulated Möbius*) [27], también un método previo del que aquí solo interesa su aportación.

El FMM, presentado en la ecuación (2.3), deforma el argumento del coseno mediante una transformación de Möbius del círculo, gobernada por un parámetro de asimetría ω. Con ello ataca justamente el problema del Cosinor: captura formas de onda asimétricas y apuntadas (recuperando el coseno simétrico como caso particular, $\omega = 1$) sin renunciar a una interpretación directa de sus parámetros; nivel medio, amplitud, fase del pico y asimetría. Y sin el sobreajuste asociado a los modelos multiarmónicos. El modelo se ajusta por mínimos cuadrados, es precisamente esa función de pérdida la que la Sección 2.5 sustituye por un criterio penalizado más robusto, que constituye una de las aportaciones de este trabajo.

2.3.4. Inferencia con restricciones de orden (ORI)

El modelo FMM impone una forma funcional concreta. Como contrapeso, CIRCUST emplea además un criterio *no paramétrico* que solo asume que la expresión sigue un patrón *unimodal* a lo largo del ciclo (sube hasta un máximo y luego baja), sin fijar ninguna ecuación. Es la Inferencia con Restricciones de Orden (ORI) [29]: dada la expresión ordenada por fase, se busca la curva que mejor la ajusta sujeta a la restricción de unimodalidad, mediante regresión isotónica (algoritmo *pool adjacent violators* PAVA). La calidad del ajuste se cuantifica de nuevo con un coeficiente de determinación,

$$R^2_{\mathrm{ORI}} = 1 - \frac{\mathrm{SSE}_{\mathrm{unimodal}}}{\mathrm{SSE}_{\mathrm{constante}}}, \tag{2.11}$$

que compara el error del ajuste unimodal con el de un modelo plano (sin ritmo). Disponer de un criterio paramétrico (FMM) y otro no paramétrico (ORI) hace más exigente la selección de genes rítmicos descrita en la Sección 2.1.6, un gen solo se considera fiable si ambos coinciden en que oscila, lo que reduce el riesgo de seleccionar artefactos dependientes del modelo.

2.4. Mejora de CIRCUST: implementación modular y eficiencia

Las aportaciones metodológicas de las secciones siguientes se apoyan en un objetivo de soporte que conviene presentar antes, la re-implementación de CIRCUST en Python. La versión original es un *script* monolítico en R, en el que todas las etapas comparten un mismo flujo de código y resulta difícil de probar, extender o paralelizar (Sección **??**). La re-implementación persigue dos metas complementarias. La primera es una arquitectura modular que aísle cada etapa del algoritmo. La segunda es una mejora del rendimiento que aproveche el ecosistema numérico de Python. Ambas se describen a continuación.

2.4.1. Estructura modular

La idea principal es traducir la descomposición conceptual del método (Figura 2.1) en una descomposición real del código. Cada etapa del algoritmo se encapsula en un componente independiente, implementado como una clase con un método `run()` que recibe la salida de la etapa anterior y devuelve un objeto de resultado bien definido. Así, el preprocesamiento, la selección de genes reloj, el CPCA, la sincronización, la selección de genes TOP y la estimación robusta del orden viven cada uno en su propio módulo, y un orquestador se limita a encadenarlos. Los datos que circulan entre etapas no son variables sueltas, sino estructuras de resultado explícitas, lo que hace inequívoco qué produce y qué

consume cada componente.

Esta separación se extiende a los modelos de ritmicidad, que se agrupan en un subpaquete propio bajo una interfaz común. Todos los modelos (el FMM en sus variantes base y robusta, el Cosinor y el ORI) comparten un mismo contrato, una clase base abstracta con un método `fit()` y un contenedor de resultados homogéneo. De este modo, cualquier punto del algoritmo que necesite ajustar una curva puede usar uno u otro modelo sin cambios en el resto del código, lo que resulta esencial para introducir el FMM robusto de la Sección 2.5 como una pieza intercambiable.

La arquitectura prevé además varios puntos de configuración que permiten alterar el comportamiento del algoritmo sin reescribirlo. Se puede seleccionar la variante del modelo FMM, el método con que se elige el orden robusto, la técnica de agregación de órdenes o el conjunto de genes reloj de partida, todo ello como opciones y no como modificaciones del código. Por último, la implementación separa el cálculo de las tareas accesorias. El núcleo de cómputo no se ocupa de la entrada y salida, que se limita a volcar los resultados a ficheros, y tanto la visualización como la validación residen en módulos aparte. El conjunto se distribuye como un paquete instalable y se acompaña de pruebas unitarias.

El resultado es un sistema testable, reutilizable y extensible, en el que una etapa puede probarse de forma aislada, reemplazarse por una variante o paralelizarse sin afectar a las demás. Es justamente lo que el *script* monolítico original no permitía.

2.4.2. Eficiencia en Python

Python es un lenguaje interpretado y, por sí solo, más lento que R o C en los bucles numéricos intensivos. La eficiencia de esta implementación descansa, por tanto, en tres estrategias que evitan ejecutar esos bucles en Python puro.

La primera es la **vectorización**. Las operaciones se expresan como álgebra matricial sobre arreglos completos en lugar de bucles elemento a elemento, y se delegan en bibliotecas numéricas compiladas. El CPCA, por ejemplo, se reduce a una descomposición en valores singulares resuelta por rutinas optimizadas de LAPACK, y el paso lineal del ajuste FMM es un problema de mínimos cuadrados igualmente vectorizado.

La segunda es la **compilación al vuelo** (JIT). La parte más costosa del ajuste FMM es la búsqueda en rejilla, en la que el modelo y su función objetivo se evalúan miles de veces por cada gen. Esas funciones internas se compilan a código máquina con Numba, lo que elimina la sobrecarga del intérprete en el bucle crítico. La misma técnica se aplica al ajuste ORI. De forma opcional, y dado que cada punto de la rejilla es independiente de los demás, la búsqueda puede ejecutarse en GPU mediante CUDA cuando hay una disponible.

La tercera es la **paralelización**, que se aplica en los dos lugares donde el trabajo se reparte de forma natural. Por un lado, los ajustes de los distintos genes en la selección de

genes TOP se distribuyen entre los núcleos del procesador. Por otro, las K repeticiones de la estimación robusta del orden, que son independientes entre sí, se ejecutan en paralelo. El tipo de paralelismo se elige según la naturaleza del cálculo. Cuando el trabajo libera el bloqueo global del intérprete, como ocurre con el FMM robusto al apoyarse en rutinas BLAS y en núcleos compilados con Numba, basta con hilos que comparten en memoria las matrices ya precalculadas y se evita el coste de serializar datos entre procesos. En caso contrario se recurre a procesos independientes.

A estas tres estrategias se añade el **precálculo y reutilización** de resultados intermedios. En el FMM robusto, la rejilla y las matrices auxiliares se calculan una sola vez y se reutilizan para todos los genes, y el parámetro de penalización se calibra una única vez y se propaga a las etapas posteriores en lugar de recomputarse. El efecto conjunto de estas decisiones es una reducción sustancial del tiempo de cómputo frente a una traducción directa del algoritmo original.

2.5. Modelo FMM robusto

La primera aportación metodológica del trabajo es una versión robusta del ajuste FMM, concebida para estabilizar la estimación cuando los datos son escasos, ruidosos o de muestreo temporal irregular, condiciones habituales en las cohortes post-mortem humanas. La idea es modificar el modo en que se ajusta el modelo de la Sección 2.3.3, sin alterar su forma funcional, de manera que el ajuste resulte menos sensible al ruido y al desequilibrio en la distribución de las muestras.

El ajuste FMM base estima los parámetros por mínimos cuadrados, esto es, minimizando la suma de residuos al cuadrado. Ese criterio presenta dos debilidades cuando los datos son escasos o ruidosos. La primera es que tiende a sobreajustar el ruido, produciendo ondas muy apuntadas que se ciñen a las observaciones concretas pero no al ritmo subyacente. La segunda es que trata todas las muestras por igual, de modo que las regiones del ciclo con muchas muestras dominan el ajuste mientras que las poco muestreadas apenas influyen, un problema frecuente cuando el muestreo temporal es irregular. El FMM robusto ataca ambas debilidades a la vez. Sustituye la función de pérdida por un criterio de potencia penalizado y pondera las muestras según su densidad temporal.

Ponderación por densidad temporal. Para que ninguna zona del ciclo pese más que otra por el mero hecho de estar más muestreada, a cada muestra i se le asigna un peso inversamente proporcional a la densidad de muestras en su instante. Esa densidad se estima con un núcleo de von Mises (la distribución circular de la ecuación (**??**)) centrado

en cada muestra,

$$\hat{f}(t) = \frac{1}{n\, 2\pi\, \mathrm{I}_0(\kappa)} \sum_{j=1}^{n} \exp\big(\kappa \cos(t - t_j)\big), \qquad w_i \propto \frac{1}{\hat{f}(t_i)}, \tag{2.12}$$

con los pesos reescalados para que $\sum_i w_i = n$. El parámetro de concentración κ se elige de forma automática por validación cruzada dejando uno fuera. Así, las muestras situadas en tramos del ciclo poco representados reciben más peso, lo que compensa los muestreos irregulares.

Criterio de potencia penalizado. El núcleo de la propuesta es reemplazar la minimización del error por la maximización de un criterio que premia el ajuste y castiga la complejidad de la onda. Fijados los parámetros no lineales (α, ω), que determinan la fase de Möbius $\varphi_i = \varphi(t_i; \alpha, \omega)$, el criterio es

$$J(\alpha, \omega) = P(\alpha, \omega) - \lambda\, g(\omega)\, R(\alpha, \omega). \tag{2.13}$$

El primer término, P, es la potencia de un periodograma ponderado en la forma de Lomb–Scargle,

$$P(\alpha, \omega) = \frac{u^2 + v^2}{D}, \qquad \text{con} \quad \begin{aligned} u &= \sum_i w_i\, (x_i - \bar{x}_w) \cos\varphi_i, \\ v &= \sum_i w_i\, (x_i - \bar{x}_w) \sin\varphi_i, \\ D &= \sum_i w_i \cos^2\varphi_i + \sum_i w_i \sin^2\varphi_i, \end{aligned} \tag{2.14}$$

donde $\bar{x}_w$ es la media ponderada de la expresión. La potencia P mide cuánta señal rítmica captura la onda definida por (α, ω) y desempeña el papel que en el FMM base tenía el ajuste por mínimos cuadrados. De hecho, en ausencia de pesos y penalización, maximizar P equivale a minimizar la suma de residuos al cuadrado. El segundo término penaliza la *rugosidad*. La cantidad $R(\alpha, \omega)$ mide la curvatura de la onda ajustada a través de las segundas derivadas de sus componentes, de manera que las ondas muy onduladas o apuntadas, propias del sobreajuste, reciben un castigo mayor. El factor $g(\omega) = \big(\omega_0/(\omega + \omega_0)\big)^p$ refuerza esa penalización a medida que ω disminuye, es decir, precisamente en las formas más apuntadas, que son las más propensas a sobreajustar. El parámetro λ gradúa el equilibrio entre ajuste y suavidad. Una vez localizado el máximo de J sobre una rejilla de valores de (α, ω), con un refinamiento local posterior, los parámetros lineales restantes (mesor, amplitud y forma) se obtienen en forma cerrada por mínimos cuadrados ponderados.

Calibración de la penalización. Queda por fijar λ. Un valor demasiado pequeño no corrige el sobreajuste, y uno demasiado grande aplana ritmos reales. La propuesta lo calibra de forma automática bajo la hipótesis nula de ausencia de ritmo. Se simulan numerosas réplicas de datos planos, sin más señal que el ruido, y para cada valor candidato de λ se resume un cuantil alto del estadístico que detecta ondas apuntadas espurias. La curva de ese cuantil frente a λ decrece a medida que se penaliza más, y se elige el valor situado en su codo, el punto a partir del cual aumentar la penalización ya apenas reduce los picos falsos. Este λ calibrado se calcula una sola vez sobre el conjunto de datos y se reutiliza en todas las etapas que ajustan un FMM, como se anticipó en la Sección 2.4.2.

Estabilidad numérica. Por último, la implementación evalúa la fase de Möbius sin calcularla de forma explícita. En lugar de obtener φ y arriesgar la singularidad que la tangente introduce cuando $t - \alpha = \pi$, calcula directamente $\cos\varphi$ y $\sin\varphi$ mediante identidades del ángulo doble, cuyo denominador es una suma de cuadrados siempre positiva. Esto hace el ajuste numéricamente estable en todo el ciclo.

2.6. El problema de sincronización de órdenes circulares

La reconstrucción del orden temporal encadena en realidad dos problemas. El primero es estimar, a partir únicamente de la expresión, un orden circular de las muestras. El segundo, una vez obtenido ese orden, es anclarlo al tiempo biológico real, porque un orden circular no fija por sí solo ni dónde empieza el ciclo ni en qué sentido avanza. Esta sección formula ambos problemas y la ambigüedad que los conecta (Sección 2.6.1), y describe después el procedimiento de sincronización que resuelve el segundo (Sección 2.6.2).

2.6.1. Formulación del problema y los $2n$ órdenes

Partimos de la matriz de expresión $\mathbf{X} = [\mathbf{x}_1, \ldots, \mathbf{x}_n] \in \mathbb{R}^{G\times n}$ introducida en la Sección 2.1, cuyas n columnas son las muestras y cuyos tiempos de recogida $t_1, \ldots, t_n$ son desconocidos. Estimar el orden temporal equivale a hallar una permutación de las muestras,

$$\pi : \{1, \ldots, n\} \to \{1, \ldots, n\}, \tag{2.15}$$

tal que la matriz reordenada $\mathbf{X}_\pi = [\mathbf{x}_{\pi(1)}, \ldots, \mathbf{x}_{\pi(n)}]$ refleje la progresión temporal latente en los datos. Por la periodicidad del ciclo, el orden que induce esa permutación no es lineal sino circular. Siguiendo a Larriba et al. [51], el problema se plantea como una minimización,

$$\pi^* = \arg\min_{\pi} C(\mathbf{X}_\pi), \tag{2.16}$$

donde C es una función de coste, definida habitualmente en términos de distancias, que cuantifica cuánto se aparta cada permutación de la estructura oscilatoria esperada.

Resolver la minimización (2.16) de forma exacta no es viable. El número de órdenes circulares distintos para n muestras es $(n-1)!$, de modo que el problema es NP-hard y su exploración exhaustiva resulta imposible salvo para valores muy pequeños de n. Por ello se recurre a aproximaciones, como la basada en el Problema del Viajante de Comercio [51] o, en el caso de CIRCUST, la propia reducción de dimensionalidad mediante CPCA (Sección 2.3.2). En esta última, la proyección de las muestras sobre el círculo unidad asigna a cada una un ángulo φ_i, y la ordenación creciente de esos ángulos proporciona directamente un orden circular que se adopta como solución inicial π^*.

Ese orden circular es, sin embargo, *relativo*. La proyección del CPCA recupera la disposición cíclica de las muestras, pero no determina dos elementos que la expresión, por sí sola, no contiene. El primero es el punto de arranque del ciclo, es decir, el origen de la escala. El segundo es el sentido de giro, horario o antihorario. Para un orden circular de n muestras existen, en consecuencia, $2n$ configuraciones temporales compatibles, fruto de combinar las n posibles elecciones de origen con los 2 sentidos de avance. Todas representan el mismo orden relativo y son indistinguibles a partir de la expresión, ya que en los datos no hay ninguna referencia de tiempo absoluto.

Elegir, de entre esas $2n$ configuraciones, la que se corresponde con el tiempo biológico real es el problema de sincronización. Su resolución exige información externa, en concreto el conocimiento de la fase de algunos genes reloj cuya expresión temporal está bien caracterizada y que actúan como anclas. El procedimiento que fija el origen y el sentido a partir de esas anclas se desarrolla en la Sección 2.6.2.

2.6.2. Sincronización mediante genes ancla

De entre las $2n$ configuraciones compatibles con el orden circular estimado, la sincronización selecciona la que se corresponde con el tiempo biológico real. La versión actual del algoritmo lo resuelve apoyándose en un conjunto fijo de genes ancla y en tres supuestos biológicos bien establecidos [23].

El primer supuesto fija el origen. El pico del gen *ARNTL*, estimado mediante el modelo FMM, se sitúa en π. Como *ARNTL* alcanza su máximo en anticipación del periodo inactivo, esta convención permite interpretar el intervalo $[0, \pi)$ como periodo de luz inferido y $[\pi, 2\pi)$ como periodo de oscuridad. Los otros dos supuestos fijan el sentido de giro. Por un lado, el gen *DBP* alcanza su pico después de los genes de fase ROR (*ARNTL*, *NPAS*, *CLOCK*). Por otro, la mayoría de los genes reloj presentan su máximo durante el periodo activo $[0, \pi)$.

A partir de estos supuestos, el procedimiento opera en dos pasos. Primero rota la escala circular para que el pico de *ARNTL* quede en π, lo que ancla el origen. Después determina

la orientación con el gen de dirección *DBP*. Si su pico cae en la mitad incorrecta del ciclo respecto a *ARNTL*, se invierte el sentido de la escala. Una verificación de consistencia con el resto de genes reloj refina esa decisión, comprobando que la mayoría de sus picos caen en $[0, \pi)$ y que se respeta el orden esperado entre *DBP*, *CRY1* y *ARNTL*. El resultado es una escala circular alineada con el tiempo biológico, sobre la que cada gen reloj queda clasificado como diurno o nocturno según la posición de su pico.

Extensión futura: sincronización híbrida. El procedimiento anterior depende de un conjunto de genes ancla fijado de antemano. Una extensión natural es una sincronización híbrida que formule el anclaje como un problema de regresión circular, buscando la rotación y la orientación que maximizan la concordancia entre los instantes de máxima expresión estimados en el tejido objetivo (post mortem) y los de un tejido de referencia con etiqueta temporal (in vivo), inspirándose en la metodología del *molecular timetable* [52]. Este enfoque permitiría además automatizar la selección del ancla y reducir la dependencia de un gen prefijado. Su desarrollo se deja como trabajo futuro, a incorporar si el alcance del proyecto lo permite.

2.7. Ordenación agregada: orden de consenso

La estimación robusta del orden (Sección 2.1.6) no produce un único orden, sino K. CIRCUST reestima el orden circular sobre K subconjuntos aleatorios de los genes TOP, y cada repetición devuelve una ordenación de las muestras ligeramente distinta. En lugar de quedarse con una de ellas, esta aportación consolida las K ordenaciones en un único *orden de consenso*, lo que estabiliza la estimación final y reduce su dependencia de una selección concreta de genes. La herramienta para hacerlo es la agregación de órdenes circulares de Barragán, Rueda y Fernández [53].

Agregar órdenes sobre el círculo no equivale a promediarlos. La aproximación euclídea habitual, promediar las posiciones o aplicar el método de Borda, falla en este contexto porque el conjunto de vectores que satisfacen un orden circular no es convexo. Dos repeticiones pueden compartir el mismo orden circular y, aun así, la media de sus ángulos no respetarlo. Se necesita, por tanto, un criterio definido directamente sobre el círculo.

Sea $\theta^{(k)} = (\theta_1^{(k)}, \ldots, \theta_n^{(k)})$ el vector de fases que la repetición $k = 1, \ldots, K$ asigna a las n muestras. Para medir cuánto se ajusta una ordenación candidata O a esas fases, se emplea el estimador de regresión isotónica circular (CIRE), que es el vector $\tilde{\theta}^{(O,k)}$ más cercano a las observaciones de entre los que respetan el orden O, según la suma de errores circulares,

$$\tilde{\theta}^{(O,k)} = \arg\min_{\alpha \sim O} \sum_{i=1}^{n} \big(1 - \cos(\theta_i^{(k)} - \alpha_i)\big). \tag{2.17}$$

La distancia entre la repetición k y el orden O es el promedio de esos errores, conocido

como media de la suma de errores circulares (MSCE),

$$d(\theta^{(k)}, O) = \frac{1}{n} \sum_{i=1}^{n} \big(1 - \cos(\theta_i^{(k)} - \tilde{\theta}_i^{(O,k)})\big), \tag{2.18}$$

y el orden de consenso es el que minimiza la distancia agregada sobre las K repeticiones,

$$O^* = \arg\min_{O} \sum_{k=1}^{K} \omega_k \, d(\theta^{(k)}, O), \tag{2.19}$$

donde los pesos ω_k permiten dar más importancia a las repeticiones más fiables.

Igual que el problema de estimación del orden (Sección 2.6.1), esta minimización es NP-hard, por lo que se resuelve de forma aproximada en dos pasos. Primero se construye un orden inicial y después se refina con búsquedas locales que reordenan tríos de muestras consecutivas. Para el primer paso existen dos familias de métodos.

La primera, basada en información *por pares* y la única implementada por ahora, reduce el problema a un Problema del Viajante de Comercio (TSP). Cada repetición se representa como un grafo dirigido cuyos nodos son las muestras y cuyas aristas miden la preferencia de una muestra sobre otra. Al agregar esas aristas entre repeticiones, el orden de consenso es el recorrido más corto que visita cada muestra una sola vez. La variante empleada, **TSP3**, usa una distancia dirigida que penaliza con un factor $\alpha = 3$ los avances en el sentido equivocado. Su interpretación es intuitiva. Un viajero que rebasa una parada debe volver atrás y recorrer de nuevo el tramo, con lo que acaba cubriendo tres veces esa distancia.

La segunda familia, basada en información *por tríos* y propuesta como extensión futura, se apoya en la teoría de Hodge. Como un trío es el conjunto más pequeño que admite un orden sobre el círculo, esta representación es la natural para datos circulares y combina bien información de fuentes con orígenes distintos. El orden de consenso se obtiene resolviendo un problema de mínimos cuadrados sobre las preferencias entre tríos, y sus variantes, en particular HODs, son computacionalmente eficientes y robustas frente a datos incompletos. Según el estudio original [53], ningún método es uniformemente superior, pero TSP3 y HODs son los más competitivos.

En la implementación actual, el orden de consenso se calcula por defecto con TSP3, mientras que la variante de Hodge queda propuesta como trabajo futuro. Una vez fijado ese orden de consenso, se reajusta el modelo FMM sobre él para obtener los parámetros finales del atlas circadiano del tejido.

2.8. Marco de validación y métricas de similitud

(En desarrollo...)

Capítulo 3

Resultados y Simulaciones

(En desarrollo...)

Capítulo 4

Conclusiones y Trabajo Futuro

(En desarrollo...)

Bibliografía

[1] Takahashi, J. S. (2017). *Transcriptional architecture of the mammalian circadian clock*. Nature Reviews Genetics, 18(3):164–179. https://doi.org/10.1038/nrg.2016.150

[2] Halberg, F. (1969). *Chronobiology*. Annual Review of Physiology, 31:675–725. https://doi.org/10.1146/annurev.ph.31.030169.003331

[3] Bell-Pedersen, D., Cassone, V. M., Earnest, D. J., Golden, S. S., Hardin, P. E., Thomas, T. L., y Zoran, M. J. (2005). *Circadian rhythms from multiple oscillators: lessons from diverse organisms*. Nature Reviews Genetics, 6(7):544–556. https://doi.org/10.1038/nrg1633

[4] Mohawk, J. A., Green, C. B., y Takahashi, J. S. (2012). *Central and peripheral circadian clocks in mammals*. Annual Review of Neuroscience, 35:445–462. https://doi.org/10.1146/annurev-neuro-060909-153128

[5] Gómez-Abellán, P., Madrid, J. A., Ordovás, J. M., y Garaulet, M. (2012). *Aspectos cronobiológicos de la obesidad y el síndrome metabólico*. Endocrinología y Nutrición, 59(1):50–61. https://doi.org/10.1016/j.endonu.2011.08.002

[6] Klein, D. C., Moore, R. Y., y Reppert, S. M. (Eds.) (1991). *Suprachiasmatic Nucleus: The Mind's Clock*. Oxford University Press, Nueva York.

[7] Czeisler, C. A., y Klerman, E. B. (1999). *Circadian and sleep-dependent regulation of hormone release in humans*. Recent Progress in Hormone Research, 54:97–130.

[8] Roenneberg, T., y Merrow, M. (2016). *The Circadian Clock and Human Health*. Current Biology, 26(10):R432–R443. https://doi.org/10.1016/j.cub.2016.04.011

[9] Zhang, R., Lahens, N. F., Ballance, H. I., Hughes, M. E., y Hogenesch, J. B. (2014). *A circadian gene expression atlas in mammals: Implications for biology and medicine*. Proceedings of the National Academy of Sciences of the United States of America, 111(45):16219–16224. https://doi.org/10.1073/pnas.1408886111

[10] Hughes, M. E., DiTacchio, L., Hayes, K. R., Vollmers, C., Pulivarthy, S., Baggs, J. E., Panda, S., y Hogenesch, J. B. (2009). *Harmonics of Circadian Gene Transcription*

in Mammals. PLoS Genetics, 5(4):e1000442. https://doi.org/10.1371/journal.pgen.1000442

[11] Sulli, G., Manoogian, E. N. C., Taub, P. R., y Panda, S. (2018). *Training the Circadian Clock, Clocking the Drugs, and Drugging the Clock to Prevent, Manage, and Treat Chronic Diseases*. Trends in Pharmacological Sciences, 39(9). https://doi.org/10.1016/j.tips.2018.07.003

[12] Sahar S, Sassone-Corsi P. *Metabolism and cancer: the circadian clock connection. Nat Rev Cancer*. 2009 Dec;9(12):886-96. https://doi.org/10.1038/nrc2747. PMID: 19935677.

[13] Ruan, W., Yuan, X., y Eltzschig, H. K. (2021). *Circadian rhythm as a therapeutic target*. Nature Reviews Drug Discovery, 20(4):287–307. https://doi.org/10.1038/s41573-020-00109-w

[14] BaHammam, A. S., y Pirzada, A. (2023). *Timing matters: the interplay between early mealtime, circadian rhythms, gene expression, circadian hormones, and metabolism – implications for metabolic disease prevention*. Frontiers in Neuroendocrinology, 70:101082. https://doi.org/10.3389/fnins.2023.1287933

[15] Fudulu, D. P., Dimagli, A., Sinha, S., y Angelini, G. D. (2021). *Circadian variation in outcomes following cardiac surgery*. Journal of Clinical Medicine, 10(21):4966. https://doi.org/10.3390/jcm10214966

[16] Marcu, O., et al. (2024). *Circadian medicine: harnessing biological rhythms for therapeutic benefit*. npj Biological Timing and Sleep, 1:4. https://doi.org/10.1038/s44323-024-00005-3

[17] Ince, L. M., Barnoud, C., Gao, Y., Konsman, J. P., y Bhatt, D. L. (2023). *Circadian clocks and the immune response to infection*. The Lancet Microbe, 4(11):e879–e889. https://doi.org/10.1016/S2666-5247(23)00145-6

[18] Antoch, M. P., y Kondratov, R. V. (2013). *Pharmacological modulators of the circadian clock as potential therapeutic drugs: focus on genotoxic/anticancer therapy*. Handbook of Experimental Pharmacology, 217. https://doi.org/10.1007/978-3-642-25950-0_12

[19] Hesse, J., Martinelli, J., Aboumanify, O., Ballesta, A., y Relógio, A. (2021). *A mathematical model of the circadian clock and drug pharmacology to optimize irinotecan administration timing in colorectal cancer*. Computational and Structural Biotechnology Journal, 19:5170–5183. https://doi.org/10.1016/j.csbj.2021.08.051

[20] Ueda, H. R., Hayashi, S., Chen, W., Sano, M., Machida, M., Shigeyoshi, Y., Iino, M., y Hashimoto, S. (2005). *System-level identification of transcriptional circuits underlying mammalian circadian clocks*. Nature Genetics, 37(2):187–192. https://doi.org/10.1038/ng1504

[21] Panda, S., Antoch, M. P., Miller, B. H., Su, A. I., Schook, A. B., Straume, M., Schultz, P. G., Kay, S. A., Takahashi, J. S., y Hogenesch, J. B. (2002). *Coordinated Transcription of Key Pathways in the Mouse by the Circadian Clock*. Cell, 109(3):307–320. https://doi.org/10.1016/S0092-8674(02)00722-5

[22] GTEx Consortium (2020). *The GTEx Consortium atlas of genetic regulatory effects across human tissues*. Science, 369(6509):1318-1330. https://doi.org/10.1126/science.aaz1776

[23] Larriba, Y., Mason, I. C., Saxena, R., Scheer, F. A. J. L., y Rueda, C. (2023). *CIRCUST: A novel methodology for temporal order reconstruction of molecular rhythms; validation and application towards a daily rhythm gene expression atlas in humans*. PLOS Computational Biology, 19(9):e1011510. https://doi.org/10.1371/journal.pcbi.1011510

[24] Brown, S. A., Fleury-Olela, F., Nagoshi, E., Hauser, C., Juge, C., Meier, C. A., Chicheportiche, R., Dayer, J.-M., Albrecht, U., y Schibler, U. (2005). *The Period Length of Fibroblast Circadian Gene Expression Varies Widely Among Human Individuals*. PLoS Biology, 3(10):e338. https://doi.org/10.1371/journal.pbio.0030338

[25] Walker, W. H., Walton, J. C., DeVries, A. C., y Nelson, R. J. (2020). *Circadian rhythm disruption and mental health*. Translational Psychiatry, 10(1):28. https://doi.org/10.1038/s41398-020-0694-0

[26] Zhu, Y., Wang, L., Yin, Y., y Yang, E. (2017). *Systematic Analysis of Gene Expression Patterns Associated with Postmortem Interval in Human Tissues*. Scientific Reports, 7(1):5435. https://doi.org/10.1038/s41598-017-05882-0

[27] Rueda, C., Larriba, Y., y Peddada, S. (2019). *Frequency Modulated Möbius Model Accurately Predicts Rhythmic Signals in Biological and Physical Sciences*. Scientific Reports, 9:18701. https://doi.org/10.1038/s41598-019-54569-1

[28] Scholz, M. (2007). *Analysing Periodic Phenomena by Circular PCA*. En *Bioinformatics Research and Development (BIRD 2007)* (pp. 38-47). Springer.

[29] Larriba, Y., Rueda, C., Fernández, M. A., y Peddada, S. D. (2016). *Order restricted inference for oscillatory systems for detecting rhythmic signals*. Nucleic Acids Research, 44(22):e163. https://doi.org/10.1093/nar/gkw771

[30] Anafi, R., Francey, L., Hogenesch, J., y Kim, J. (2017). *CYCLOPS reveals human transcriptional rhythms in health and disease*. Proceedings of the National Academy of Sciences of the United States of America, 114(20):5312–5317. https://doi.org/10.1073/pnas.1619320114

[31] Hammarlund, J. A. (2025). *CYCLOPS 2.0: improving and applying circadian phase reconstruction in confounded datasets* (Tesis doctoral). Drexel University, Filadelfia, Pensilvania.

[32] Ansary Ogholbake, A., y Cheng, Q. (2023). *PENN: Phase Estimation Neural Network on Gene Expression Data*. En *Deep Learning, Big Data and Blockchain (DBB 2023)*. Lecture Notes in Networks and Systems, vol. 768, pp. 59–67. Springer. https://doi.org/10.1007/978-3-031-42317-8_5

[33] Ansary Ogholbake, A., y Cheng, Q. (2025). *PROTECT: Protein circadian time prediction using unsupervised learning*. iScience, 28(10):113605. https://doi.org/10.1016/j.isci.2025.113605

[34] Ananthasubramaniam, B., y Venkataramanan, R. (2025). *Rhythm profiling using COFE reveals multi-omic circadian rhythms in human cancers in vivo*. PLoS Biology, 23(5):e3003196. https://doi.org/10.1371/journal.pbio.3003196

[35] Talamanca, L. (2023). *Statistical physics of periodic biological processes* (Tesis doctoral). École Polytechnique Fédérale de Lausanne (EPFL), Lausana.

[36] Talamanca, L., et al. (2023). *Sex-dimorphic and age-dependent organization of 24-hour gene expression rhythms in humans*. Science, 379(6631):478-483. https://doi.org/10.1126/science.add0846

[37] Ruben, M. D., Wu, G., Smith, D. F., Schmidt, R. E., Francey, L. J., Lee, Y. Y., et al. (2018). *A database of tissue-specific rhythmically expressed human genes has potential applications in circadian medicine*. Science Translational Medicine, 10(458):eaat8806. https://doi.org/10.1126/scitranslmed.aat8806

[38] Thaben, P. F., y Westermark, P. O. (2014). *Detecting rhythms in time series with RAIN*. Journal of Biological Rhythms, 29(6):391–400. https://doi.org/10.1177/0748730414553029

[39] Hughes, M. E., Hogenesch, J. B., y Kornacker, K. (2010). *JTK_CYCLE: an efficient nonparametric algorithm for detecting rhythmic components in genome-scale data sets*. Journal of Biological Rhythms, 25(5):372–380. https://doi.org/10.1177/0748730410379711

[40] Dyar, K. A., Lutter, D., Artati, A., Ceglia, N. J., Liu, Y., Armenta, D., et al. (2018). *Atlas of circadian metabolism reveals system-wide coordination and communication between clocks*. Cell, 174(6):1571–1585. https://doi.org/10.1016/j.cell.2018.08.042

[41] Wei, H., y Bhatt, D. L. (2022). *Circadian rhythm in cardiovascular disease*. Nature Reviews Cardiology, 19:726–727. https://doi.org/10.1038/s41569-022-00746-9

[42] Wu, G., Ruben, M. D., Schmidt, R. E., Francey, L. J., Smith, D. F., Anafi, R. C., et al. (2018). *Population-level rhythms in human skin with implications for circadian medicine*. Proceedings of the National Academy of Sciences of the United States of America, 115(48):12313–12318. https://doi.org/10.1073/pnas.1809442115

[43] Mure, L. S., Le, H. D., Benegiamo, G., Chang, M. W., Rios, L., Jillani, N., et al. (2018). *Diurnal transcriptome atlas of a primate across major neural and peripheral tissues*. Science, 359(6381):eaao0318. https://doi.org/10.1126/science.aao0318

[44] Kimura, M., Murase, K., Azuma, M., Toyama, Y., Aihara, K., Oga, T., Chin, K., y Takahashi, K. (2023). *Irregular sampling bias in post-mortem transcriptomic circadian studies*. Chronobiology International, 40(4):472–481. https://doi.org/10.1080/07420528.2023.2178692

[45] Gorczyca, M. T., y Mostafavi, S. (2025). *Characterizing circadian gene expression in the human brain using post-mortem RNA-seq data*. PLOS Computational Biology, 21(1):e1012685. https://doi.org/10.1371/journal.pcbi.1012685

[46] Lech, K., Ackermann, K., Revell, V. L., Lao, O., Skene, D. J., y Kayser, M. (2016). *Dissecting daily and circadian expression rhythms of clock-controlled genes in human blood*. Journal of Biological Rhythms, 31(1):68–81. https://doi.org/10.1177/0748730415611761

[47] Bozek, K., Relógio, A., Kielbasa, S. M., Heine, M., Dame, C., Kramer, A., et al. (2009). *Regulation of clock-controlled genes in mammals*. PLOS ONE, 4(3):e4882. https://doi.org/10.1371/journal.pone.0004882

[48] Cornelissen, G. (2014). *Cosinor-based rhythmometry*. Theoretical Biology & Medical Modelling, 11:16. https://doi.org/10.1186/1742-4682-11-16

[49] Hughey, J. J., Hastie, T., y Butte, A. J. (2016). *ZeitZeiger: supervised learning for high-dimensional data from an oscillatory system*. Nucleic Acids Research, 44(8):e80. https://doi.org/10.1093/nar/gkw030

[50] Braun, R., Kath, W. L., Iwanaszko, M., Kula-Eversole, E., Abbott, S. M., Reid, K. J., Zee, P. C., y Allada, R. (2018). *Universal method for robust detection of circadian*

state from gene expression. Proceedings of the National Academy of Sciences of the United States of America, 115(39):E9247–E9256. https://doi.org/10.1073/pnas.1800314115

[51] Larriba, Y., Rueda, C., Fernández, M. A., y Peddada, S. D. (2020). *Order restricted inference in chronobiology*. Statistics in Medicine, 39(3):265–278. https://doi.org/10.1002/sim.8397

[52] Ueda, H. R., Chen, W., Minami, Y., Honma, S., Honma, K., Iino, M., y Hashimoto, S. (2004). *Molecular-timetable methods for detection of body time and rhythm disorders from single-time-point genome-wide expression profiles*. Proceedings of the National Academy of Sciences of the United States of America, 101(31):11227–11232. https://doi.org/10.1073/pnas.0401882101

[53] Barragán, S., Rueda, C., y Fernández, M. A. (2015). *Circular Rank Aggregation and its Application to Cell-cycle Genes Expressions*.